Data Science

Level 2

01. 통계 분석 개요

1 개요

통계분석의 정의

- 수집된 데이터에 통계학적 원리와 기법을 적용하여 데이터에 내재된 정보와 패턴을 추출하고, 이를 통해 의미 있는 결론을 도출하는 체계적 과정

통계분석의 목적

- **현상의 기술과 요약** : 수집된 데이터의 특성과 분포를 파악
- **관계의 탐지** : 변수 간의 상관관계와 인과관계 분석
- **추론과 일반화** : 표본으로부터 모집단의 특성 추정
- **예측과 의사결정** : 미래 현상에 대한 예측과 최적 의사결정 지원

1 개요

통계분석의 분류

- 기술통계학(descriptive statistics) : 수집된 데이터를 요약하고 기술하는 통계 분야
- 추론통계학(inferential statistics) : 표본 정보를 이용하여 모집단에 대한 추론을 수행하는 통계 분야

2 모집단과 표본

관련 용어

- **모집단(population)** : 통계분석 방법을 적용할 관심 대상의 전체 집합
- **표본(sample)** : 직접적인 조사 대상이 된 모집단의 일부
- **표본추출(sampling)** : 모집단으로부터 표본을 얻는 과정 또는 방법
- **통계량(statistics)** : 표본을 분석하여 얻는 값
- **모수(parameters)** : 모집단을 분석하여 얻는 값

2 모집단과 표본

주요 개념간 관계

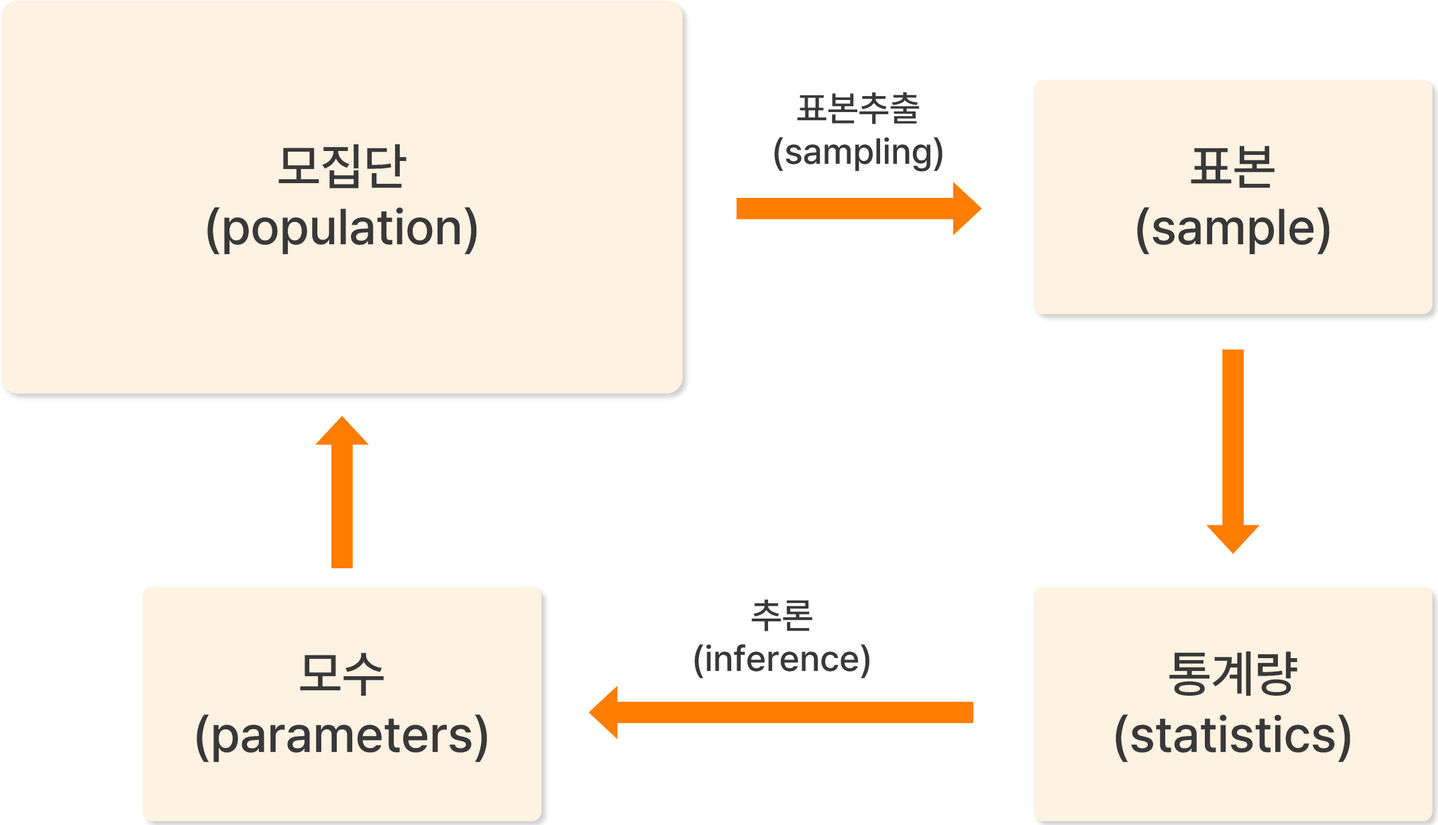

3 관련 기호

그리스 문자

대문자	소문자	발음
A	α	alpha
B	β	beta
Γ	γ	gamma
Δ	δ	delta
E	ϵ	epsilon
Z	ζ	zeta
H	η	eta
Θ	θ	theta

대문자	소문자	발음
I	ι	iota
K	κ	kappa
Λ	λ	lambda
M	μ	mu
N	ν	nu
Ξ	α	xi
O	o	omicron
Π	π	pi

대문자	소문자	발음
P	ρ	rho
Σ	σ	sigma
T	τ	tau
Υ	υ	upsilon
Φ	ϕ	phi
X	χ	chi
Ψ	ψ	psi
Ω	ω	omega

3 관련 기호

모수와 통계량 관련 기호

구분	모수	통계량
평균	μ	$\bar{x}$
분산	σ^2	s^2
표준편차	σ	s
비율	P	$\hat{P}$

4 데이터의 이해

데이터의 정의

- 관찰이나 측정을 통해 수집된 사실이나 정보의 집합

데이터의 핵심 특징

- 현실 세계의 현상을 수치화하거나 기호화한 형태
- 분석과 해석을 통해 정보와 지식으로 변환 가능
- 의사결정의 근거로 활용되는 원시(raw) 자료

4 데이터의 이해

데이터 포인트(Data Point)

- 데이터셋에서 하나의 개별 관측값 또는 기록
- 관측값(observation), 사례(instance), 표본(sample), 레코드(record) 로도 불림

데이터셋(Dataset)

- 동일한 구조를 가진 데이터 포인트들의 집합
- 행(row)과 열(column)로 구성된 표 형태(tabular data) 가 일반적
- 분석의 기본 단위가 되는 데이터 집합체

변수(Variable)

- 데이터 포인트의 특성이나 속성을 나타내는 측정 가능한 요소
- 독립변수(independent variable) : 다른 변수에 영향을 주는 변수로 보통 "X"로 표기
- 종속변수(dependent variable) : 독립변수의 영향을 받는 변수로 보통 "Y"로 표기
- 독립변수는 설명변수(explanatory variable), 특성(feature)으로도 표기
- 종속변수는 결과변수(outcome variable), 타겟(target)으로도 표기

변수(variable)

ID	생산라인	중량
1001	A	101
1002	A	99
1003	B	102
1004	C	89

Data Point

수치형 데이터(Numerical Data)

- 숫자로 표현되며 수학적 연산이 가능한 데이터
- 연속형 데이터(continuous data)와 이산형 데이터(discrete data)로 나뉨
- 이산형 데이터 : 정수 또는 특정 값들만 가능하며 (일반적으로) 셀 수 있는 개별적인 값
- 연속형 데이터 : 실수 범위에서 모든 값이 가능하며 무한히 많은 값을 가질 수 있음

※ 연속형 데이터는 등간형(interval)과 비율형(ratio)으로 나누어짐

범주형 데이터(Categorical Data)

- 범주나 그룹으로 분류되는 질적 데이터
- 명목형 데이터(nominal data)와 순서형 데이터(ordinal data)로 나뉨
- 명목형 데이터 : 지역명, 색상 등 순서가 없는 범주형 데이터
- 순서형 데이터 : 순서나 등급이 있는 범주형 데이터

5 측정 척도

측정 척도(Scale of Measurement)의 개념

- 측정(measurement) : 현실 세계의 특성이나 속성을 숫자나 기호로 표현하는 과정
- 척도(scale) : 측정할 때 사용하는 기준이나 규칙
- 측정 척도에는 명목/순서/구간/비율 척도가 있음

5 측정 척도

명목 척도(Nominal Scale)

- 이름표를 붙이는 것으로 단순히 구분하고 분류하는 용도
- 제품명, 전화번호, 색상 등이 해당됨

순서 척도(Ordinal Scale)

- 순서/순위를 지정하기 위한 용도
- 등수, 리뷰의 별점, 만족도 등이 해당됨

5 측정 척도

구간 척도(Interval Scale)

- 간격은 의미 있지만 절대적인 '0'이 없음
- 온도, 연도, IQ 등이 해당됨

비율 척도(Ratio Scale)

- 진짜 '0'이 존재하고 모든 수학 연산이 의미 있음
- 키, 몸무게, 돈 등이 해당됨

6 문제 풀이

Q1. 다음 중 수치형 데이터의 특징에 대한 설명으로 가장 적절한 것은?

1. 항상 연속형 데이터이다.
2. 연속형과 이산형으로 나뉘며, 실수 범위에서 모든 값이 가능하다.
3. 범주형 데이터와 동일한 개념이다.
4. 수학적 연산이 불가능하다.

6 문제 풀이

Q1. 다음 중 수치형 데이터의 특징에 대한 설명으로 가장 적절한 것은?

1. 항상 연속형 데이터이다.
2. 연속형과 이산형으로 나뉘며, 실수 범위에서 모든 값이 가능하다.
3. 범주형 데이터와 동일한 개념이다.
4. 수학적 연산이 불가능하다.

해설

**수치형 데이터는 연속형 데이터와 이산형 데이터로 나뉘고,
연속형 데이터는 실수 범위에서 모든 값이 가능하며
무한히 많은 값을 가질 수 있다.**

6 문제 풀이

Q2. 데이터 포인트(Data Point)에 대한 설명으로 옳지 않은 것은?

1. 데이터셋에서 하나의 개별 관측값 또는 기록을 의미한다.
2. 관측값(observation)과 같은 의미로 사용된다.
3. 데이터 포인트들이 모여서 데이터셋을 구성한다.
4. 데이터 포인트는 반드시 숫자로만 구성되어야 한다.

6 문제 풀이

Q2. 데이터 포인트(Data Point)에 대한 설명으로 옳지 않은 것은?

1. 데이터셋에서 하나의 개별 관측값 또는 기록을 의미한다.
2. 관측값(observation)과 같은 의미로 사용된다.
3. 데이터 포인트들이 모여서 데이터셋을 구성한다.
4. 데이터 포인트는 반드시 숫자로만 구성되어야 한다.

해설

데이터 포인트는 숫자 뿐만 아니라 범주형 값 등 다양한 형태의 데이터를 포함할 수 있다. 예를 들어, 이름, 성별, 지역 등도 데이터 포인트의 구성 요소가 될 수 있다.

6 문제 풀이

Q3. 모수(Parameters)와 통계량(Statistics)에 대한 설명으로 옳지 않은 것은?

1. 모수는 모집단을 분석하여 얻는 값이다.
2. 통계량은 표본을 분석하여 얻는 값이다.
3. 모수는 변하는 값이고, 통계량은 고정된 값이다.
4. 모집단 평균은 μ로, 표본 평균은 x로 표기한다.

6 문제 풀이

Q3. 모수(Parameters)와 통계량(Statistics)에 대한 설명으로 옳지 않은 것은?

1. 모수는 모집단을 분석하여 얻는 값이다.
2. 통계량은 표본을 분석하여 얻는 값이다.
3. 모수는 변하는 값이고, 통계량은 고정된 값이다.
4. 모집단 평균은 μ로, 표본 평균은 x로 표기한다.

해설

모수는 모집단의 특성을 나타내는 고정된 값이고,
통계량은 표본에 따라 변하는 값이다.

6 문제 풀이

Q4. 다음 데이터 중 비율 척도(Ratio Scale)에 해당하는 것은?

1. 온도(섭씨)
2. 학점(A, B, C, D, F)
3. 키(cm)
4. 전화번호

6 문제 풀이

Q4. 다음 데이터 중 비율 척도(Ratio Scale)에 해당하는 것은?

1. 온도(섭씨)
2. 학점(A, B, C, D, F)
3. 키(cm)
4. 전화번호

해설

비율 척도는 진짜 '0'이 존재하고 모든 수학 연산이 의미 있는 척도이다. 키는 절대 영점(0cm)이 존재하고 비율 계산이 의미 있으므로 비율 척도에 해당한다.
온도(섭씨)는 구간 척도, 학점은 순서 척도, 전화번호는 명목 척도이다.

6 문제 풀이

Q5. 다음 중 명목 척도(Nominal Scale)와 순서 척도(Ordinal Scale)의 차이점에 대한 설명으로 가장 적절한 것은?

1. 명목 척도는 숫자로 표현되고, 순서 척도는 문자로 표현된다.
2. 명목 척도는 단순 구분 및 분류, 순서 척도는 순서나 등급이 있는 범주형 데이터이다.
3. 명목 척도에서는 평균 계산이 가능하지만, 순서 척도에서는 불가능하다.
4. 명목 척도와 순서 척도는 본질적으로 동일한 측정 방법이다.

6 문제 풀이

Q5. 다음 중 명목 척도(Nominal Scale)와 순서 척도(Ordinal Scale)의 차이점에 대한 설명으로 가장 적절한 것은?

1. 명목 척도는 숫자로 표현되고, 순서 척도는 문자로 표현된다.
2. 명목 척도는 단순 구분 및 분류, 순서 척도는 순서나 등급이 있는 범주형 데이터이다.
3. 명목 척도에서는 평균 계산이 가능하지만, 순서 척도에서는 불가능하다.
4. 명목 척도와 순서 척도는 본질적으로 동일한 측정 방법이다.

해설

명목 척도는 이름표를 붙이는 것으로 단순히 구분하고 분류하는 용도(예: 제품명, 색상)이며, 순서 척도는 순서나 등급이 있는 범주형 데이터(예: 등수, 별점, 만족도)이다.