Data Science

Level 2

02. 통계량

1 통계량 개요

통계량의 정의

- 표본의 특성을 요약하고 모집단의 모수를 추정하거나 가설을 검정하는 데 사용되는 값

$$T = T(X_1, X_2, \dots, X_n)$$

통계량의 핵심 특성

- 표본에 따라 값이 변하는 확률변수
- 모집단 모수의 추정량 역할
- 통계적 가설검정의 기준으로 활용
- 표본 정보를 간결하게 요약

1 통계량 개요

통계량의 종류

- **기술통계량(descriptive statistics)** : 표본 데이터의 특성을 요약하고 기술하는 통계량
- **검정통계량(test statistics)** : 가설검정에서 사용되는 통계량
- **추정량(estimators)** : 모수를 추정하는 통계량
- **순서통계량(order statistics)** : 데이터를 크기 순으로 정렬한 후 위치에 따른 통계량.
- **충분통계량(sufficient statistics)** : 모수에 대한 모든 정보를 포함하는 통계량

2 기술통계량

기술통계량의 활용

- 데이터의 중심경향, 변이, 분포의 형태를 파악하여 데이터의 전반적인 특성을 이해하는 데 사용

기술통계량의 목적

- 데이터의 전체적인 특성 파악
- 복잡한 데이터를 간단한 수치로 요약
- 데이터의 패턴과 구조 발견
- 추론통계의 기초 정보 제공

2 기술통계량

기술통계량의 종류

- 위치 통계량 (measures of location) : 데이터의 중심경향
- 변이 통계량 (measures of variability) : 데이터의 산포도
- 모양 통계량 (measures of shape) : 분포의 형태

2 기술통계량

위치 통계량의 정의

- 데이터의 중심적 위치나 대표값을 나타내는 통계량

주요 위치 통계량

- 평균(average)
- 중앙값, 중위수(median)
- 최빈값(mode)
- 분위수(quantile)

3 위치 통계량

평균

- **산술평균(arithmetic mean)** : 데이터의 합계를 데이터의 총 개수로 나눈 값으로 가장 일반적으로 사용
- **가중평균(weighted mean)** : 각 관측값에 가중치를 부여한 평균
- **기하평균(geometric mean)** : n개 양수의 곱의 n제곱근으로 **곱의 평균**이라고도 함
- **조화평균(harmonic mean)** : 역수들의 산술평균의 역수

조화평균 ≤ 기하평균 ≤ 산술평균

3 위치 통계량

평균의 계산

- 산술평균

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

- 가중평균

$$\overline{x_w} = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_n x_n}{w_1 + w_2 + \cdots + w_n}$$

- 기하평균

$$\overline{x_g} = \sqrt[n]{x_1 \cdot x_2 \cdot x_3 \cdots x_n}$$

- 조화평균

$$\overline{x_h} = \frac{n}{\frac{1}{x_1} + \frac{1}{x_2} + \cdots + \frac{1}{x_n}}$$

3 위치 통계량

산술평균의 특성

- 표본 데이터의 중심적 위치를 나타냄
- 모든 관측값을 고려하며 이상치에 민감
- 계산이 간단하고 직관적

가중평균의 특성

- 각 값의 중요도나 빈도가 다른 데이터에 적용
- 가중치의 합은 일반적으로 1 또는 n
- 모든 가중치가 같은 경우 산술평균과 동일

3 위치 통계량

기하평균의 특성

- 비율이나 성장률 데이터에 적합
- 항상 산술평균보다 작거나 같음
- 0이 포함되면 0이 됨

조화평균의 특성

- 속도, 밀도, 비율의 평균에 사용
- 항상 기하평균보다 작거나 같음
- 작은 값의 영향을 크게 받음

  ※ 하나의 값이라도 0에 가까우면 전체 평균이 급격히 감소

3 위치 통계량

중위수의 정의

- 데이터를 크기 순으로 정렬했을 때 중앙에 위치하는 값

중위수의 계산

- 데이터 개수가 짝수인 경우 가운데 있는 두 수의 평균으로 산출

숫자 개수가 홀수인 경우

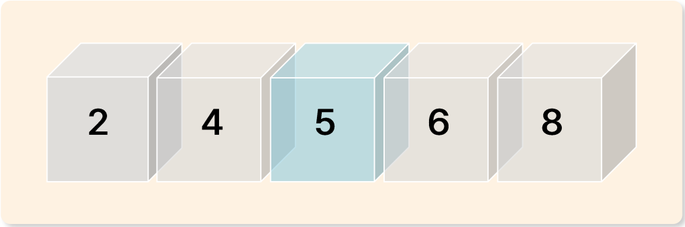

※ 중앙에 위치한 수(5)

숫자 개수가 짝수인 경우

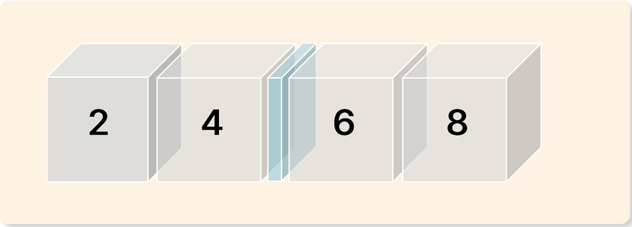

※ 중앙에 가까운 두 개의 값의 평균(5)

3 위치 통계량

중위수의 특성

- 이상치에 강건(robust) 또는 둔감함
- 한쪽으로 치우친 분포에서 평균보다 대표성이 높음

3 위치 통계량

최빈값의 정의

- 데이터에서 가장 자주 나타나는 값

최빈값의 특성

- 범주형 데이터에 적용 가능한 유일한 중심경향 측도
- 분포가 다봉(multimodal)일 경우 여러 개 존재 가능
- 연속형 데이터에서는 구간별 빈도로 근사

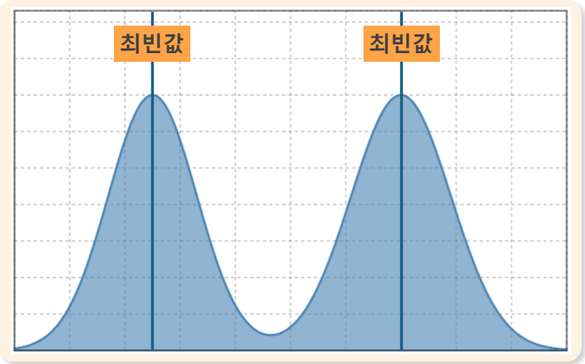

3 위치 통계량

분위수(Quantiles)의 정의

- 데이터를 일정 비율로 나누는 위치 값

분위수의 특성

- 이상치에 강건한 위치 측도
- 데이터의 분포와 형태를 파악하는 데 유용
- 상자그림(box plot)의 기초 요소

3 위치 통계량

분위수의 종류

- **사분위수(quartiles)** : 전체 데이터를 4개 구간으로 나누는 분위수
- **십분위수(deciles)** : 전체 데이터를 10개 구간으로 나누는 분위수
- **백분위수(percentiles)** : 전체 데이터를 100개 구간으로 나누는 분위수

3 위치 통계량

분위수 - 사분위수

- **제 1 사분위수(Q_1)**: 제 25 백분위수와 같으며 하위 25% 지점
- **제 2 사분위수(Q_2)**: 제 50 백분위수, 중위수와 같으며 하위 50% 지점
- **제 3 사분위수(Q_3)**: 제 75 백분위수와 같으며 하위 75% 지점

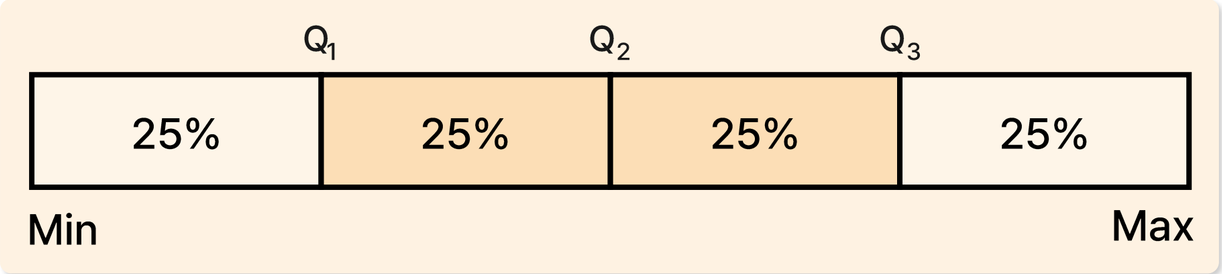

4 변이 통계량

변이 통계량의 정의

- 데이터의 흩어진 정도나 변동성을 측정하는 통계량

주요 변이 통계량

- **범위(range)** : 최댓값과 최솟값의 차이
- **사분위수 범위(IQR, Interquartile Range)** : 제1사분위수와 제3사분위수의 차이
- **분산(variance)** : 평균으로부터의 편차제곱의 평균
- **표준편차(standard deviation)** : 분산의 양의 제곱근
- **변동 계수(coefficient of variation)** : 표준편차를 평균으로 나눈 상대적 변동

4 변이 통계량

범위의 계산

$$R = x_{max} - x_{min}$$

범위의 특성

- 계산이 간단
- 극값에만 의존하므로 정보 손실이 큼
- 표본크기가 클수록 증가하는 경향

4 변이 통계량

사분위수 범위(IQR)의 계산

$$IQR = Q_3 - Q_1$$

사분위수 범위의 특성

- 범위 내 50%의 데이터를 포함
- 이상치에 강건(robust)
- 상자그림(box plot)의 핵심 요소

4 변이 통계량

분산의 계산

$$Var = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

분산의 특성

- 편차의 제곱을 사용하므로 이상치에 민감
- 항상 0 이상의 값(음수가 될 수 없음)
- 원 데이터의 단위를 제곱한 단위를 가짐
- 평균에 대해 이동 불변성을 가짐

4 변이 통계량

표준편차의 계산

$$Std = \sqrt{Var} = \left(\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2\right)^{0.5}$$

표준편차의 특성

- 분산의 양의 제곱근
- 원 데이터와 같은 단위를 가짐
- 평균에 대해 이동 불변성을 가짐

5 모양 통계량

모양 통계량의 정의

- 분포의 형태적 특성을 측정하는 통계량

모양 통계량의 종류

- 왜도(skewness) : 분포의 비대칭성을 측정
- 첨도(kurtosis) : 분포의 뾰족한 정도를 측정

5 모양 통계량

왜도의 계산

$$Skewness = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right]$$

왜도의 특성

- 데이터의 분포가 한쪽으로 치우쳐져 있을 수록 극단적인 값이 산출됨
- 치우침의 정도를 판단하기 위해 왜도의 절대값을 확인하기도 함

5 모양 통계량

왜도에 따른 위치 통계량의 상대적 위치

- 왜도가 양수인 경우 산술평균이 최빈값보다 크며 음수는 그 반대

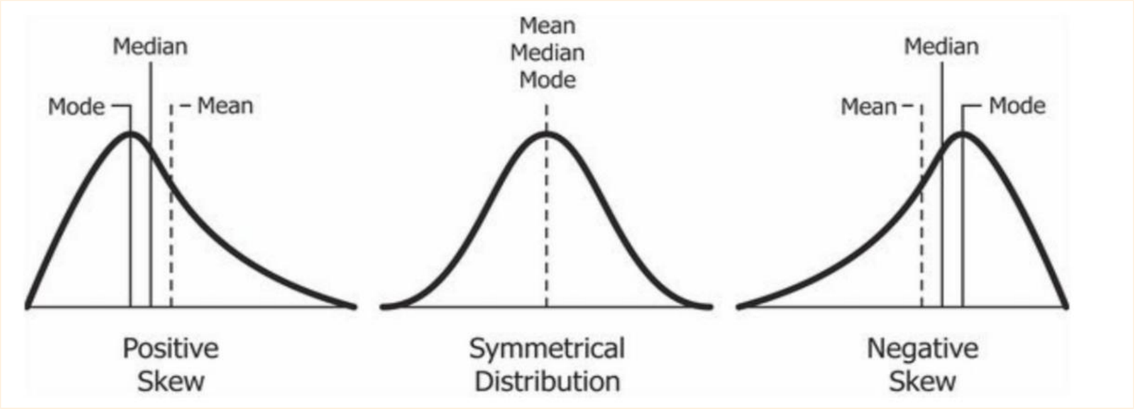

https://zetawiki.com/wiki/비대칭도

5 모양 통계량

왜도의 해석

- 왜도 = 0 : 데이터 분포가 대칭
- 왜도 > 0 : 데이터 분포가 왼쪽(음수쪽)으로 치우쳐짐(right skewed, 오른쪽 꼬리가 긴 분포)
- 왜도 < 0 : 데이터 분포가 오른쪽(양수쪽)으로 치우쳐짐(left skewed, 왼쪽 꼬리가 긴 분포)

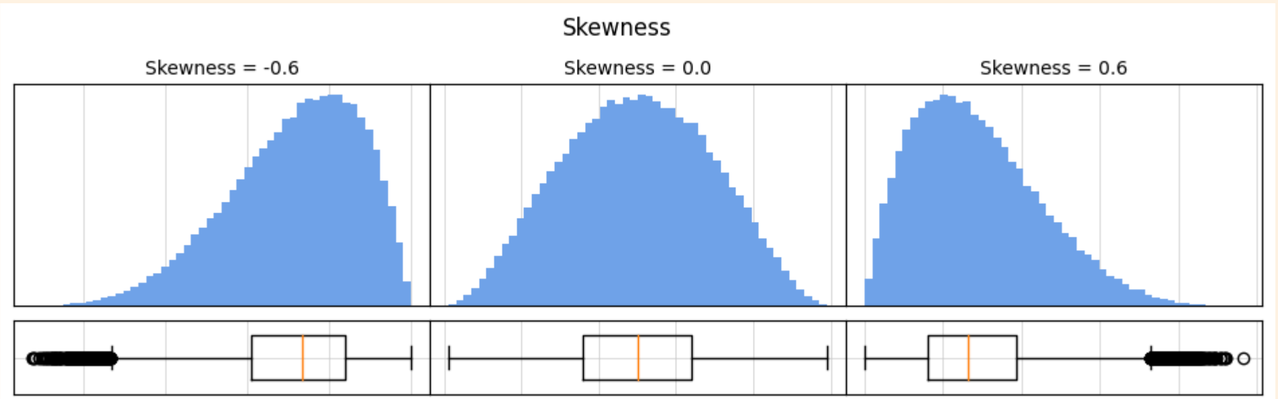

https://datadoctorblog.com/2023/08/19/Py-Stat-Descriptive-Statistics-shape/

5 모양 통계량

첨도의 계산

$$Kurtosis = E\left[\left(\frac{X-\mu}{\sigma}\right)^4\right]$$

$$Kurtosis_e = E\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] - 3$$

첨도의 특성

- 일반적으로 말하는 첨도는 초과 첨도(excess kurtosis)로 정규분포 기준 0
- 높은 첨도는 값들이 평균 주변에 집중됨을 뜻함

5 모양 통계량

첨도의 해석(초과첨도 기준)

- 첨도 = 0 : 정규분포와 첨도가 같음(mesokurtic)
- 첨도 > 0 : 정규분포보다 뾰족한 분포(leptokurtic)
- 첨도 < 0 : 정규분포보다 평평한 분포(platykurtic)

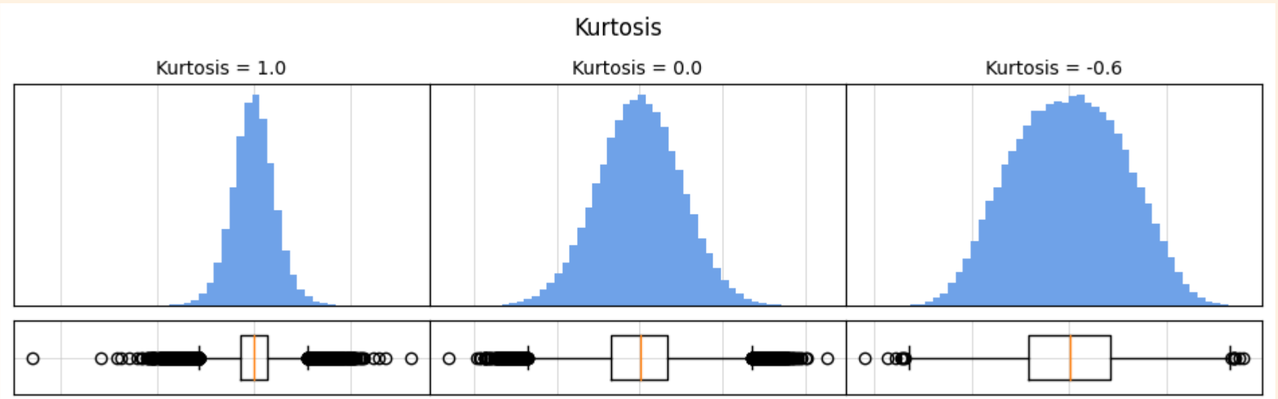

https://datadoctorblog.com/2023/08/19/Py-Stat-Descriptive-Statistics-shape/

6 통계량의 선형 연산

단일 변수의 선형 변환(Linear Transform)

- 단일 변수에 사칙연산이 가해질 경우 그 기대값(평균)/분산의 변환 결과에 대한 이해 필요

$$E(Y) = E[aX + b] = aE[X] + b$$

$$Var(Y) = Var(aX + b) = a^2 Var(X)$$

6 통계량의 선형 연산

두 변수의 선형 결합(Linear Combination)

- 두 변수의 결합에서 분산의 경우 독립 여부에 따라 공분산 계산 여부가 결정됨

$$E[Z] = aE[X] + bE[Y] + c$$

$$Var(Z) = a^2Var(X) + b^2Var(Y) \quad \text{(독립인 경우)}$$

$$Var(Z) = a^2Var(X) + b^2Var(Y) + 2ab \cdot Cov(X, Y)$$

7 문제 풀이

Q1. 전체 데이터를 4개 구간으로 나누는 사분위수에서, 제 2 사분위수(Q_2)와 같은 의미를 가지는 것은?

1. 제 25 백분위수
2. 중위수(median)
3. 제 75 백분위수
4. 최빈값(mode)

7 문제 풀이

Q1. 전체 데이터를 4개 구간으로 나누는 사분위수에서, 제 2 사분위수(Q_2)와 같은 의미를 가지는 것은?

1. 제 25 백분위수
2. 중위수(median)
3. 제 75 백분위수
4. 최빈값(mode)

해설

제2사분위수(Q_2)는 중위수와 동일한 개념으로 둘 다 하위 50% 지점을 나타냄

7 문제 풀이

Q2. 다음 중 첨도(Kurtosis)에 대한 설명으로 옳은 것은?

1. 첨도가 0이면 정규분포와 같은 첨도를 가진다.
2. 첨도가 양수이면 정규분포보다 평평한 분포이다.
3. 첨도가 음수이면 정규분포보다 뾰족한 분포이다.
4. 첨도는 분포의 비대칭성을 측정하는 지표이다.

7 문제 풀이

Q2. 다음 중 첨도(Kurtosis)에 대한 설명으로 옳은 것은?

1. 첨도가 0이면 정규분포와 같은 첨도를 가진다.
2. 첨도가 양수이면 정규분포보다 평평한 분포이다.
3. 첨도가 음수이면 정규분포보다 뾰족한 분포이다.
4. 첨도는 분포의 비대칭성을 측정하는 지표이다.

해설

첨도가 0이면 정규분포와 같은 첨도를 가지며, 양수는 뾰족한 분포, 음수는 평평한 분포를 의미(초과첨도 기준)

7 문제 풀이

Q3. 데이터 {2, 8, 6, 4, 10}에서 사분위수 범위(IQR)를 구하면?

1. 2
2. 4
3. 6
4. 8

7 문제 풀이

Q3. 데이터 {2, 8, 6, 4, 10}에서 사분위수 범위(IQR)를 구하면?

1. 2
2. 4
3. 6
4. 8

해설

데이터를 오름차순으로 정렬한 후 제 1 사분위수와 제 3 사분위수를 확인하면
각각 4와 8이 되며 최종적으로 사분위 범위는 4로 계산된다.

7 문제 풀이

Q4. 조화평균에 대한 설명으로 옳지 않은 것은?

1. 역수들의 산술평균의 역수이다.
2. 속도, 밀도, 비율의 평균에 사용된다.
3. 항상 기하평균보다 크거나 같다.
4. 작은 값의 영향을 크게 받는다.

7 문제 풀이

Q4. 조화평균에 대한 설명으로 옳지 않은 것은?

1. 역수들의 산술평균의 역수이다.
2. 속도, 밀도, 비율의 평균에 사용된다.
3. 항상 기하평균보다 크거나 같다.
4. 작은 값의 영향을 크게 받는다.

해설

조화평균은 항상 기하평균보다 작거나 같다.

7 문제 풀이

Q5. 변수 X에 대해 Y = 3X + 5의 선형변환을 했을 때,
E[X] = 10, Var(X) = 4라면 Var(Y)는?

1. 16
2. 149
3. 47
4. 36

7 문제 풀이

Q5. 변수 X에 대해 Y = 3X + 5의 선형변환을 했을 때, E[X] = 10, Var(X) = 4라면 Var(Y)는?

1. 16
2. 149
3. 47
4. 36

해설

분산의 경우 덧셈과 뺄셈은 변환에 영향을 주지 않고, 변수의 계수만 제곱의 형태로 영향을 준다. 그리하여 최종적으로 36이 산출된다.