Data Science

Level 2

03. 자료의 표현

1 개요

원시자료(Raw Data)의 정의

- 원시자료는 수집된 상태 그대로의 데이터로, 가공되지 않은 형태

원시자료의 한계

- 대량의 데이터는 그 자체로는 의미 있는 정보를 파악하기 어려움
- 데이터의 분포나 경향을 직관적으로 이해하기 힘듦
- 여러 그룹이나 시점 간의 비교가 어려움
- 원시 상태의 데이터로 명확한 통찰을 얻기 어려움

1 개요

자료 정리의 필요성

- 효과적인 데이터 분석을 위해서는 **원시자료를 표나 그래프로 정리하고 요약**할 필요가 있음

자료 정리의 효과

- 인간의 정보 처리 한계를 극복하여 대용량 데이터의 이해 가능
- 데이터의 분포, 중심경향, 변이성 등의 통계적 특성을 명확히 파악 가능
- 정리된 정보를 바탕으로 보다 합리적이고 신속한 의사결정을 내릴 수 있음

1 개요

표 형식의 장점

- 정확한 수치 정보 제공
- 계산과 검증이 용이

그래프 형식의 장점

- 직관적인 이해 가능
- 시각적 임팩트 제공
- 패턴과 추세의 명확한 표현
- 비전문가도 쉽게 이해 가능

2 도수분포표

도수분포표(Frequency Distribution Table)의 정의

- 데이터의 각 값이나 구간에 대해 나타나는 빈도를 체계적으로 정리한 표

관련 용어

- **도수(Frequency)** : 특정 값이나 구간에 속하는 관측값의 개수
- **상대도수(Relative frequency)** : 전체 관측값에 대한 각 구간의 도수 비율
- **누적도수(Cumulative frequency)** : 특정 값 이하의 모든 도수를 합한 값

2 도수분포표

질적 자료의 도수분포표

- 범주형 데이터의 경우, 각 범주별로 빈도를 계산하여 도수분포표를 작성

재고 품목	도수(f)	상대도수	백분율(%)
절연 장갑	25	0.25	25
볼트	20	0.20	20
너트	15	0.15	15
손세정제	30	0.30	30
복사용지	10	0.10	10
합계	100	1.00	100

2 도수분포표

양적 자료의 도수분포표

- 연속형 데이터의 경우 계급구간을 설정하여 도수분포표를 작성

관련 용어

- **계급(class, bin)** : 연속적인 수치를 일정한 구간으로 나눈 것
- **계급폭(class width, bin width)** : 각 계급의 범위
- **계급값(class mark)** : 각 계급의 중앙값
- **계급경계** : 인접한 계급 간의 경계점

2 도수분포표

양적 자료의 도수분포표 예시

계급 구간	계급값	도수	상대도수	누적도수
180-184	182	5	0.10	5
185-189	187	8	0.16	13
190-194	192	15	0.30	28
195-199	197	12	0.24	40
200-204	202	7	0.14	47
205-210	207	3	0.06	50
합계		50	1.00	

3 분할표

분할표의 정의

- 두 개 이상의 범주형 변수의 조합에 따른 빈도를 표로 나타낸 것

	B_1	B_2	…	B_j	…	B^c	합계
A_1	n_{11}	n_{12}	…	n_{1j}	…	n_1^c	$n_{1.}$
A_1	n_{21}	n_{22}	…	n_{2j}	…	n_2^c	$n_{2.}$
…	…	…	…	…	…	…	…
A_i	n_{i1}	n_{i2}	…	n_{ij}	…	n_i^c	$n_{i.}$
…	…	…	…	…	…	…	…
A^r	n_1^r	n_2^r	…	n_j^r	…	n^{rc}	$n_.^r$
합계	$n_{.1}$	$n_{.2}$	…	$n_{.j}$	…	$n_.^c$	n

3 분할표

분할표의 구성요소

- **주변도수(Marginal frequency)**
  : 각 변수의 개별 범주에 대한 도수의 합
- **결합도수(Joint frequency)**
  : 두 변수의 특정 범주 조합에 해당하는 도수
- **조건부 상대도수(Conditional relative frequency)**
  : 한 변수의 특정 범주가 주어졌을 때, 다른 변수의 각 범주가 나타날 상대적 빈도

3 분할표

분할표의 구성요소 예시

- 성별과 선호 음료 분할표

	커피	차	주스	합계
남성	45	15	20	80
여성	25	35	40	100
합계	70	50	60	180

- 결합상대도수표

	커피	차	주스	합계
남성	0.25	0.08	0.11	0.44
여성	0.14	0.19	0.22	0.56
합계	0.39	0.28	0.33	1.00

4 데이터 시각화

데이터 시각화(Data Visualization)의 정의

- 그래픽 형태로 표현하여 데이터의 패턴, 경향, 관계를 직관적으로 이해할 수 있게 하는 과정

시각화의 목적

- 복잡한 수치 데이터를 직관적으로 이해할 수 있는 형태로 변환
- 데이터에 숨겨진 규칙성, 추세, 이상치 등을 탐지
- 서로 다른 그룹, 시점, 조건 간의 차이를 기반으로 비교 분석 가능
- 비전문가의 효과적이고 효율적인 정보 이해 지원

4 데이터 시각화

그래프의 분류 - 변수의 개수에 따른 분류

- 일변량 그래프(Univariate graph) : 히스토그램, 막대그래프, 원그래프, 상자그림 등
- 이변량 그래프(Bivariate graph) : 산점도, 선그래프, 복합막대그래프 등

그래프의 분류 - 데이터 유형에 따른 분류

- 범주형 데이터 : 막대그래프, 원그래프
- 연속형 데이터 : 히스토그램, 상자그림
- 혼합형 데이터 : 그룹별 상자그림, 막대그래프

5 일변량 그래프

개요

- **히스토그램(Histogram)** : 표로 되어 있는 도수 분포를 정보 그림으로 나타낸 것
- **원 그래프(Pie chart)** : 전체에 대한 각 부분의 비율을 부채꼴 모양으로 백분율로 나타낸 그래프
- **막대 그래프(Bar chart)** : 직사각형 막대의 높이 또는 너비를 값에 비례하여 표현하는 그래프
- **상자 그림(Box plot)** : 5가지 요약수치를 기반으로 데이터의 분포를 표현하는 그래프

5 일변량 그래프

막대 그래프

- 범주형 변수의 원소 개수를 막대로 표현한 그래프
- 원소 개수를 뜻하는 수치형 정보는 보통 y축을 기준으로 표기

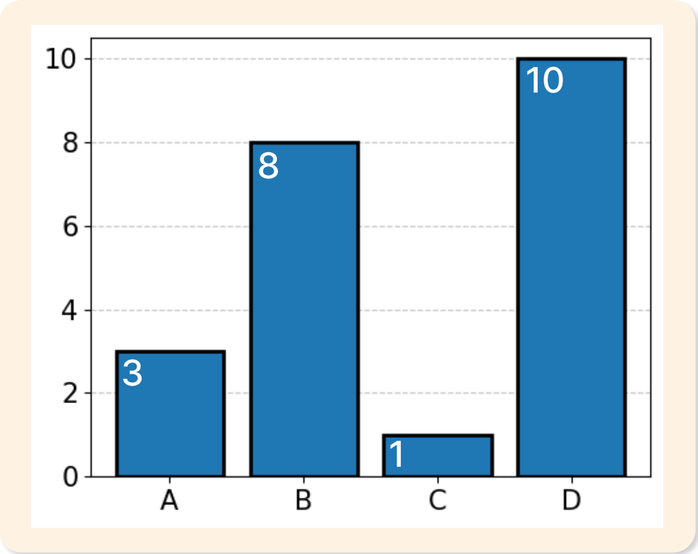

type
A
A
A
B
B
B
B
B
B
B
B

3개

8개

type
C
D
D
D
D
D
D
D
D
D

1개

10개

5 일변량 그래프

히스토그램

- 표로 되어 있는 도수 분포(도수분포표)를 정보 그림으로 나타낸 것
- 막대는 각 계급의 도수를 나타냄
- 계급폭에 따라 막대 개수가 정해짐

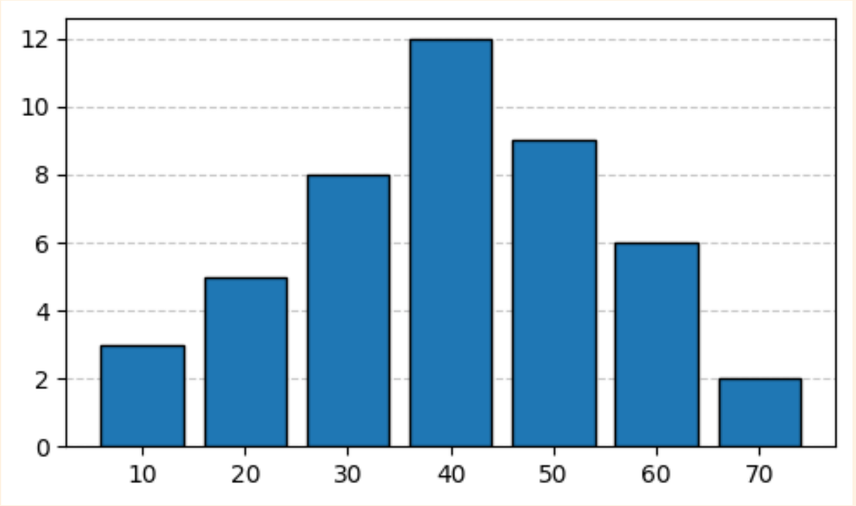

나이대	도수
10대	3
20대	5
30대	8
40대	12
50대	9
60대	6
70대	2

5 일변량 그래프

원 그래프

- 전체에 대한 각 범주의 비율을 원의 부채꼴로 나타낸 그래프
- 각 범주의 구성비에 비례하여 각 범주에 해당하는 부채꼴의 중심각이 결정됨
- 전체에 대한 각 부분의 비율을 직관적으로 표현
- 범주가 많을 경우 표현 및 해석이 어려움

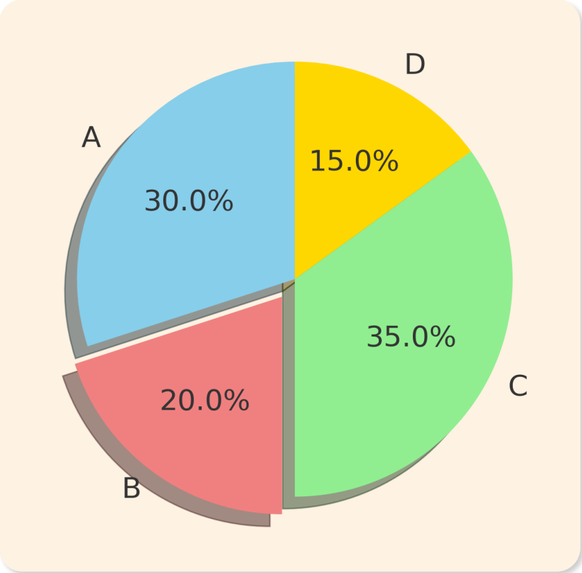

5 일변량 그래프

상자 그림

- 데이터의 분포를 5개 수치 요약(5-number summary)을 통해 나타낸 그래프
- 5개 수치 요약은 최소/최대, 사분위수로 이루어져 있음
- 하단 수염은 Q_1에서 Q_1 - 1.5×IQR 범위 내의 최솟값까지로 그려짐
- 상단 수염은 Q_3에서 Q_3 + 1.5×IQR 범위 내의 최댓값까지로 그려짐

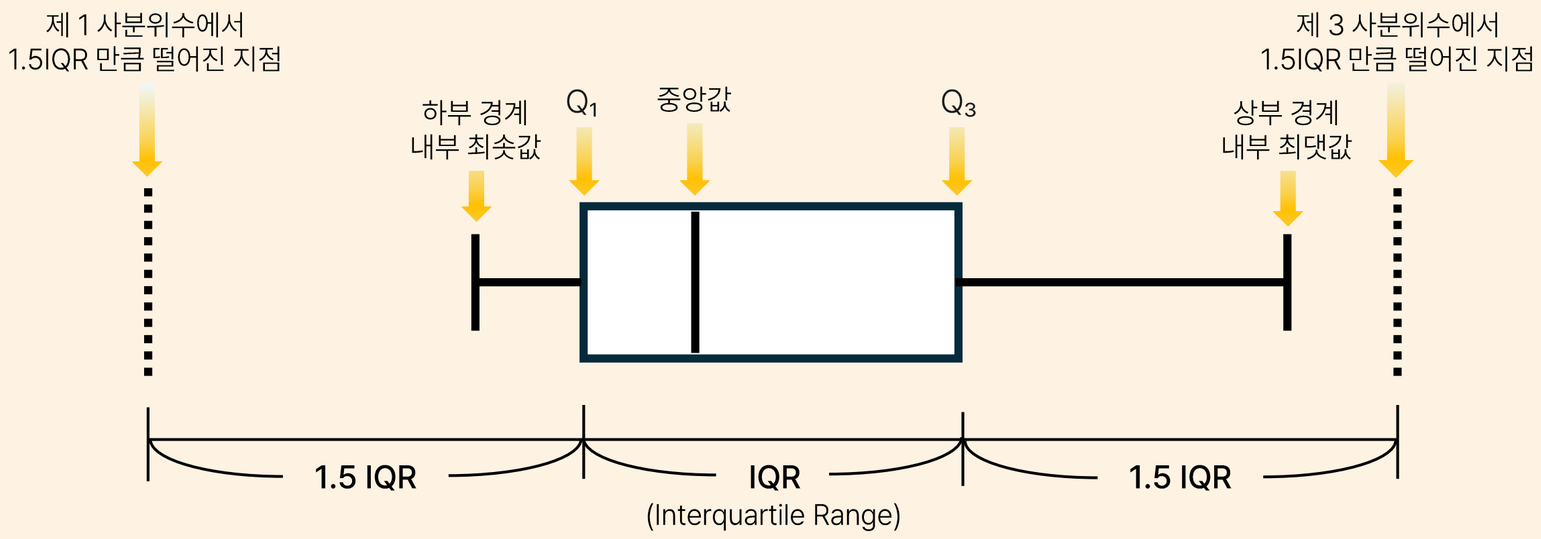

상자 그림 예시

- 상자 그림의 경우 가로 또는 세로로 표현하며 2개 이상의 그룹에 대한 그래프는 다음과 같음

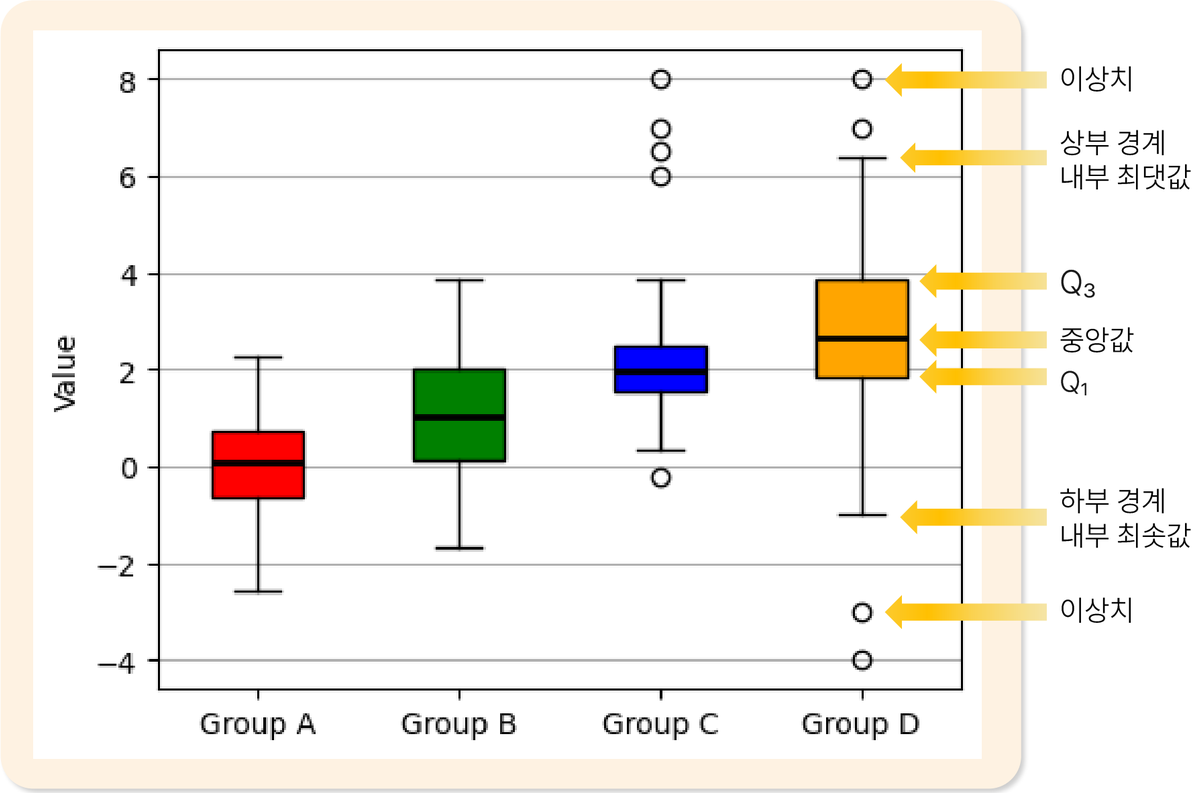

6 이변량 그래프

개요

- **산점도(Scatter plot)** : 두 수치형 변수의 교차지점을 점을 사용하여 직교 좌표계에 표기한 그래프
- **선 그래프(Line chart)** : 산점도에서 점과 점을 차례대로 선분으로 이은 그래프
- **복합 막대그래프(Grouped bar chart)** : 주 범주 막대 영역에 부 범주형 변수의 범주를 나란히 표기한 막대 그래프
- **누적 막대그래프(Stacked bar chart)** : 주 범주 막대 내부에 부 범주형 변수의 범주를 표기한 막대 그래프

6 이변량 그래프

산점도

- 두 수치형 변수 간의 관계를 시각화하는 가장 기본적인 방법
- 모든 데이터를 점으로 표기하기에 데이터가 많을 경우 점이 겹칠 수 있음
- 이상치, 선형 관계, 군집 등 다양한 패턴 관찰 가능
- 특정 축에 연속적인 의미를 부여하거나 시계열 속성이 있는 경우 선그래프 권장

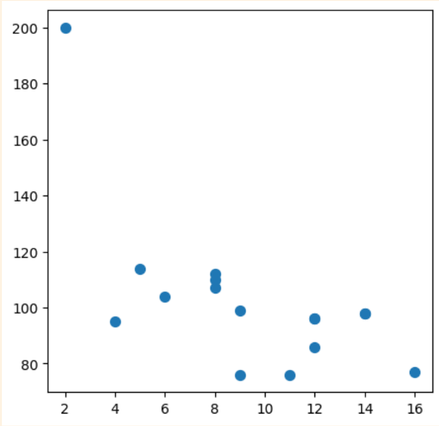

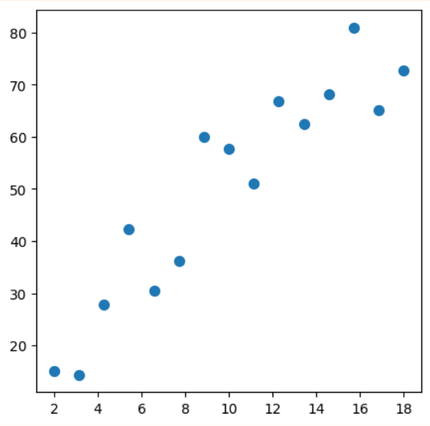

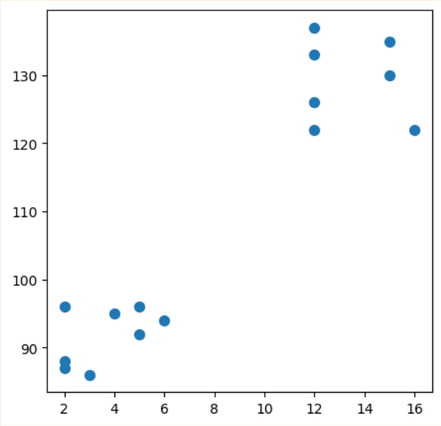

6 이변량 그래프

선 그래프

- 연속된 시점에서의 데이터 변화를 선으로 연결하여 나타낸 그래프
- x축은 연속적인 수치형 변수를 위치시키며 주로 시간 변수가 위치
- 시계열적 추세, 변화율 파악, 주기성 등을 탐지하는데 활용

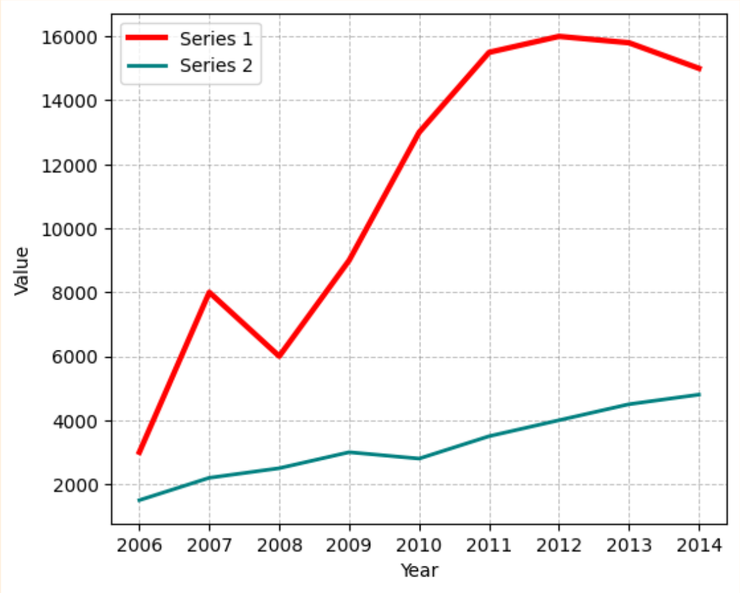

6 이변량 그래프

복합 막대그래프

- 각 주범주에 대해 부범주별로 막대를 나란히 배치한 그래프
- 범주 간 직접 비교를 통한 각 그룹 내에서의 차이를 명확하게 확인 가능

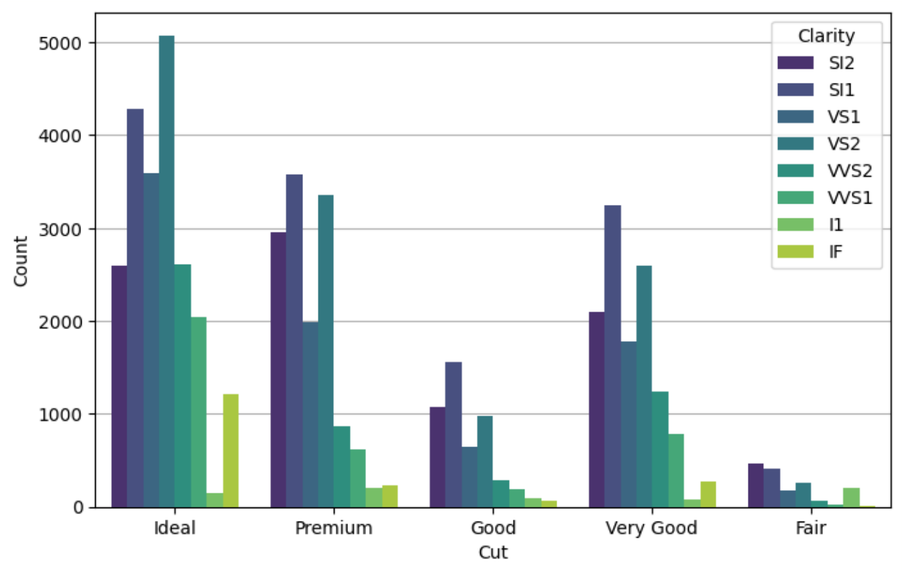

6 이변량 그래프

누적 막대그래프

- 각 주범주에 대해 부범주를 누적하여 표시한 그래프
- 주 범주별 합계와 각 부범주의 기여도 파악 가능

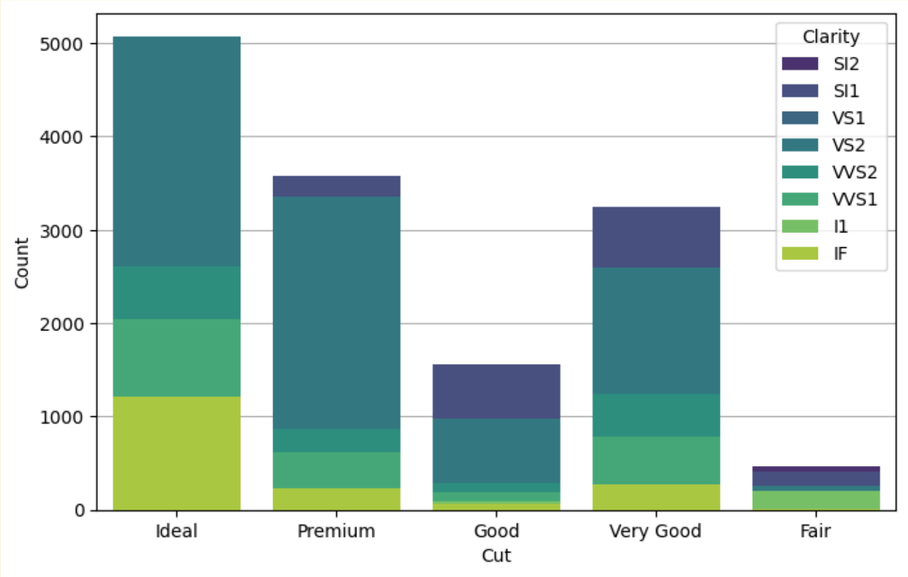

7 문제 풀이

Q1. 도수분포표의 상대도수에 대한 설명으로 옳지 않은 것은?

1. 전체 관측값에 대한 각 구간의 도수 비율을 나타낸다.
2. 모든 상대도수의 합은 항상 1이 된다.
3. 상대도수는 0 이상 1 이하의 값을 가진다.
4. 상대도수는 절대도수보다 항상 작은 값을 가진다.

7 문제 풀이

Q1. 도수분포표의 상대도수에 대한 설명으로 옳지 않은 것은?

1. 전체 관측값에 대한 각 구간의 도수 비율을 나타낸다.
2. 모든 상대도수의 합은 항상 1이 된다.
3. 상대도수는 0 이상 1 이하의 값을 가진다.
4. 상대도수는 절대도수보다 항상 작은 값을 가진다.

해설

일반적으로 상대도수는 1 미만이나, 절대도수가 1이고 전체 관측값이 1인 경우 상대도수는 1이 될 수 있다.

7 문제 풀이

Q2. 어떤 연속형 데이터의 최솟값이 15, 최댓값이 85이고, 계급의 개수를 7개로 설정하려고 한다. 이때 계급폭은?

1. 10
2. 12
3. 14
4. 16

7 문제 풀이

Q2. 어떤 연속형 데이터의 최솟값이 15, 최댓값이 85이고, 계급의 개수를 7개로 설정하려고 한다. 이때 계급폭은?

1. 10
2. 12
3. 14
4. 16

해설

계급폭 = (최댓값 - 최솟값) ÷ 계급의 개수 = (85 - 15) ÷ 7 = 70 ÷ 7 = 10

7 문제 풀이

Q3. 원그래프에서 어떤 범주의 도수가 전체의 25%를 차지한다면, 이 범주에 해당하는 중심각의 크기는?

1. 45°
2. 60°
3. 90°
4. 120°

7 문제 풀이

Q3. 원그래프에서 어떤 범주의 도수가 전체의 25%를 차지한다면, 이 범주에 해당하는 중심각의 크기는?

1. 45°
2. 60°
3. 90°
4. 120°

해설

중심각 = (해당 범주의 비율) × 360° = 0.25 × 360° = 90°

7 문제 풀이

Q4. 데이터 {2, 4, 6, 8, 10, 12, 14, 16, 18}로 그린 상자그림으로 판단되는 것은 무엇인가?

1. A
2. B
3. C
4. D

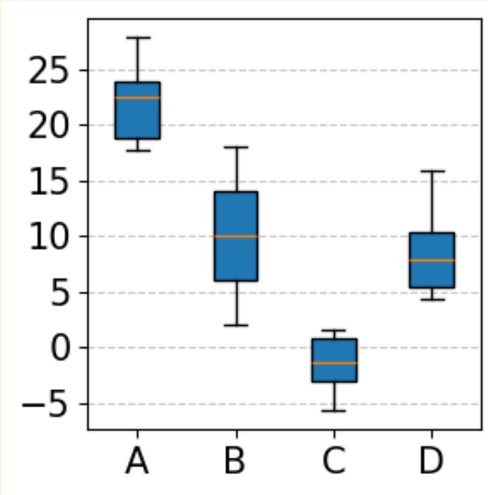

7 문제 풀이

Q4. 데이터 {2, 4, 6, 8, 10, 12, 14, 16, 18}로 그린 상자그림으로 판단되는 것은 무엇인가?

1. A
2. B
3. C
4. D

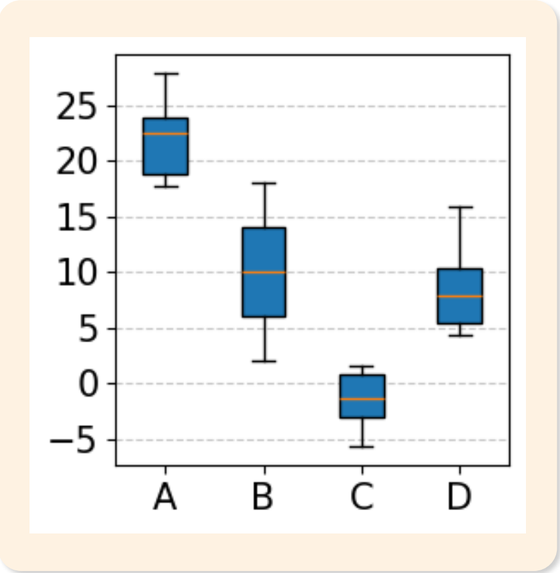

해설

제 1 사분위수가 6, 중앙값 10, 제 3 사분위수가 14로 B 상자그림이 정답이다.

7 문제 풀이

Q5. 누적 막대그래프의 특징으로 옳지 않은 것은?

1. 각 주범주에 대해 부범주를 누적하여 표시한다.
2. 전체 합계 정보 파악이 용이하다.
3. 각 부분의 기여도를 파악하기 용이하다.
4. 중간 범주의 변화를 정확히 파악하기 쉽다.

7 문제 풀이

Q5. 누적 막대그래프의 특징으로 옳지 않은 것은?

1. 각 주범주에 대해 부범주를 누적하여 표시한다.
2. 전체 합계 정보 파악이 용이하다.
3. 각 부분의 기여도를 파악하기 용이하다.
4. 중간 범주의 변화를 정확히 파악하기 쉽다.

해설

누적 막대그래프의 중간 범주는 위아래 범주의 영향을 받아 변화량을 직관적으로 파악하기 어렵다.