Data Science

Level 2

08. 추론 통계

1 추론 통계 개요

추론 통계학(Inferential Statistics)의 정의

- 표본으로부터 모집단의 특성을 추정하거나 가설을 검정하는 통계학 분야

추론 통계학의 필요성

- 모집단 전체 조사는 비용, 시간, 물리적으로 어려움
- 표본 결과를 바탕으로 모집단에 대한 일반적 결론 도출의 필요성
- 불확실성 하에서 합리적 의사결정을 위한 통계적 근거 제공

1 추론 통계 개요

기술 통계학의 한계

- **일반화 불가** : 표본 데이터만으로는 모집단에 대한 일반적 결론을 도출할 수 없음
- **불확실성의 무시** : 표본 변동에 따른 불확실성을 고려하지 않음
- **예측의 한계** : 미래 현상에 대한 예측이나 의사결정 지원의 한계

1 추론 통계 개요

추론 통계학의 역할

- 추정(estimation) : 표본 정보를 이용하여 모집단 모수를 추정
- 가설검정(hypothesis testing) : 모집단에 대한 가설의 참/거짓을 판단
- 예측(prediction) : 통계 모델을 바탕으로 미래 현상 예측

2 추정

추정(Estimation)의 개념

- 표본 정보를 이용하여 모집단의 미지 모수에 대한 정보를 제공하는 통계적 절차

추정의 종류

- **점추정(point estimation)** : 모수를 하나의 값으로 추정
- **구간추정(interval estimation)** : 모수가 포함될 것으로 예상되는 구간을 제시

추정의 목적

- 모집단 모수의 값을 근사적으로 산출
- 모수에 대한 불확실성을 정량화
- 의사결정을 위한 정보 제공

표본변동(Sampling Variation)

- 동일한 모집단에서 다른 표본을 추출할 때마다 통계량의 값이 달라지는 현상
- 표본변동의 원인 : 확률적 표본추출 과정, 모집단의 이질성, 표본크기의 한계
- 표본변동의 영향 : 추정량의 정확도, 신뢰구간 폭

3 중심극한정리

중심극한정리(CLT, Central Limit Theorem) 정의

- 어떤 분포를 따르는 모집단이라도, 표본의 크기가 충분히 크면
  그 표본평균의 분포는 근사적으로 정규분포를 따름

중심극한정리의 조건

- 표본은 서로 독립이고 동일한 분포에서 추출되어야 함
  ※ i.i.d : independent and identically distributed
- 일반적으로 $n \geq 30$ 이면 근사적으로 CLT 적용 가능

3 중심극한정리

중심극한정리의 시각적 이해

- 표본 크기가 커질수록 분포가 중심(평균) 주변으로 좁고 정규분포처럼 되는 경향이 뚜렷하게 보임

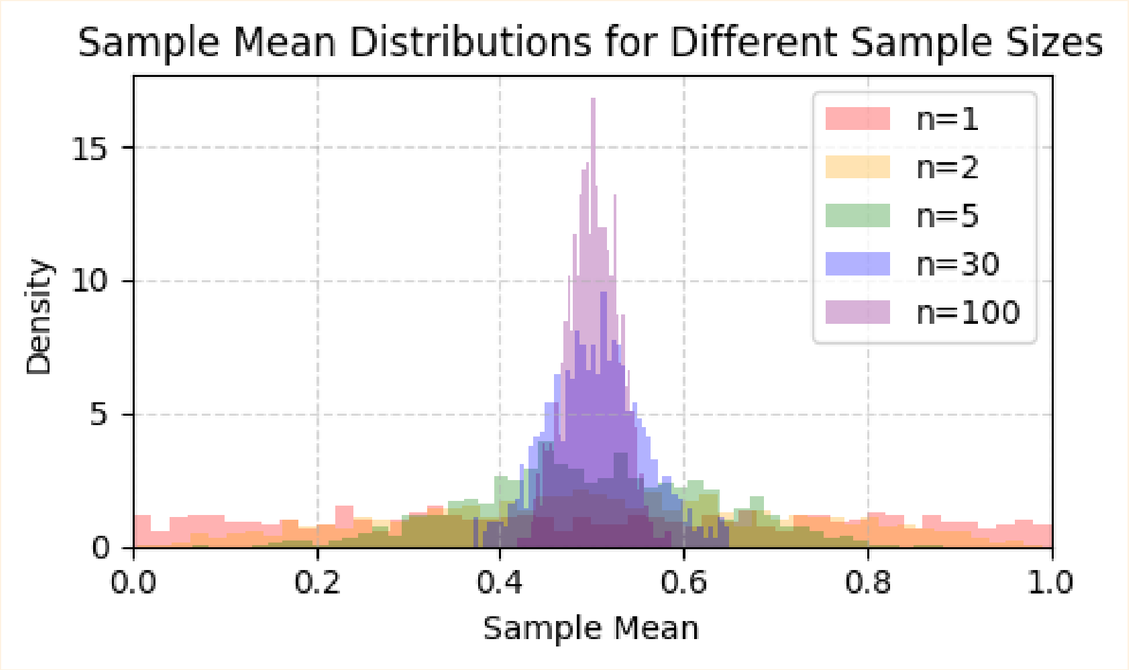

4 표본 분포

표본 분포(Sampling Distribution)의 개념

- 동일한 모집단에서 같은 크기의 표본을 무수히 많이 뽑았을 때
  각 표본에서 계산한 통계량들이 이루는 분포

표본 분포의 특징

- 통계량은 확률 변수이므로 특정한 확률 분포를 따름
- 표본크기와 모집단의 특성에 따라 분포가 결정됨
- 표본분포의 표준편차인 표준오차(standard error)는 통계량들의 산포를 나타냄

4 표본 분포

표준오차(SE, Standard Error)의 개념

- 통계량의 표준편차를 의미하며, 추정의 정확도를 나타내는 중요한 지표

주요 통계량의 표준오차

- 표본평균의 표준오차: $SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$
- 표본비율의 표준오차: $SE(\hat{p}) = \sigma^2 \sqrt{\frac{2}{n-1}}$

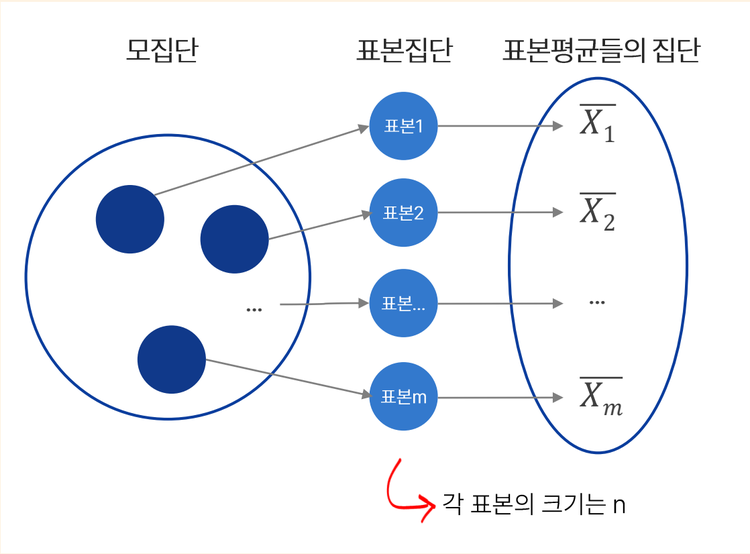

5 점추정

점추정(Point Estimation)의 정의

- 점추정은 표본 정보를 이용하여 모집단의 미지 모수를 하나의 값(점)으로 추정하는 방법

점추정의 특징

- 추정한 모수를 하나의 숫자로 표현
- 추정의 불확실성을 직접적으로 나타내지 않음
- 표본이 달라지면 추정값도 변함

5 점추정

관련 용어

- **추정량(estimator)** : 모수 θ를 추정하기 위해 표본 $X_1, X_2, \ldots, X_n$ 의 함수로 정의된 통계량

$$\hat{\theta} = \hat{\theta}(X_1, X_2, \ldots, X_n)$$

- **추정값(estimate)** : 특정 표본에 대해 추정량을 계산한 구체적인 수치

$$\hat{\theta}_{obs} = \hat{\theta}(x_1, x_2, \ldots, x_n)$$

5 점추정

좋은 점 추정량의 조건

- 불편성(unbiasedness) : 추정량이 모수와 같아야(최소가 되어야) 함
- 일치성(consistency) : 표본 크기가 모집단의 크기에 가까울 수록 오차가 줄어듦
- 유효성(efficiency) : 모수에 대한 추정량의 분산이 작을 수록 좋음
- 충분성(sufficiency) : 표본은 모집단을 대표할 수 있어야 함

6 구간 추정

구간추정(Interval Estimation)의 정의

- 표본 정보를 이용하여 모집단의 미지 모수가 포함될 것으로 예상되는 구간을 제시하는 추정 방법

점추정의 한계

- 추정값이 얼마나 정확한지 알 수 없음
- 표본변동으로 인한 불확실성을 고려하지 않음
- 추정값만으로는 위험도를 평가하기 어려움
- 추정 결과에 대한 확신 정도를 알 수 없음

6 구간 추정

신뢰구간(CI, Confidence Interval)

- 신뢰구간은 어떤 모수를 추정할 때,
  추정값 주위에 오차 범위를 설정하여 모수가 포함될 것이라 기대되는 구간

신뢰구간의 구성요소

- **추정량** : 표본에서 계산한 값
- **신뢰수준** : 신뢰구간이 모수를 포함할 확률
- **표준오차** : 표본통계량의 변동성 측정치
- **오차한계(margin of error)** : 추정량 주위에 얼마나 오차를 허용할지를 수치화한 값

6 구간 추정

모평균의 신뢰구간

- 정규분포 기반의 신뢰구간(모분산을 알 때)

$$CI = \bar{X} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

- 정규분포의 임계값(z, critical value)
  : 신뢰수준에 따라 결정되는 표준 정규 분포 상의 특정 값

신뢰수준	유의수준(z)	$z_{\alpha/2}$
90%	0.10	1.645
95%	0.05	1.960
99%	0.01	2.576

7 문제 풀이

Q1. 추론통계학에 대한 설명으로 가장 적절하지 않은 것은?

1. 표본으로부터 모집단의 특성을 추정하거나 가설을 검정하는 통계학 분야이다.
2. 모집단 전체 조사가 비용, 시간, 물리적으로 어려울 때 필요하다.
3. 수집된 데이터의 특성과 분포를 파악하여 데이터를 요약하는 것이 주목적이다.
4. 불확실성 하에서 합리적 의사결정을 위한 통계적 근거를 제공한다.

7 문제 풀이

Q1. 추론통계학에 대한 설명으로 가장 적절하지 않은 것은?

1. 표본으로부터 모집단의 특성을 추정하거나 가설을 검정하는 통계학 분야이다.
2. 모집단 전체 조사가 비용, 시간, 물리적으로 어려울 때 필요하다.
3. 수집된 데이터의 특성과 분포를 파악하여 데이터를 요약하는 것이 주목적이다.
4. 불확실성 하에서 합리적 의사결정을 위한 통계적 근거를 제공한다.

해설

3번은 기술통계학의 목적에 해당하고, 추론통계학은 표본으로부터 모집단에 대한 추론을 수행하는 것이 주목적

7 문제 풀이

Q2. 중심극한정리에 대한 설명으로 옳은 것은?

1. 모집단이 정규분포를 따를 때만 적용할 수 있다.
2. 표본의 크기가 충분히 크면 표본평균의 분포는 근사적으로 정규분포를 따른다.
3. 표본은 서로 독립일 필요가 없으며 동일한 분포에서 추출되지 않아도 된다.
4. 일반적으로 표본 크기가 10 이상이면 중심극한정리를 적용할 수 있다.

7 문제 풀이

Q2. 중심극한정리에 대한 설명으로 옳은 것은?

1. 모집단이 정규분포를 따를 때만 적용할 수 있다.
2. 표본의 크기가 충분히 크면 표본평균의 분포는 근사적으로 정규분포를 따른다.
3. 표본은 서로 독립일 필요가 없으며 동일한 분포에서 추출되지 않아도 된다.
4. 일반적으로 표본 크기가 10 이상이면 중심극한정리를 적용할 수 있다.

해설

중심극한정리는 어떤 분포를 따르는 모집단이라도
표본의 크기가 충분히 크면(일반적으로 $n \geq 30$)
표본평균의 분포가 근사적으로 정규분포를 따른다는 정리

7 문제 풀이

Q3. 표본분포(Sampling Distribution)의 표준편차인 표준오차(Standard Error)에 대한 설명으로 가장 적절한 것은?

1. 개별 관측값들의 산포 정도를 나타내는 지표이다.
2. 통계량들의 산포를 나타내며 추정의 정확도를 측정하는 중요한 지표이다.
3. 표본크기가 증가할수록 표준오차는 증가한다.
4. 모집단의 변동성과는 무관하게 결정된다.

7 문제 풀이

Q3. 표본분포(Sampling Distribution)의 표준편차인 표준오차(Standard Error)에 대한 설명으로 가장 적절한 것은?

1. 개별 관측값들의 산포 정도를 나타내는 지표이다.
2. 통계량들의 산포를 나타내며 추정의 정확도를 측정하는 중요한 지표이다.
3. 표본크기가 증가할수록 표준오차는 증가한다.
4. 모집단의 변동성과는 무관하게 결정된다.

해설

표준오차는 통계량들의 산포를 나타내며 추정의 정확도를 나타내는 중요한 지표이고, 표준오차가 작을수록 추정이 더 정확

7 문제 풀이

Q4. 점추정의 특징으로 옳지 않은 것은?

1. 추정한 모수를 하나의 숫자로 표현한다.
2. 표본이 달라지면 추정값도 변한다.
3. 모집단의 미지 모수를 단일값으로 추정하는 방법이다
4. 추정의 불확실성을 직접적으로 나타낸다.

7 문제 풀이

Q4. 점추정의 특징으로 옳지 않은 것은?

1. 추정한 모수를 하나의 숫자로 표현한다.
2. 표본이 달라지면 추정값도 변한다.
3. 모집단의 미지 모수를 단일값으로 추정하는 방법이다
4. 추정의 불확실성을 직접적으로 나타낸다.

해설

점추정은 추정의 불확실성을 직접적으로 나타내지 않음.
이는 점추정의 한계 중 하나이며, 이를 보완하기 위해 구간추정이 사용됨

7 문제 풀이

Q5. 어느 공장에서 생산된 제품의 무게를 조사하기 위해 36개의 표본을 추출했다. 표본평균이 50g, 모표준편차가 6g일 때, 모평균 무게에 대한 95% 신뢰구간은? (단, $z_{0.025} = 1.96$)

1. [48.04, 51.96]
2. [49.02, 50.98]
3. [47.08, 52.92]
4. [46.12, 53.88]

7 문제 풀이

Q5. 어느 공장에서 생산된 제품의 무게를 조사하기 위해 36개의 표본을 추출했다. 표본평균이 50g, 모표준편차가 6g일 때, 모평균 무게에 대한 95% 신뢰구간은? (단, $z_{0.025} = 1.96$)

1. [48.04, 51.96]
2. [49.02, 50.98]
3. [47.08, 52.92]
4. [46.12, 53.88]

해설

$$50 \pm 1.96 \times \frac{6}{\sqrt{36}} = 50 \pm 1.96 \times 1 = 50 \pm 1.96 = [48.04, 51.96]$$