Data Science

Level 2

10. 데이터처리 2

1 수치형 데이터 변환 – 일반

개요

- **정규성 확보** : 정규분포를 가정하는 통계기법 실시 전 데이터 전처리
- **왜도(skewness) 보정** : 산출되는 기술 통계량의 왜곡방지
- **이상치의 영향 완화** : 양의 왜도를 낮추는 로그 변환 등은 이상치의 영향을 줄여줌

1 수치형 데이터 변환 – 일반

지수 변환

- 지수함수를 활용하여 지나치게 왜도가 큰 데이터를 변환
- 왜도가 양수인 경우 1 미만의 지수(ex. 0.5), 왜도가 음수인 경우 1 초과의 지수(ex. 2) 권장
- 지수가 -1의 경우 또한 지수 변환이며 이를 역변환 이라고 함

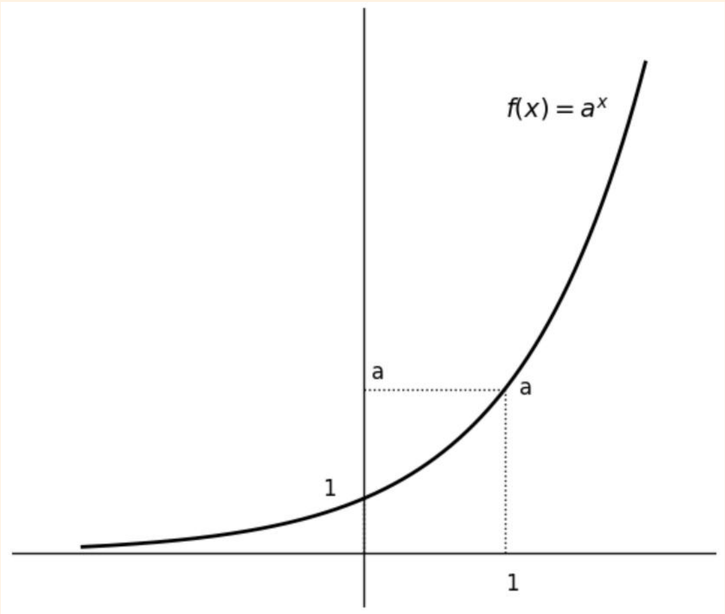

1 수치형 데이터 변환 – 일반

지수 변환 예시

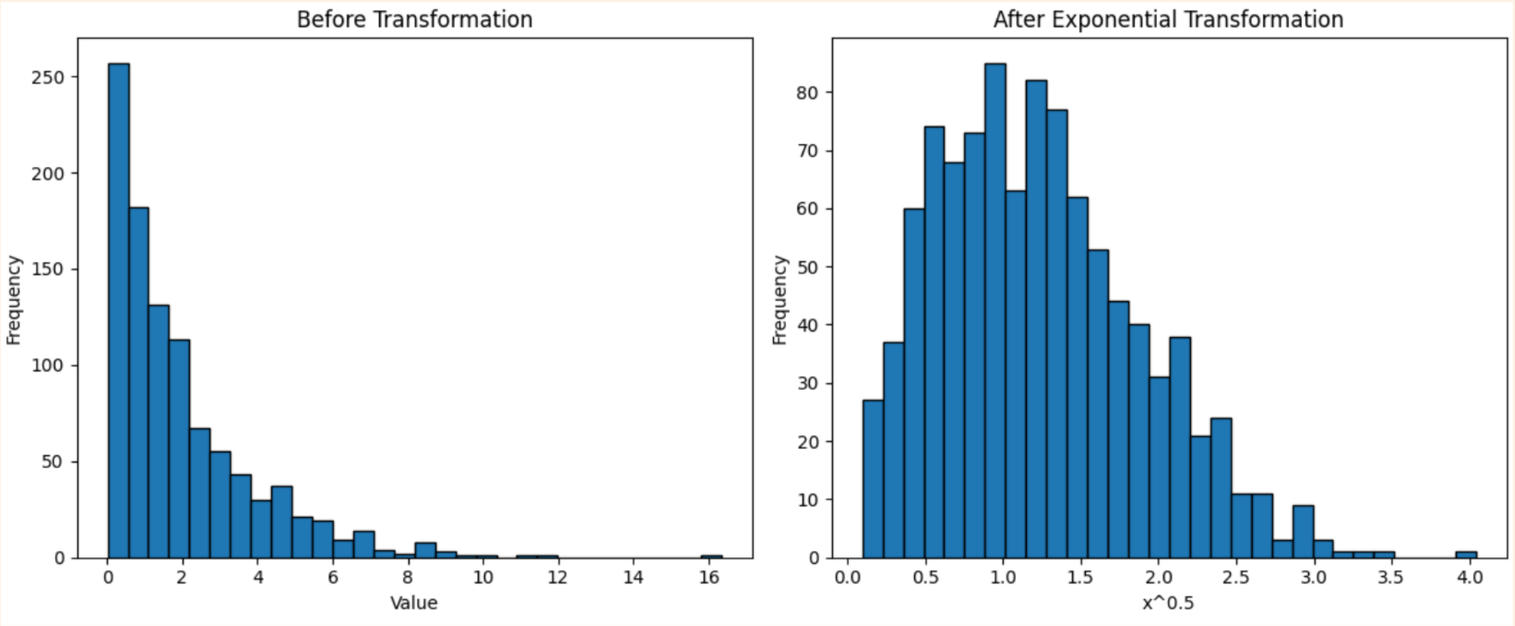

변환 전	변환 후
0.001	0.03
0.01	0.10
0.1	0.32
1	1.00
2	1.41
3	1.73
4	2.00

1 수치형 데이터 변환 – 일반

로그 변환

- 0 초과의 수치 데이터를 대상으로 실시하며 양의 왜도를 줄이는 데 효과적
- 큰 값은 줄이고 작은 값은 상대적으로 확대(1 기준)
- 양의 왜도 또는 분산 감소 가능

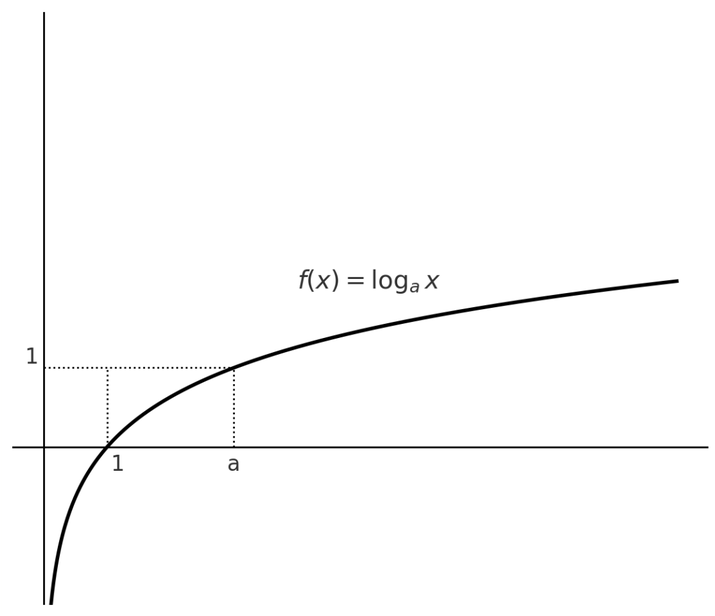

1 수치형 데이터 변환 – 일반

로그 변환 예시(상용로그)

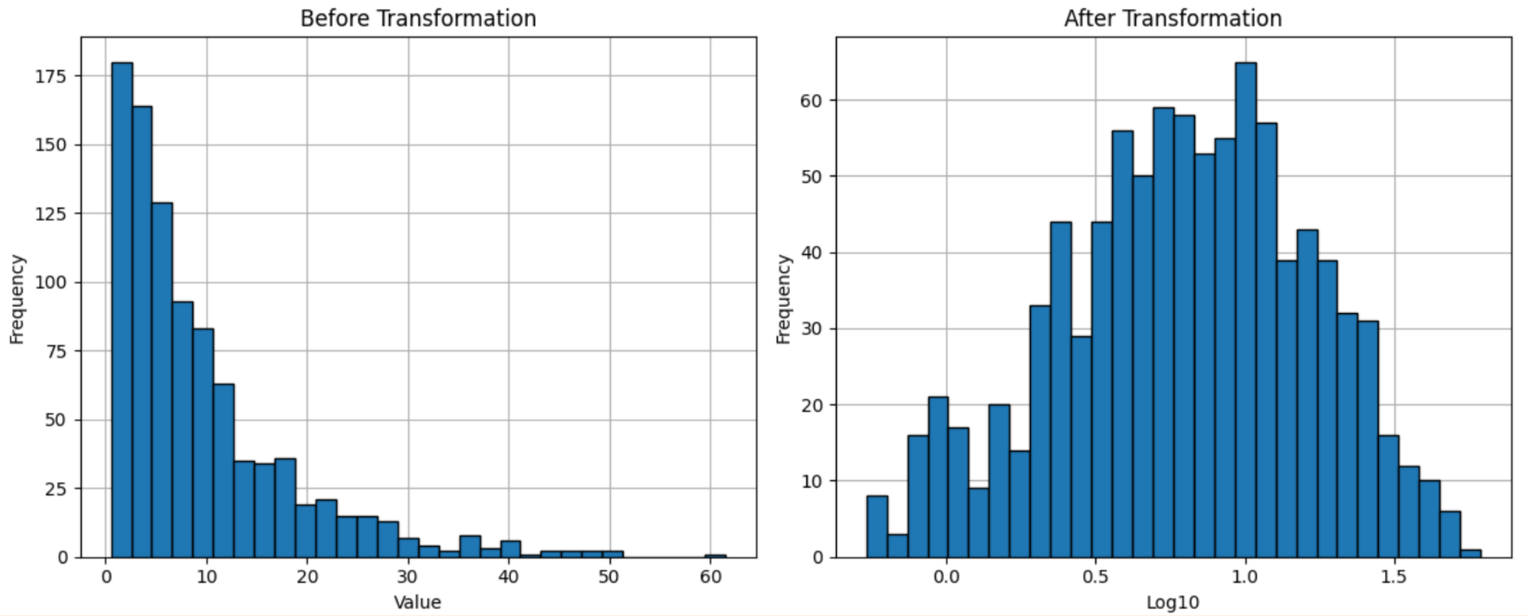

변환 전	변환 후
0.001	-3
0.01	-2
0.1	-1
1	0
10	1
50	1.69897
100	2

2 수치형 데이터 변환 – 정규화

개요

- 서로 다른 척도(scale)를 가진 수치형 데이터를 일정한 기준에 따라 변환하는 과정
- 비교 가능성 확보 : 단위나 범위가 다른 변수들을 동일 선상에서 비교하기 위해 필요
- 단위의 영향 제거 : 원래의 단위(예 : cm, kg, 원 등)에 따른 영향 없이 본질적 분포를 비교 가능

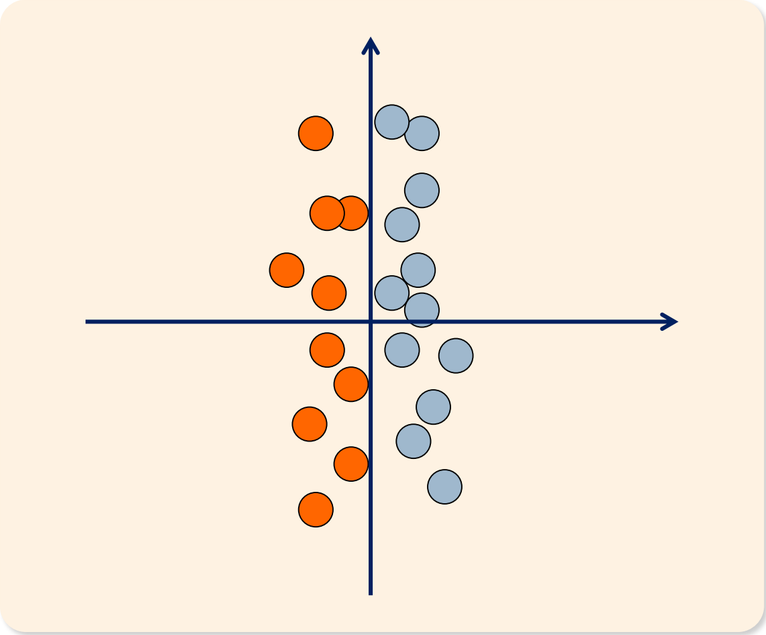

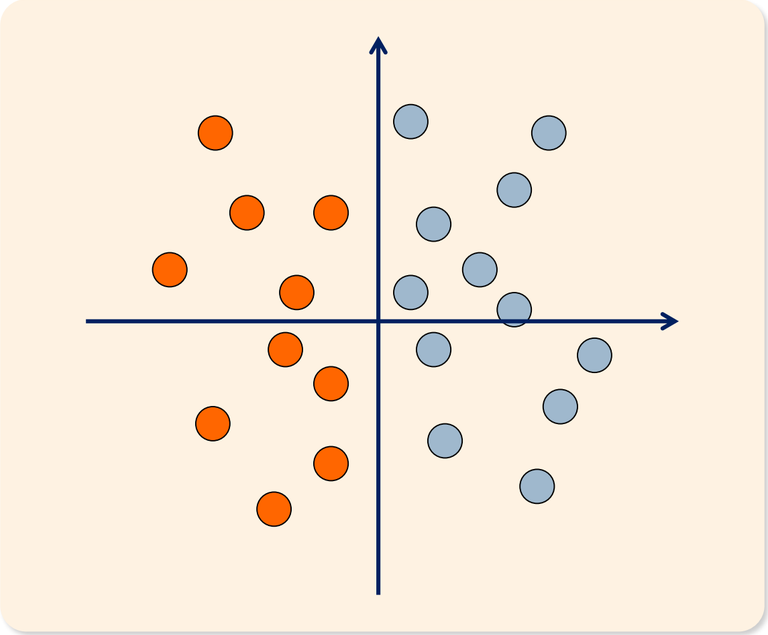

2 수치형 데이터 변환 – 정규화

최소-최대 정규화(Min-Max Normalization)

- 데이터의 최소값을 0, 최대값을 1로 변환
- 변환 후에도 기존의 분포를 유지하며 직관적
- 이상치의 영향을 크게 받음(이상치가 아닌 값들이 상대적으로 쏠릴 수 있음)

$$N_Q = \frac{x - \min(x)}{\max(x) - \min(x)}$$

2 수치형 데이터 변환 – 정규화

최소-최대 정규화 변환 예시

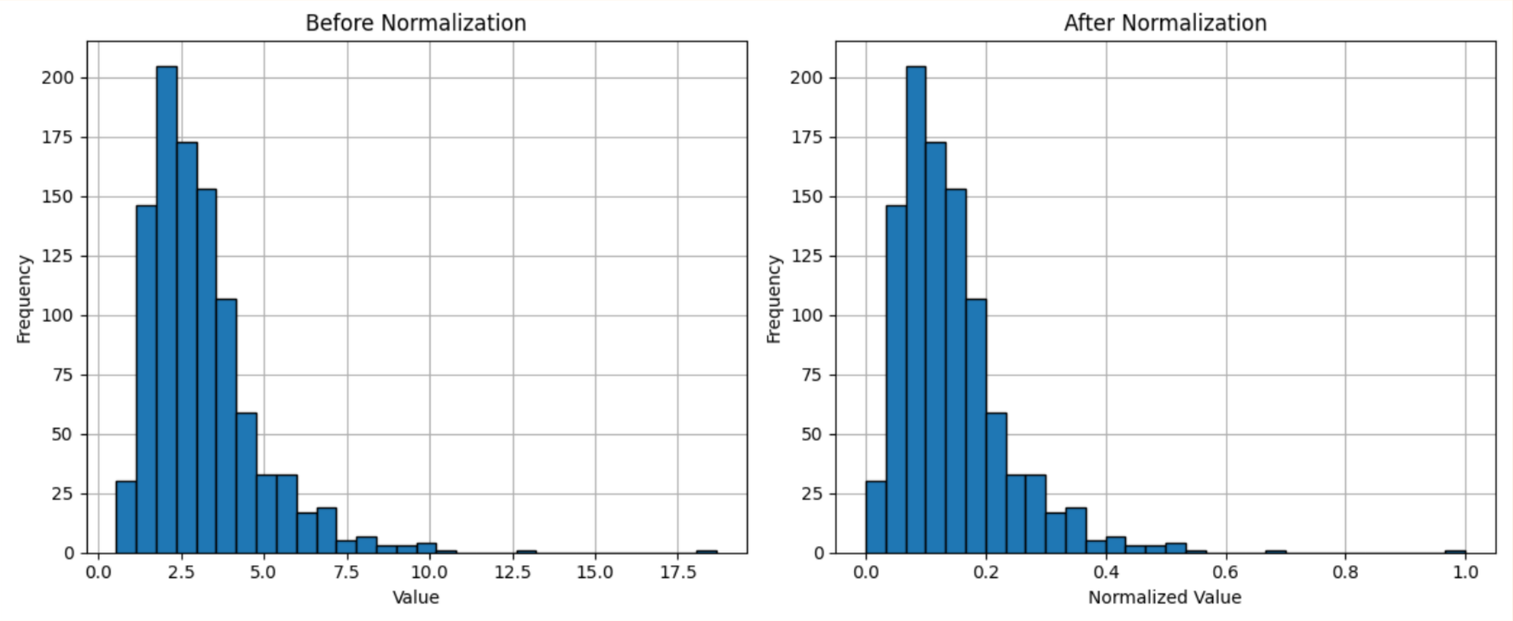

변환 전	변환 후
0.001	0
0.01	0.00225
0.1	0.02476
1	0.24981
2	0.49987
3	0.74994
4	1

2 수치형 데이터 변환 – 정규화

표준화(Standardization)

- 데이터의 평균을 0, 표준편차를 1로 변환
- 데이터 분포의 중심과 퍼짐 정도를 고려하는 방식
- 정규분포를 변환할 경우 표준 정규분포가 됨

$$z = \frac{x - \mu}{\sigma}$$

μ: 평균, σ: 표준편차

2 수치형 데이터 변환 – 정규화

표준화 변환 예시

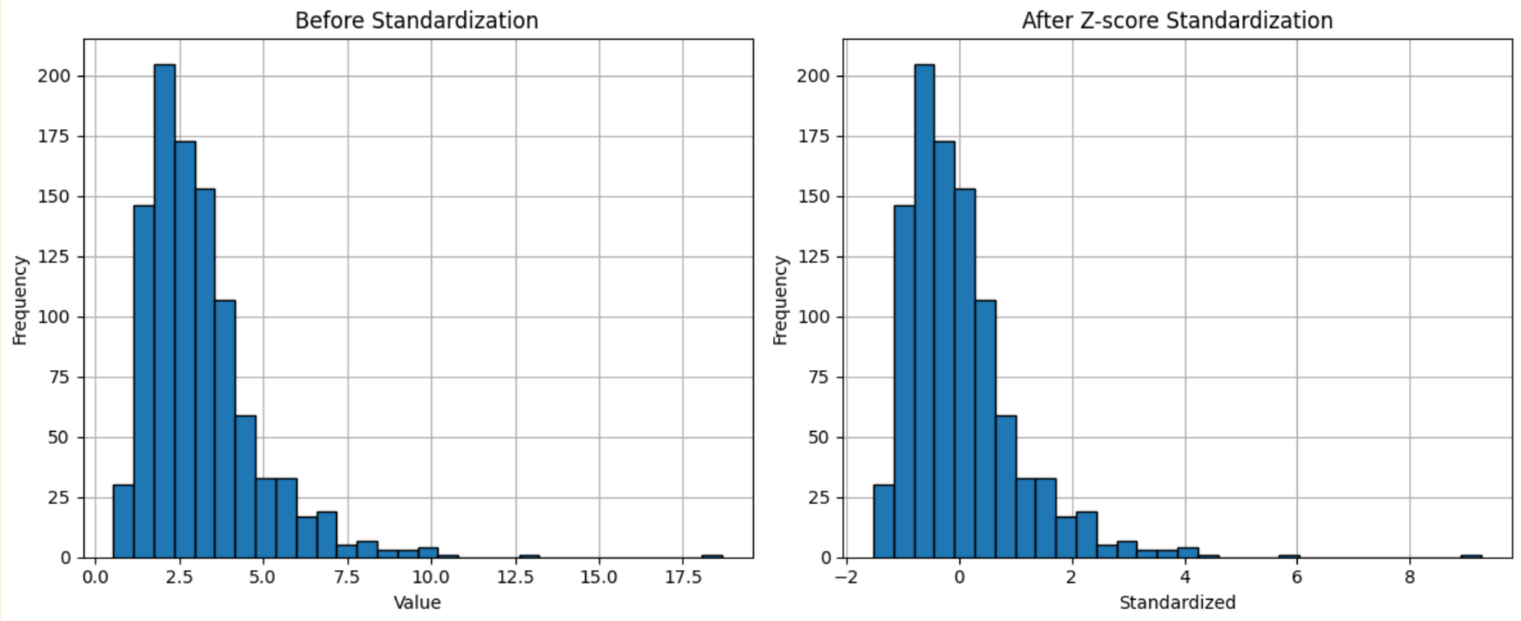

변환 전	변환 후
0.001	-0.973
0.01	-0.9669
0.1	-0.9063
1	-0.2996
2	0.3745
3	1.04858
4	1.72266

3 범주형 데이터 변환

개요

- 문자나 범주(category)로 구성된 데이터를 분석 또는 계산에 적합한 수치형 형식으로 바꾸는 과정
- 대표적으로 One Hot Encoding, Label Encoding, Ordinal Encoding이 있음
- 수치형으로 변환된 범주형 데이터를 사칙연산을 수행하지 않도록 주의

3 범주형 데이터 변환

원핫 인코딩(OHE, One Hot Encoding)

- 하나의 명목형 변수를 해당 변수의 범주 개수만큼의 새로운 가변수(dummy variable)로 변환

  ※더미(dummy) 코딩이라고도 함

- 생성되는 가변수는 0과 1의 값을 가지며 특정 범주 존재 여부를 나타냄(존재 : 1)
- 가변수는 1개 제외하여도 모든 정보를 표현가능하기 때문에 특정 가변수를 분석에서 제외 가능

  ※범주형 변수 당 가변수 1개 제외 가능하며 제외하는 가변수는 분석가의 주관에 따라 결정

Color
E
G
H
H
G

→

Color_E	Color_G	Color_H
1	0	0
0	1	0
0	0	1
0	0	1
0	1	0

또는

Color_E	Color_G	
1	0	
0	1	
0	0	← H
0	0	← H
0	1	

3 범주형 데이터 변환

라벨 인코딩(Label Encoding)

- n개의 범주형 데이터를 0부터 n-1까지의 연속적 수치 데이터로 치환하는 것

변환 전	변환 후
A	0
B	1
C	2
D	3
E	4
F	5
G	6

3 범주형 데이터 변환

순서형 데이터의 변환

- **순서 정보 보존** : 범주 간 상대적 위치(서열)를 수치로 표현
- **계산 가능성 확보** : 통계 분석 및 수치 연산이 가능하도록 정수(또는 실수) 변환
- **간결한 표현** : One-Hot보다 더 낮은 차원으로 데이터 표현 가능

변환 전	변환 후
1	7
50	3
200	1
100	2
40	4
15	6
25	5

4 문제 풀이

Q1. 지수 변환에 대한 설명으로 옳지 않은 것은?

1. 지수함수를 활용하여 지나치게 왜도가 큰 데이터를 변환한다.
2. 왜도가 양수인 경우 지수 값을 0.5로 하여 변환할 수 있다.
3. 왜도가 음수인 경우 1 초과의 지수를 권장한다.
4. 지수가 -1인 경우는 지수 변환이 아니며 역변환이라고 한다.

4 문제 풀이

Q1. 지수 변환에 대한 설명으로 옳지 않은 것은?

1. 지수함수를 활용하여 지나치게 왜도가 큰 데이터를 변환한다.
2. 왜도가 양수인 경우 지수 값을 0.5로 하여 변환할 수 있다.
3. 왜도가 음수인 경우 1 초과의 지수를 권장한다.
4. 지수가 -1인 경우는 지수 변환이 아니며 역변환이라고 한다.

해설

지수가 -1인 경우 또한 지수 변환이며 이를 역변환이라고 한다.

4 문제 풀이

Q2. 다음 중 로그 변환의 특징으로 옳은 것을 모두 고른 것은?

ㄱ. 0 초과의 데이터만 변환 가능
ㄴ. 양의 왜도 감소
ㄷ. 분산의 증가
ㄹ. 이상치 영향 완화

1. ㄱ, ㄴ
2. ㄱ, ㄴ, ㄹ
3. ㄱ, ㄴ, ㄷ
4. ㄱ, ㄴ, ㄷ, ㄹ

4 문제 풀이

Q2. 다음 중 로그 변환의 특징으로 옳은 것을 모두 고른 것은?

ㄱ. 0 초과의 데이터만 변환 가능
ㄴ. 양의 왜도 감소
ㄷ. 분산의 증가
ㄹ. 이상치 영향 완화

1. ㄱ, ㄴ
2. ㄱ, ㄴ, ㄹ
3. ㄱ, ㄴ, ㄷ
4. ㄱ, ㄴ, ㄷ, ㄹ

해설

1 이상의 데이터에 대해 로그 변환을 실시할 경우
분산이 감소하는 것은 맞으나, 0.001, 0.002 같은
매우 작은 숫자의 경우 오히려 분산이 증가한다.

4 문제 풀이

Q3. 다음 데이터를 최소-최대 정규화할 때, 값 6이 변환되는 결과는?

데이터 : [1, 3, 4, 6, 8, 9, 10]

1. 0.444
2. 0.556
3. 0.600
4. 0.667

4 문제 풀이

Q3. 다음 데이터를 최소-최대 정규화할 때, 값 6이 변환되는 결과는?

데이터 : [1, 3, 4, 6, 8, 9, 10]

1. 0.444
2. 0.556
3. 0.600
4. 0.667

해설

최솟값, 최댓값은 각각 1, 9로 6에서 1을 빼고
9를 나눌 경우 그 결괏값은 0.556이 된다.

4 문제 풀이

Q4. 범주형 데이터 변환에 대한 설명으로 옳은 것은?

1. 원핫 인코딩에서는 모든 가변수를 분석에 포함해야 한다.
2. 라벨 인코딩은 n개의 범주를 1부터 n까지의 수치로 변환한다.
3. 순서형 데이터 변환은 범주간 상대적 위치를 수치로 표현한다.
4. 수치형으로 변환된 범주형 데이터는 분석의 편의를 위해 사칙연산을 수행 해도 문제가 없다.

4 문제 풀이

Q4. 범주형 데이터 변환에 대한 설명으로 옳은 것은?

1. 원핫 인코딩에서는 모든 가변수를 분석에 포함해야 한다.
2. 라벨 인코딩은 n개의 범주를 1부터 n까지의 수치로 변환한다.
3. 순서형 데이터 변환은 범주간 상대적 위치를 수치로 표현한다.
4. 수치형으로 변환된 범주형 데이터는 분석의 편의를 위해 사칙연산을 수행 해도 문제가 없다.

해설

순서형 데이터를 변환하는 것은 해당 순서형 원소의 순위를 매기는 행위로, 이는 범주간 상대적 위치를 그에 대응하는 별도의 수치로 표현하는 것과 같다.

4 문제 풀이

Q5. 표준화(Standardization)에 대한 설명으로 옳다고 보기 어려운 것은?

1. 데이터의 평균을 0, 표준편차를 1로 변환한다.
2. 정규분포를 변환할 경우 표준정규분포가 된다.
3. 양의 왜도를 가진 데이터의 왜도를 효과적으로 줄여준다.
4. 평균과 표준편차를 사용하여 계산한다.

4 문제 풀이

Q5. 표준화(Standardization)에 대한 설명으로 옳다고 보기 어려운 것은?

1. 데이터의 평균을 0, 표준편차를 1로 변환한다.
2. 정규분포를 변환할 경우 표준정규분포가 된다.
3. 양의 왜도를 가진 데이터의 왜도를 효과적으로 줄여준다.
4. 평균과 표준편차를 사용하여 계산한다.

해설

표준화는 데이터의 중심(평균)과 퍼짐(표준편차)만 조정하고 데이터의 왜도는 변화시키지 않는다. 로그 변환, 지수 변환과 같은 변환 방법의 경우 양의 왜도를 줄이는 효과가 있다.