Data Science

Level 2

12. 머신러닝 개요1

용어 정리 1

- **모델** : 어떤 현상을 설명하기 위한 수식 또는 규칙
- **모델 튜닝** : 모델의 성능 향상이나 해석을 위해 취하는 일련의 조치
- **하이퍼파라미터(hyperparameter)** : 모델의 성능 또는 동작 원리에 큰 영향을 미치는 설정 값

<모델 튜닝 예시>

에어프라이어로 더 맛있는 호빵을 조리하기 위해
기존 조리법에서 조리 온도와 조리 시간을 조금씩 수정해보며
최상의 맛을 내는 조리법을 찾고자 함

평가 기준 모델 하이퍼파라미터

용어 정리 2

- 학습 데이터셋(Train dataset) : 모델의 학습에 사용되는 데이터셋
- 검증 데이터셋(Validation dataset) : 모델의 최종 평가 이전에 학습 상태를 점검하기 위해 사용되는 데이터셋
- 평가 데이터셋(Test dataset) : 모델의 최종 평가에 사용되는 데이터셋

1 머신러닝의 개념

개념 정리

- 기계학습이라고도 하며 컴퓨터가 학습할 수 있도록 하는 알고리즘과 기술을 개발하는 분야
- 추정 및 추론에 중점을 두는 통계와는 달리 주로 예측에 초점을 맞추고 있음
- 주어진 데이터 기반으로 학습을 하여 비교적 일반화된 수식 또는 규칙이 담긴 모델 생성 및 교정
- 생성한 모델은 각 알고리즘의 고유한 평가지표 또는 범용 평가지표를 활용하여 평가

2 머신러닝의 분류

머신러닝의 갈래

- **지도학습(Supervised Learning)** : 입력 데이터(input)와 정답(label)이 쌍으로 주어지는 데이터를 학습
- **비지도학습(Unsupervised Learning)** : 정답(label) 없이 입력 데이터만 사용하여, 데이터의 구조 또는 패턴 탐색
- **강화학습(Reinforcement Learning)** : 어떤 환경 안에서 정의된 에이전트가 보상을 최대로 하는 행동을 선택

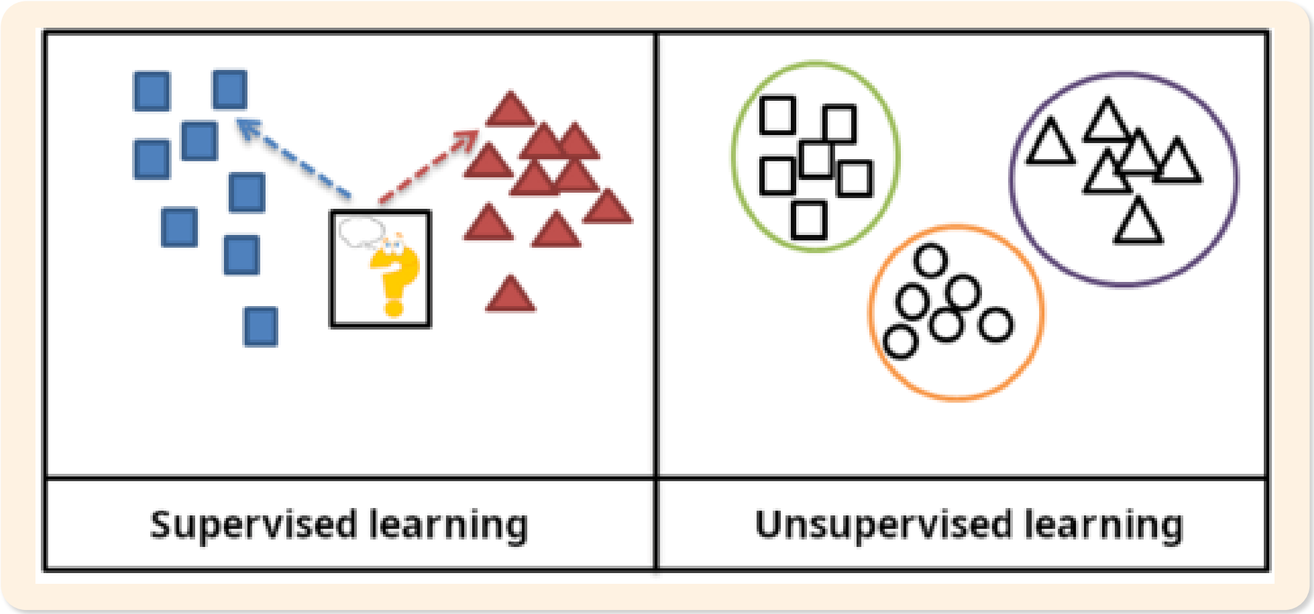

https://en.wikipedia.org/wiki/Supervised_learning

2 머신러닝의 분류

지도학습

- 입력 데이터와 출력 데이터의 관계를 분석하고 학습하여 그 내용을 모델로 만드는 것
- 학습에 사용되는 정답 데이터의 유형에 따라(수치/분류) 회귀모델과 분류모델로 나뉨
- 입력 데이터는 문제, 출력 데이터는 답에 비유할 수 있으며 이를 활용하여 성능 평가 가능
- 지도학습 기법으로 선형회귀 분석, 의사결정나무 등 다양한 알고리즘이 있음
- 주로 예측 분석에 활용됨

2 머신러닝의 분류

비지도학습

- 지도학습과 다르게 문제에 해당하는 입력 데이터만 있으며 해당 데이터간 관계 또는 규칙 등 분석
- 정답에 해당하는 label 데이터가 없어 성능 평가가 어렵고 그 해석이 주관적인 경우가 많음
- 대표적인 비지도학습 알고리즘으로 데이터를 묶는 군집분석이 있음
- 주로 패턴 인식에 사용되며 추천 시스템 등 다양한 영역에 활용됨

3 종속변수와 독립변수

Case Study

- "어떤 사람이 오늘 저녁에 치킨을 주문 할지 말지 고민하는 상황"을 지도학습의 개념으로 접근
- 치킨을 주문 할지 말지 → 치킨 주문 여부 → 분류 모델의 종속변수
- 치킨 주문에 영향을 주는 요인 → 모델의 독립변수

  ※ 당일 치킨 광고 노출 횟수, 마지막 치킨 주문으로부터 경과일 등
- 필요 데이터 : 일별 치킨 주문 여부 및 치킨 주문에 영향을 주는 데이터

3 종속변수와 독립변수

종속변수(Dependent Variable)

- 결과변수(outcome variable)로도 불리며 연구에서 측정하고자 하는 결과를 담고 있고 보통 "Y"로 표기
- 지도학습 모델의 학습에 사용되는 데이터에는 종속변수가 반드시 필요
- 종속변수의 데이터 유형이 수치형/연속형인 경우 지도학습의 회귀모델을 사용
- 종속변수의 데이터 유형이 범주형인 경우 지도학습의 분류모델을 사용
- 수치형 종속변수를 범주화(categorization)하여 분류모델을 사용하기도 함
- 학습 데이터의 종속변수에는 결측이 있으면 안됨

3 종속변수와 독립변수

독립변수(Independent Variable)

- 원인변수(causal variable)로도 불리며 다른 변수에 영향을 미치는 원인이 되는 변수로 보통 "X"로 표기
- 독립변수의 데이터 유형이 범주형인 경우 모델링 전에 원핫 인코딩 등 적절한 조치 필요
- 이상치 또는 결측치가 있는 경우 모델링 전 대치/제거 등 적절한 조치 필요

4 종속변수 평가지표

회귀모델 평가지표

- 주로 실제값과 예측값의 차이인 오차를 기반으로 산출하며 작을수록 해당 모델의 성능이 좋음
- 오차를 기반으로 하는 지표의 경우 대부분 오차(error)를 뜻하는 알파벳 "E"가 포함되어 있음

4 종속변수 평가지표

주요 회귀모델 평가지표

- MSE, MAE, RMSE, MAPE를 주로 사용하며 값이 작을수록 좋음
- MAPE의 경우 종속변수에 0이 있는 경우 발산하기 때문에 사용에 주의 필요

$$\mathrm{MSE} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{n}$$

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100$$

$y_i - \hat{y}_i$: $error$ y_i : 실제값 $\hat{y}_i$: 예측값

4 종속변수 평가지표

회귀모델 평가지표 계산 예시

- RMSE의 계산

$$\text{RMSE} = \sqrt{\text{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

$y_i - \hat{y}_i$: $error$ y_i : 실제값 $\hat{y}_i$: 예측값

y	$\hat{y}$	$y - \hat{y}$	$(y - \hat{y})^2$
3	2.5	0.5	0.25
-0.5	0	-0.5	0.25
2	2	0	0
7	8	-1	1
4.2	4	0.2	0.04
5.1	5.6	-0.5	0.25
3	4.3	-1.3	1.69

$$\sqrt{\frac{0.25 + 0.25 + 0 + 1 + 0.04 + 0.25 + 1.69}{7}} = 0.705$$

4 종속변수 평가지표

분류모델 평가지표

- 정분류와 오분류 결과를 기반으로 분류 성능을 가늠하며 값이 클수록 해당 모델의 성능이 좋음
- 분류모델 평가지표는 대부분 분할표(contingency table)을 기준으로 산출됨

※ 분할표는 혼동행렬(confusion matrix)로도 불림

		Predicted Class: Positive	Predicted Class: Negative	Recall
Actual Class	Positive	True Positive(TP)	False Negative(FN) Type II Error	**Sensitivity** $\frac{TP}{(TP+FN)}$
	Negative	False Positive(FP) Type I Error	True Negative(TN)	**Specificity** $\frac{TN}{(TN+FP)}$
		Precision $\frac{TP}{(TP+FP)}$	**Negative Predictive Value** $\frac{TN}{(TN+FN)}$	**Accurracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$

T(True, 참) : 올바르게 예측한 경우
F(False, 거짓) : 잘못 예측한 경우
P(Positive, 양성) : 양성으로 예측한 경우
N(Negative, 음성) : 음성으로 예측한 경우

4 종속변수 평가지표

주요 분류모델 평가지표

- 정확도, 정밀도, 재현율, F1-Score를 사용하며, 최댓값과 최솟값은 1과 0으로 값이 클수록 좋음
- 분류 성능 평가에서 TP가 중요하기 때문에 해석이 쉬운 정확도와 F1-Score를 같이 검토하는 것이 일반적
- F1-Score는 정밀도와 재현율의 조화평균으로 TP에 집중하면서 1종오류와 2종오류를 같이 고려할 수 있음

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \times \frac{precision \cdot recall}{precision + recall}$$

※ TP: True Positive, TN: True Negative, FP : False Positive, FN: False Negative

4 종속변수 평가지표

분류모델 평가지표 계산 예시

- 재현율(Recall)의 계산

$$Recall = \frac{TP}{TP + FN}$$

TP: True Positive, FN: False Negative

y	$\hat{y}$	Type
1	1	TP
0	0	TN
1	0	FN
1	1	TP
0	1	FP
1	1	TP
1	0	FN

$$\frac{3}{3+2} = \frac{3}{5} = 0.6$$

5 문제 풀이

Q1. 지도학습과 비지도학습을 구분하는 핵심 기준으로 가장 적절한 것은?

1. 사용하는 데이터의 크기와 복잡성
2. 학습에 사용되는 알고리즘의 종류
3. 학습 데이터에 정답 레이블의 존재 여부
4. 모델의 예측 정확도와 성능

5 문제 풀이

Q1. 지도학습과 비지도학습을 구분하는 핵심 기준으로 가장 적절한 것은?

1. 사용하는 데이터의 크기와 복잡성
2. 학습에 사용되는 알고리즘의 종류
3. 학습 데이터에 정답 레이블의 존재 여부
4. 모델의 예측 정확도와 성능

해설

정답 레이블에 해당하는 종속변수 존재 여부가 지도학습과 비지도학습을 구분하는 핵심 기준이 된다.

5 문제 풀이

Q2. 비지도학습에 대한 설명으로 가장 적절한 것은?

1. 입력 데이터와 정답 레이블이 모두 주어진 상태에서 학습하는 방법
2. 정답 레이블 없이 데이터의 숨겨진 패턴이나 구조를 찾는 학습 방법
3. 행동에 따른 보상을 통해 최적의 전략을 학습하는 방법
4. 예측 오차를 최소화하여 연속적인 수치 값을 예측하는 방법

5 문제 풀이

Q2. 비지도학습에 대한 설명으로 가장 적절한 것은?

1. 입력 데이터와 정답 레이블이 모두 주어진 상태에서 학습하는 방법
2. 정답 레이블 없이 데이터의 숨겨진 패턴이나 구조를 찾는 학습 방법
3. 행동에 따른 보상을 통해 최적의 전략을 학습하는 방법
4. 예측 오차를 최소화하여 연속적인 수치 값을 예측하는 방법

해설

1, 4번은 지도학습에 대한 내용이며
3번은 강화학습에 대한 내용이다.

5 문제 풀이

Q3. 회귀 모델 평가지표 중 평균 제곱근 오차(RMSE)의 설명으로 옳은 것은?

1. 예측값과 실제값의 차이의 절댓값을 평균 낸 지표
2. 예측값과 실제값의 차이를 제곱하여 평균 낸 후 제곱근을 취한 지표
3. 모델이 설명하는 분산의 비율을 나타내는 지표
4. 예측 오차의 분산을 표준편차로 나눈 지표

5 문제 풀이

Q3. 회귀 모델 평가지표 중 평균 제곱근 오차(RMSE)의 설명으로 옳은 것은?

1. 예측값과 실제값의 차이의 절댓값을 평균 낸 지표
2. 예측값과 실제값의 차이를 제곱하여 평균 낸 후 제곱근을 취한 지표
3. 모델이 설명하는 분산의 비율을 나타내는 지표
4. 예측 오차의 분산을 표준편차로 나눈 지표

해설

RMSE는 Root Mean Squared Error로 제곱근, 평균, 제곱, 오차를 조합하여 하나의 식으로 만든 지표이다.

5 문제 풀이

Q4. 이진 분류에서 정밀도(Precision)와 재현율(Recall)에 대한 설명으로 옳은 것은?

1. 정밀도는 특이도(Specificity)와 같은 개념이고, 재현율은 민감도(Sensitivity)와 다른 개념이다.
2. 정밀도와 재현율은 모든 전체 예측 중에서 올바르게 예측한 비율을 나타낸다.
3. 정밀도는 실제 양성 중에서 모델이 양성으로 예측한 비율이고,
   재현율은 모델이 양성으로 예측한 것 중에서 실제 양성인 비율이다.
4. 정밀도는 모델이 양성으로 예측한 것 중에서 실제 양성인 비율이고,
   재현율은 실제 양성 중에서 모델이 양성으로 예측한 비율이다.

5 문제 풀이

Q4. 이진 분류에서 정밀도(Precision)와 재현율(Recall)에 대한 설명으로 옳은 것은?

1. 정밀도는 특이도(Specificity)와 같은 개념이고, 재현율은 민감도(Sensitivity)와 다른 개념이다.
2. 정밀도와 재현율은 모든 전체 예측 중에서 올바르게 예측한 비율을 나타낸다.
3. 정밀도는 실제 양성 중에서 모델이 양성으로 예측한 비율이고,
   재현율은 모델이 양성으로 예측한 것 중에서 실제 양성인 비율이다.
4. 정밀도는 모델이 양성으로 예측한 것 중에서 실제 양성인 비율이고,
   재현율은 실제 양성 중에서 모델이 양성으로 예측한 비율이다.

해설

양성으로 예측한 것은 TP+FP, 실제 양성은 TP,
실제 양성은 TP+FN 으로 4번 보기가 적절한 설명이다.

5 문제 풀이

Q5. 주어진 데이터로 계산한 F1-Score로 옳은 것은?

1. 0.5
2. 0.6
3. 0.7
4. 0.8

실제값	예측값
1	1
0	0
1	1
1	0
0	1
0	1
1	0

5 문제 풀이

Q5. 주어진 데이터로 계산한 F1-Score로 옳은 것은?

1. 0.5
2. 0.6
3. 0.7
4. 0.8

실제값	예측값
1	1
0	0
1	1
1	0
0	1
0	1
1	0

해설

TP 2개, TN 1개, FP 2개, FN 2개로
정밀도와 재현율 모두 0.5로 계산된다.
최종적으로 F1-Score는 0.5이다.