Data Science

Level 2

13. 머신러닝 개요 2

1 과적합과 과소적합

개요

- **과적합(Overfitting)** : 모델이 학습 데이터에 과하게 맞춰진 상태이며 신규 데이터 기반 추론 시 저성능 야기
- **과소적합(Underfitting)** : 모델이 학습 데이터에 대충 맞춰진 상태이며 전반적으로 추론 결과가 좋지 않음

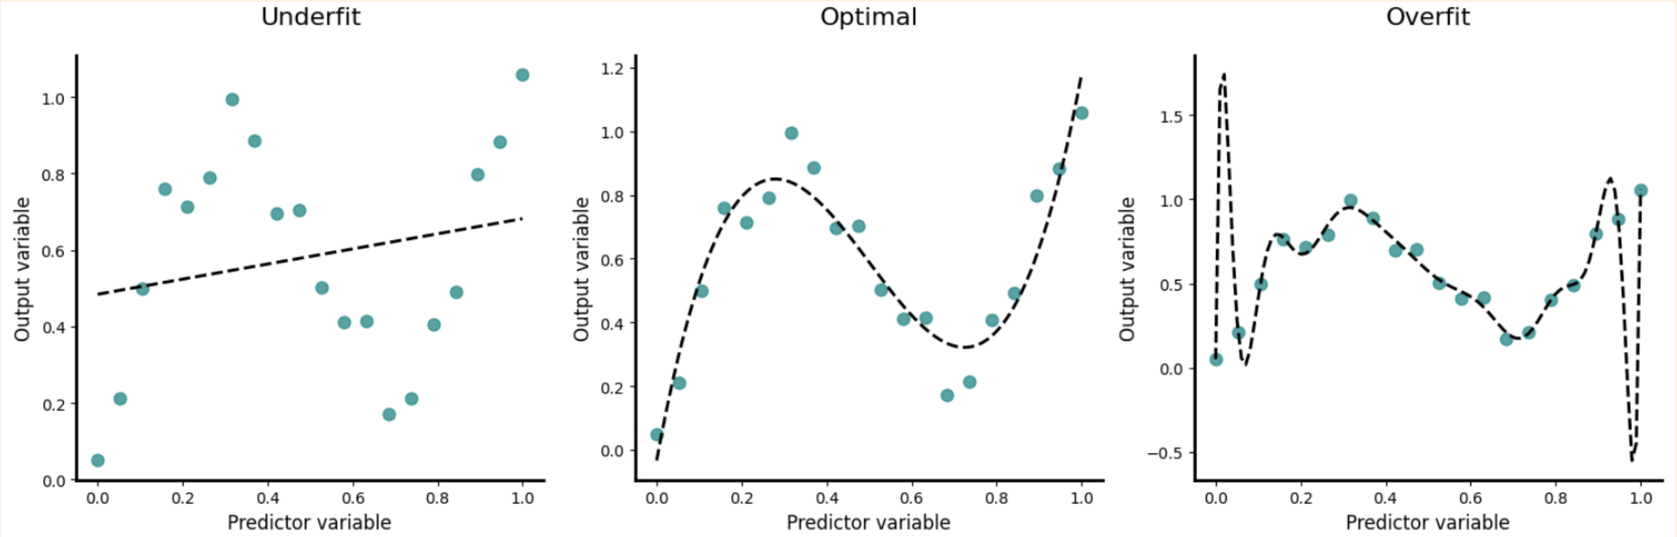

1 과적합과 과소적합

편향-분산 균형(Bias-Variance Tradeoff)

- **편향(Bias)** : 지나치게 단순한 모델로 발생되는 오차. 큰 편향은 과소적합(underfitting) 야기
- **분산(Variance)** : 지나치게 복잡한 모델로 발생되는 오차. 큰 분산은 과대적합(overfitting) 야기
- 편향과 분산을 둘 다 극단적으로 줄이기 어렵기에 타협점을 찾아야 함

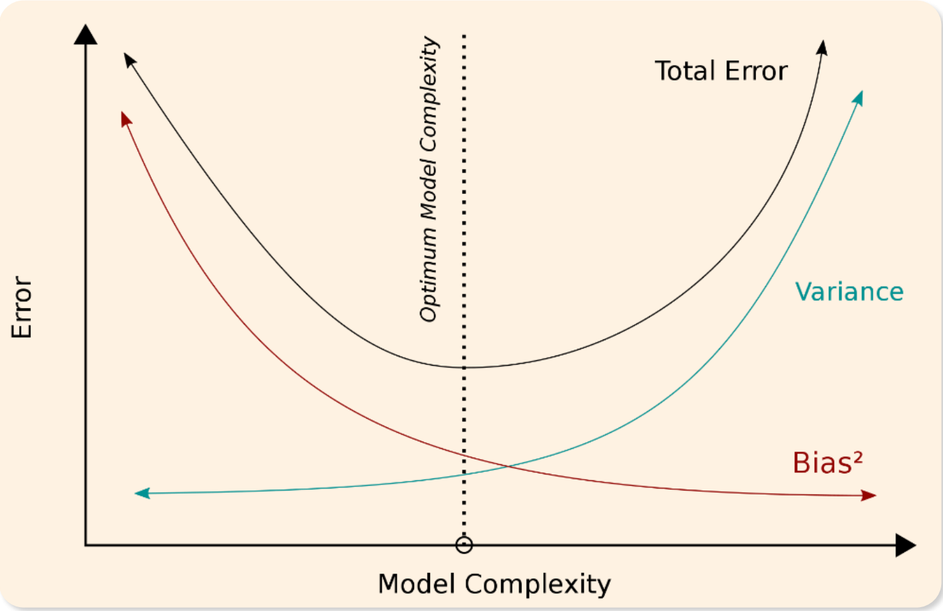

$$Error(x) = \underbrace{\left(f(x) - \frac{1}{k}\sum_{i=1}^{k} f(x_i) \right)^2}_{\text{편향의 제곱}} + \frac{\sigma_\epsilon^2}{k} + \sigma_\epsilon^2$$

분산

불가피한 오차

https://en.wikipedia.org/wiki/Bias-variance_tradeoff

2 모델링 데이터의 분할과 평가

Holdout Test

- 모델의 과적합을 막기 위하여 주어진 데이터를 두 개 이상으로 나누어 학습 및 평가하는 방법
- 두 개로 나누는 경우는 훈련(train)/평가(test) 세트로 분할하며 일반적으로 7:3 또는 8:2로 분할
- 세 개로 나누는 경우는 훈련(train)/검증(validation)/평가(test) 세트로 분할하며 일반적으로 5:3:2로 분할
- 데이터 분할 비율은 정답이 없음
- 검증 데이터 세트는 반복 학습과 평가를 통한 모델 튜닝에 사용

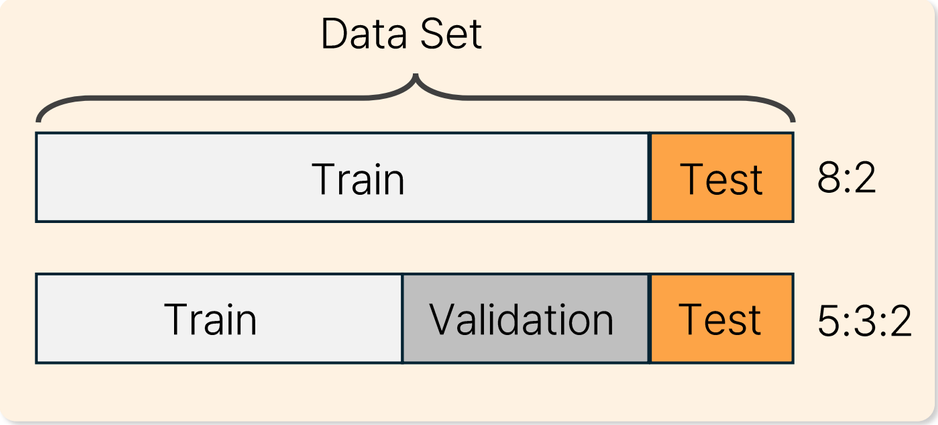

2 모델링 데이터의 분할과 평가

교차검증(CV, Cross Validation)

- 모델의 평균적인 성능을 가늠하기 위해 학습/평가 데이터를 바꿔가며 여러 번 모델의 성능 평가를 실시
- 교차검증 수행 시 모델의 하이퍼 파라미터와 종속/독립 변수는 고정 후 데이터만 변경
- 데이터는 보통 5개 또는 10개 그룹으로 분할하며 그 개수는 분석가의 주관에 따라 결정
- 분할된 데이터 그룹 중 하나는 평가, 나머지는 학습 데이터로 사용
- 데이터 분할은 기본적으로 그룹간 중복이 발생하지 않도록 비복원 추출 실시

2 모델링 데이터의 분할과 평가

교차검증 예시

- n번 반복하며 산출한 평가 지표를 (보통)평균을 사용하여 집계
- 다음의 예시는 10-folds CV

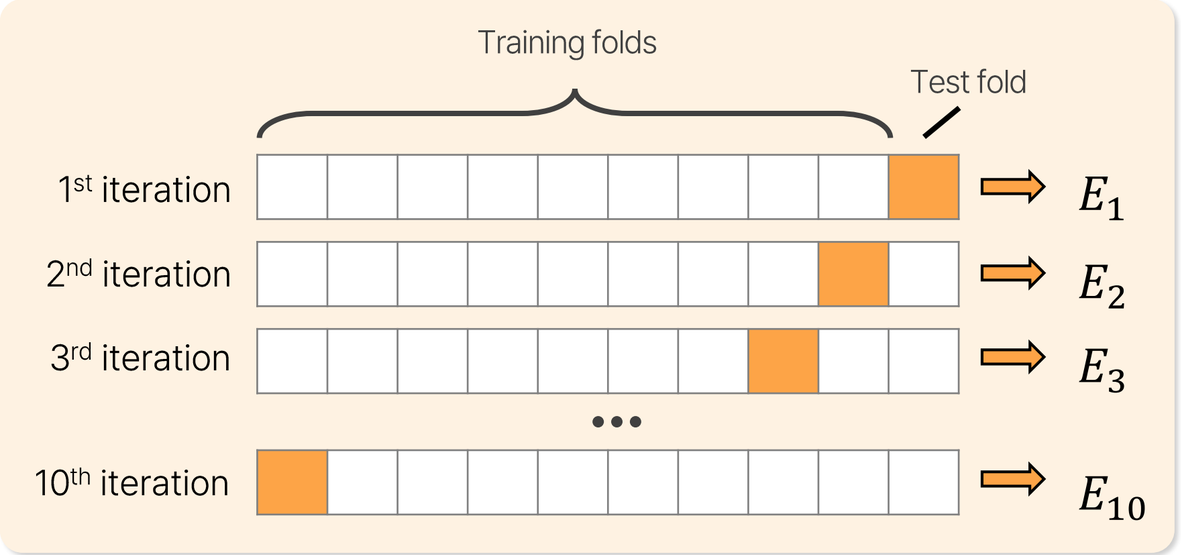

$$E = \frac{1}{10}\sum_{i=1}^{10} E_i$$

3 거리 및 유사도 계산

맨하탄 거리(Manhattan Distance)

- City Block Distance, Taxicab Distance 라고도 하며 두 점 좌표간 절대값 차이 계산

$$d(p,q) = |p_1 - q_1| + |p_2 - q_2| + \cdots + |p_n - q_n| = \sum_{i=1}^{n} |p_i - q_i|$$

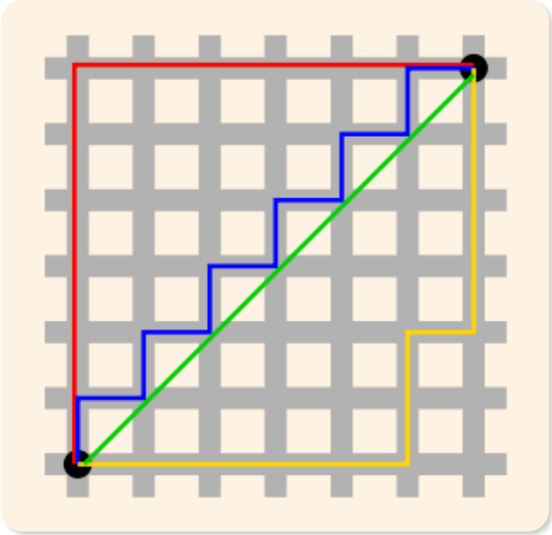

https://en.wikipedia.org/wiki/Taxicab_geometry

3 거리 및 유사도 계산

맨하탄 거리의 계산

고객	나이	연소득	경력
김출근	28	5000	5
김퇴근	40	13000	9

$$|28 - 40| + |5000 - 13000| + |5 - 9| = 12 + 8000 + 4 = 8016$$

3 거리 및 유사도 계산

유클리드 거리(Euclidean Distance)

- n차원의 공간에서 두 점간의 최단거리를 계산
- 직각삼각형의 빗변 거리 계산식의 일반식

$$d(p,q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_n - q_n)^2} = \sqrt{\sum_{i=1}^{n} (p_i - q_i)^2}$$

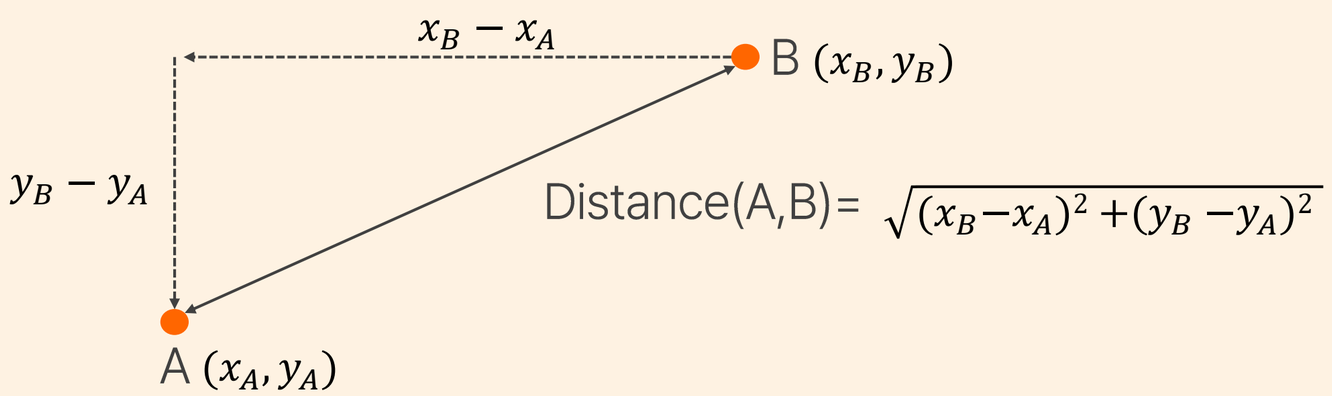

Distance(A,B)= $\sqrt{(x_B - x_A)^2 + (y_B - y_A)^2}$

3 거리 및 유사도 계산

유클리드 거리의 계산

고객	나이	연소득	경력
김출근	28	5000	5
김퇴근	40	13000	9

$$\sqrt{(28-40)^2+(5000-13000)^2+(5-9)^2}$$

$$=\sqrt{144+64000000+16}\ \approx 8000.01$$

3 거리 및 유사도 계산

민코프스키 거리(Minkowski Distance)

- m차원의 민코프스키 공간에서의 거리
- 1-norm의 경우 맨하탄 거리와 같으며 2-norm의 경우 유클리드 거리와 같음
- 민코프스키 승수(r)가 무한대로 발산할 경우 민코프스키 거리는 두 점 사이의 거리 중 최대값이 됨

$$d_M(x, y) = \left(\sum_j^m |x_j - y_j|^r \right)^{1/r}$$

$$d_M(x, y) = \lim_{r \to \infty} \left(\sum_j^m |x_j - y_j|^r \right)^{1/r} = \max |x_j - y_j|$$

3 거리 및 유사도 계산

마할라노비스 거리(Mahalanobis Distance)

- 변수간 상관관계와 분산을 고려한 거리
- 공분산 행렬이 각 변수간 스케일과 상관관계를 보정하여 단위나 스케일에 영향을 받지 않음
- 공분산 기준 정규화 시 마할라노비스 거리는 유클리드 거리와 같음

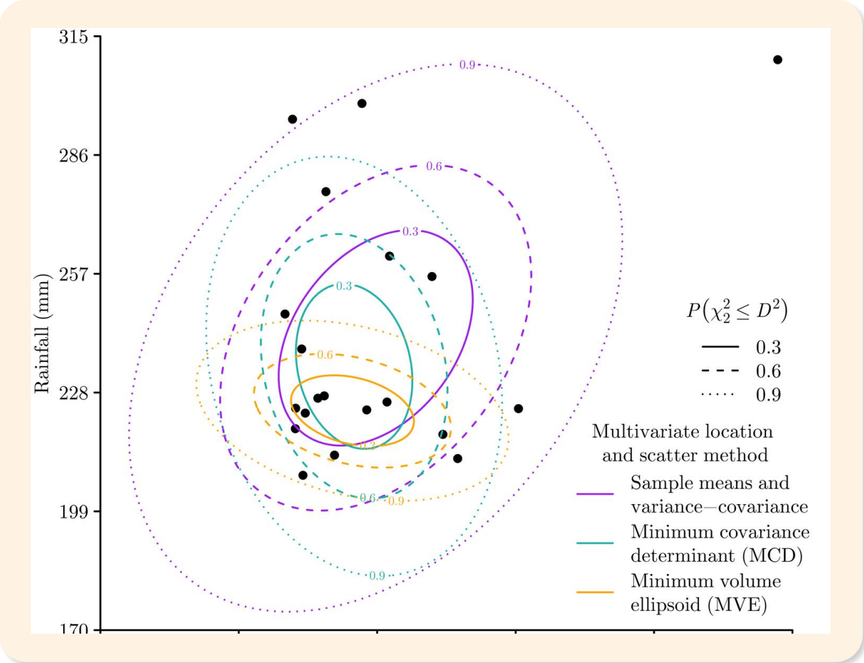

$$d_M(A, B) = \sqrt{(A - B)\,\Sigma^{-1}\,(A - B)^T}$$

공분산 행렬

※ 행 벡터 기준 수식

https://en.wikipedia.org/wiki/Mahalanobis_distance

3 거리 및 유사도 계산

코사인 유사도(Cosine Similarity)

- 내적공간의 두 벡터간 각도의 코사인값을 이용하여 측정된 벡터간의 유사한 정도
- 벡터의 크기가 아닌 방향의 유사도를 판단하는 목적으로 사용
- 두 벡터의 방향이 완전히 같을 경우 1, 90°의 각을 이룰 경우 0, 180°로 완전히 반대 방향인 경우 -1

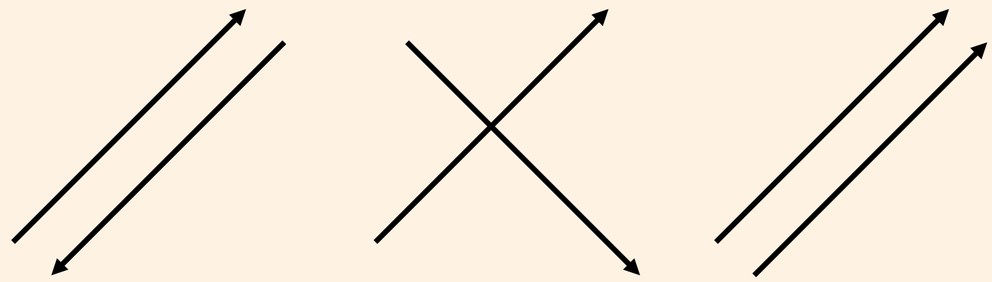

$$similarity = \cos(\theta)$$

$$= \frac{A \cdot B}{\|A\|\|B\|} = \frac{\sum_{i=1}^{n} A_i \times B_i}{\sqrt{\sum_{i=1}^{n}(A_i)^2} + \sqrt{\sum_{i=1}^{n}(B_i)^2}}$$

3 거리 및 유사도 계산

자카드 유사도(Jaccard Similarity)

- 합집합에서 교집합의 비율을 두 집단간 유사도로 판단
- 두 집단의 교집합이 공집합인 경우 0, 동일 집합인 경우 1

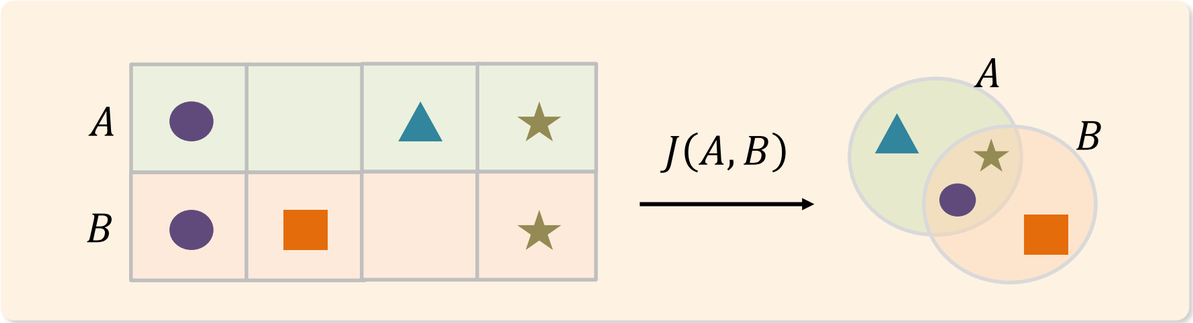

$$J(A,B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

4 머신러닝에서의 정규화

주의점

- 거리계산이 포함된 알고리즘 사용 전 결과 편향 방지를 위하여 정규화 권장
- 학습 데이터로 학습한 규칙을 기반으로 평가 데이터 세트 정규화 실시

※ 데이터 누출(Data Leakage) 문제 예방

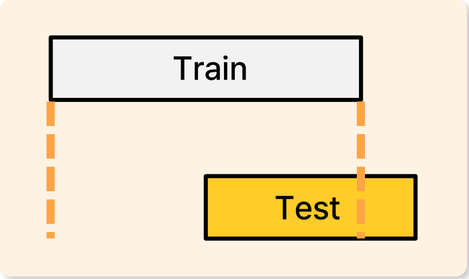

<최소-최대 정규화 예시>

구분	변환 전	Case1	Case2
Train	0	0	0.000
Train	2	0.2	0.167
Train	4	0.4	0.333
Train	10	1	0.833
Test	3	0.3	0.250
Test	5	0.5	0.417
Test	12	1.2	1.000

※ Case2는 학습/평가 데이터를 합친 후 정규화

5 문제 풀이

Q1. 편향-분산 균형(Bias-Variance Tradeoff)에 대한 설명으로 올바른 것은?

1. 편향(Bias)이 클수록 과대적합(overfitting)이 발생한다.
2. 분산(Variance)이 클수록 과소적합(underfitting)이 발생한다.
3. 편향과 분산을 동시에 극단적으로 줄일 수 없다.
4. 분산이 낮은 상태는 모델이 데이터 변화에 매우 민감한 상태이다.

5 문제 풀이

Q1. 편향-분산 균형(Bias-Variance Tradeoff)에 대한 설명으로 올바른 것은?

1. 편향(Bias)이 클수록 과대적합(overfitting)이 발생한다.
2. 분산(Variance)이 클수록 과소적합(underfitting)이 발생한다.
3. 편향과 분산을 동시에 극단적으로 줄일 수 없다.
4. 분산이 낮은 상태는 모델이 데이터 변화에 매우 민감한 상태이다.

해설

편향 또는 분산을 동시에 극단적으로 줄이는 것은 불가능 하며, 일반적으로 편향을 줄이면 분산이 증가하고 분산을 줄이면 편향이 증가하는 경향을 보임

5 문제 풀이

Q2. 교차검증(Cross Validation)에 대한 설명으로 틀린 것은?

1. 교차검증 수행 시 하이퍼파라미터를 매번 변경해야 한다.
2. 데이터 분할은 기본적으로 비복원추출을 실시한다.
3. 학습/평가 데이터를 바꿔가며 여러 번 모델의 성능 평가를 실시한다.
4. 분할된 데이터 그룹 중 하나는 평가, 나머지는 학습 데이터로 사용한다.

5 문제 풀이

Q2. 교차검증(Cross Validation)에 대한 설명으로 틀린 것은?

1. 교차검증 수행 시 하이퍼파라미터를 매번 변경해야 한다.
2. 데이터 분할은 기본적으로 비복원추출을 실시한다.
3. 학습/평가 데이터를 바꿔가며 여러 번 모델의 성능 평가를 실시한다.
4. 분할된 데이터 그룹 중 하나는 평가, 나머지는 학습 데이터로 사용한다.

해설

교차검증 수행 시 하이퍼파라미터는 변경하지 않고,
학습/평가 대상이되는 데이터 세트만 변경한다.

5 문제 풀이

Q3. 코사인 유사도(Cosine Similarity)에 대한 설명으로 올바른 것은?

1. 벡터의 크기를 고려하여 유사도를 측정한다.
2. 두 벡터가 완전히 같은 방향일 때 0의 값을 가진다.
3. 벡터 간의 거리를 측정하는 방법이다.
4. 두 벡터가 90°의 각을 이룰 때 0의 값을 가진다.

5 문제 풀이

Q3. 코사인 유사도(Cosine Similarity)에 대한 설명으로 올바른 것은?

1. 벡터의 크기를 고려하여 유사도를 측정한다.
2. 두 벡터가 완전히 같은 방향일 때 0의 값을 가진다.
3. 벡터 간의 거리를 측정하는 방법이다.
4. 두 벡터가 90°의 각을 이룰 때 0의 값을 가진다.

해설

코사인 유사도는 벡터의 크기가 아닌 방향의 유사도를 판단하며, 90°의 각을 이룰 때 0의 값을 가진다.

5 문제 풀이

Q4. 두 벡터간 코사인 유사도가 가장 큰 쌍은?

1. $\overrightarrow{AB}, \overrightarrow{AC}$
2. $\overrightarrow{AC}, \overrightarrow{BD}$
3. $\overrightarrow{DB}, \overrightarrow{AB}$
4. $\overrightarrow{DC}, \overrightarrow{CD}$

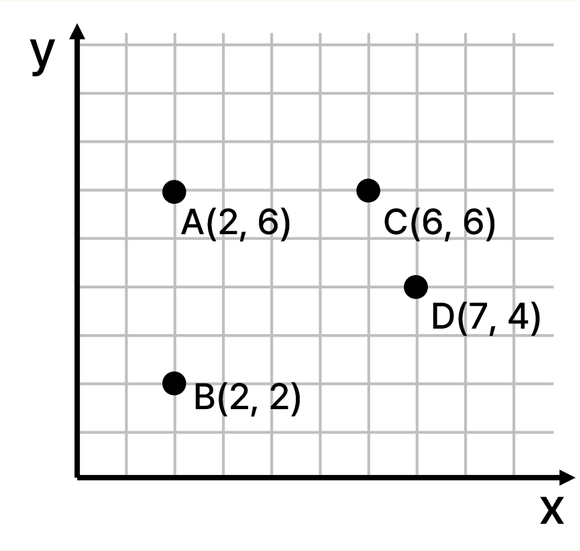

5 문제 풀이

Q4. 두 벡터간 코사인 유사도가 가장 큰 쌍은?

1. $\overrightarrow{AB}, \overrightarrow{AC}$
2. $\overrightarrow{AC}, \overrightarrow{BD}$
3. $\overrightarrow{DB}, \overrightarrow{AB}$
4. $\overrightarrow{DC}, \overrightarrow{CD}$

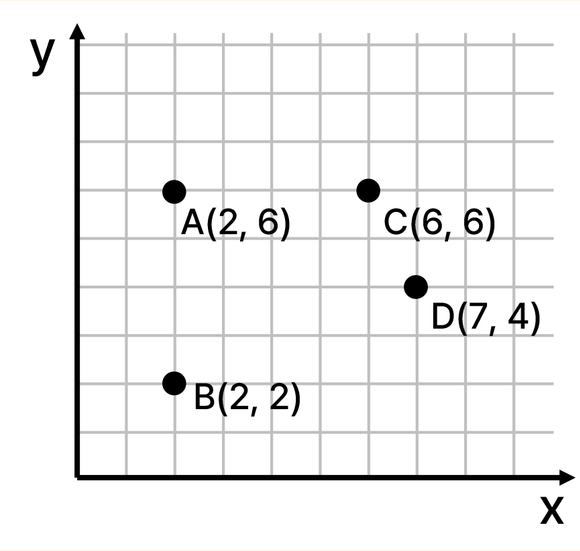

해설

두 벡터가 평행이면 코사인 유사도는 1이 된다.
평행에 가장 가까운 $\overrightarrow{AC}, \overrightarrow{BD}$ 벡터 쌍의 유사도가
가장 크며 그 값은 약 0.9285이다.

5 문제 풀이

Q5. 데이터 정규화 시 데이터 누출(Data Leakage) 문제를 예방하기 위한 올바른 방법은?

1. 학습 데이터와 평가 데이터를 각각 별도로 정규화한다.
2. 학습 데이터로 학습한 정규화 규칙을 평가 데이터에 적용한다.
3. 평가 데이터만으로 정규화 규칙을 만든다.
4. 학습 데이터와 평가 데이터를 합친 후 정규화한다.

5 문제 풀이

Q5. 데이터 정규화 시 데이터 누출(Data Leakage) 문제를 예방하기 위한 올바른 방법은?

1. 학습 데이터와 평가 데이터를 각각 별도로 정규화한다.
2. 학습 데이터로 학습한 정규화 규칙을 평가 데이터에 적용한다.
3. 평가 데이터만으로 정규화 규칙을 만든다.
4. 학습 데이터와 평가 데이터를 합친 후 정규화한다.

해설

데이터 누출 문제를 예방하려면 학습 데이터로만 정규화 규칙을 학습하고, 이를 평가 데이터에 적용해야 한다.