Data Science

Level 2

14. 선형 회귀분석 1

1 선형 회귀분석 개요

선형 회귀분석(Linear Regression)의 정의

- 종속변수와 독립변수간 선형 관계를 모델링 하여 그 관계를 예측 또는 설명하는 기법

  ※ 일반화 선형 모형(GLM, Generalized Linear Model) 중 하나

선형 회귀분석의 종류

- **단순 선형 회귀분석** : 종속변수가 1개, 독립변수가 1개인 선형 회귀분석

$$\hat{y} = \beta_0 + \beta_1 x_1$$

- **다중 선형 회귀분석** : 종속변수가 1개, 독립변수가 2개 이상인 선형 회귀분석

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

※ 다중 선형 회귀분석 수식의 우측은 선형예측자(linear predictor)와 같음

2 선형 회귀분석의 목적과 특징

선형 회귀분석의 목적

- **설명(explanation)** : 독립변수가 종속변수에 미치는 영향의 방향과 크기를 정량적으로 분석
- **예측(prediction)** : 독립변수의 값이 주어졌을 때 종속변수의 값을 추정
- **통제(control)** : 다른 변수들의 영향을 통제한 상태에서 특정 변수의 순수한 효과를 분석

선형 회귀분석의 특징

- 종속 변수 Y와 독립 변수 X간의 관계가 선형적이라고 가정
- 모델이 해석 가능하고 단순
- 이상치(outlier)와 다중공선성(multicollinearity)에 민감
- 예측 뿐만 아니라 설명 목적에도 적합

3 선형 회귀분석의 쓰임새

분야별 활용

- **경제학** : 수요-공급 관계 분석, 소득과 소비의 관계
- **마케팅** : 광고비와 매출의 관계, 가격과 수요의 관계
- **사회과학** : 교육 수준과 소득의 관계, 사회복지와 범죄율의 관계
- **공학** : 온도와 강도의 관계, 압력과 유량의 관계 등

4 선형 회귀식의 구성 요소

단순 선형 회귀모델의 회귀식

- y : 종속변수
- x : 독립변수
- β_0 : 회귀절편(intercept)
- β_1 : 회귀계수(coefficient)
- ϵ : 오차항(error term)

$$y = \beta_0 + \beta_1 x + \epsilon$$

4 선형 회귀식의 구성 요소

다중 선형 회귀모델의 회귀식

- y : 종속변수
- x : 독립변수
- β_0 : 회귀절편(intercept)
- $\beta_1, \ldots, \beta_n$: 회귀계수(coefficient)
- ϵ : 오차항(error term)

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$

5 선형 회귀분석 상세

오차항과 잔차

- 오차항(error term, ε) : 종속변수의 실제값과 회귀식으로 예측된 값 사이의 차이를 나타내는 확률변수
- 잔차(residual, e) : 표본에서 관측된 종속변수의 실제값과 회귀식으로 예측된 값 사이의 차이

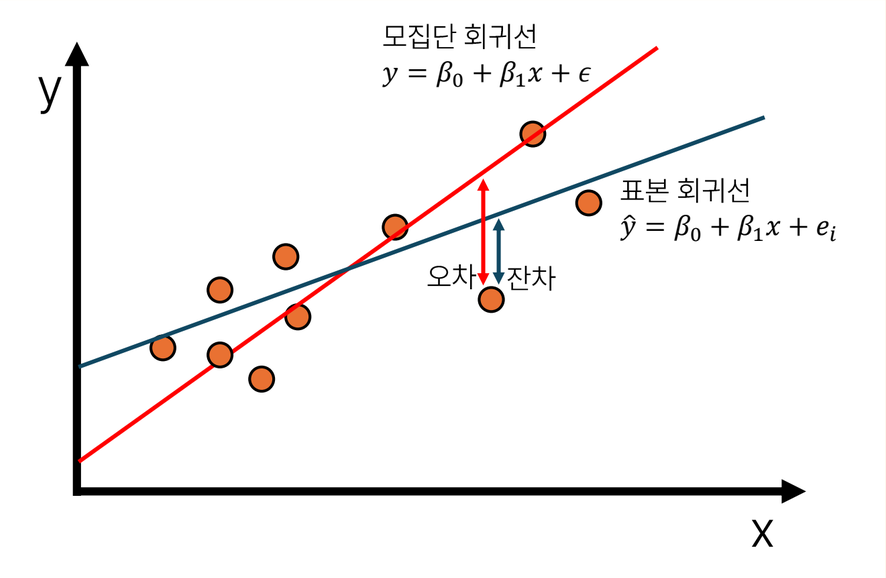

5 선형 회귀분석 상세

최소 제곱법(OLS, Ordinary Least Squares)

- 관측된 데이터와 회귀직선 사이의 차이(잔차)를 제곱해서 모두 더한 값을 최소화하여 회귀계수를 추정

$$SSE = \sum_{i=1}^{n}(y_i - \hat{y})^2 = \sum_{i=1}^{n}(y_i - (\beta_0 + \beta_1 x_i))^2$$

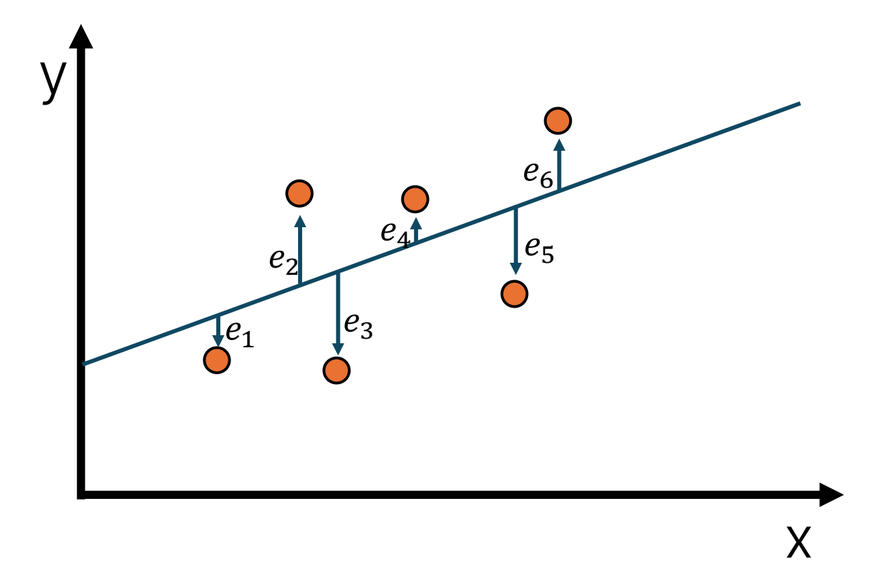

6 회귀계수의 추론

단순 선형 회귀의 회귀계수 산출

- 독립변수가 변할 때 종속변수가 얼마나 따라 변하는지에 대한 비율
- 종속변수와 독립변수의 공분산에 독립변수의 분산을 나눈 값으로 산출

$$\beta_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

6 회귀계수의 추론

회귀 계수 계산 예제

- 데이터 포인트가 5개인 데이터 기반 단순 선형 회귀분석 시 회귀 계수의 산출

x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	2	-2	-2	4	4
2	3	-1	-1	1	1
3	5	0	1	0	0
4	4	1	0	0	1
5	6	2	2	4	4

$$\bar{x} = 3, \bar{y} = 4$$

$$\beta_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{4+1+0+0+4}{4+1+0+1+4} = \frac{9}{10}$$

6 회귀계수의 추론

회귀 계수의 분산

- 표본 데이터를 사용해 추정한 회귀계수가 모집단의 진짜 값에서 얼마나 흩어져 있을지를 나타내는 측도

※ σ^2 : 오차의 분산

$$var(\hat{\beta}_1) = \frac{\sigma^2}{\sum(x_i - \bar{x})^2}$$

회귀 계수의 표준오차

- 회귀계수의 정확도를 판단하거나, 신뢰구간 계산 시 활용

$$SE(\hat{\beta}_1) = \sqrt{var(\hat{\beta}_1)}$$

6 회귀계수의 추론

회귀 계수의 신뢰구간

- $t_{\alpha/2,df}$: t분포의 임계값(보통 95% 신뢰수준으로 $\alpha = 0.05$, 자유도 $df = n - 2$)

$$CI(\hat{\beta}_1) = \hat{\beta}_1 \pm t_{\alpha/2} \cdot SE(\hat{\beta}_1)$$

T 테이블(일부)

df\α	0.25	0.2	0.15	0.1	0.05	0.025	0.01
1	1.000	1.376	1.963	3.078	6.314	12.71	31.82
2	0.816	1.080	1.386	1.886	2.920	4.303	6.965
3	0.765	0.978	1.250	1.638	2.353	3.182	4.541
4	0.741	0.941	1.190	1.533	2.132	2.776	3.747
5	0.727	0.920	1.156	1.476	2.015	2.571	3.365

$t_{0.025,3}$

6 회귀계수의 추론

회귀 계수의 신뢰구간 폭에 영향을 미치는 요인

- **표본 크기** : 클수록 신뢰구간이 좁아짐
- **신뢰수준** : 높을수록 신뢰구간이 넓어짐
- **오차분산** : 클수록 신뢰구간이 넓어짐
- **독립변수의 변동성** : 클수록 신뢰구간이 좁아짐

7 선형 회귀분석의 가정

선형성(Linearity)

- 오차항의 평균이 독립변수의 값에 관계없이 항상 0
- 모형에 체계적인 편향이 없음
- 독립변수와 오차항 사이에 상관관계가 없음

선형성 가정 위반의 주요 요인

- 중요한 설명변수가 모형에서 제외된 경우
- 실제 관계가 비선형인데 선형모형을 사용한 경우
- 독립변수에 측정오차가 있는 경우

7 선형 회귀분석의 가정

등분산성(Homoscedasticity)

- 오차항의 분산이 독립변수의 값에 관계없이 일정
- 모든 관측값이 동일한 신뢰도를 가짐
- 예측의 정확도가 독립변수의 값에 따라 변하지 않음

등분산성 가정 위반의 주요 요인

- 매출, 소득과 같이 범위(range)가 넓은 변수가 사용되는 경우
- 집단별로 변동성이 다른 경우
- 지수적 관계를 선형으로 가정하는 등 함수형태가 잘못 설정된 경우

7 선형 회귀분석의 가정

독립성(Independence)

- 서로 다른 관측 값의 오차항들이 상관관계가 없음
- 한 관측 값의 오차가 다른 관측 값의 오차에 영향을 주지 않음
- 관측 값들이 무작위로 추출

독립성 가정 위반의 주요 요인

- 계절성, 추세, 순환 등의 시간 패턴이 있는 경우
- 지리적으로 인접한 관측 값들 간의 상관관계(서로 영향을 주는 인접 지역의 가격 등)
- 관측 값들이 클러스터를 이루는 경우
- 중요한 설명변수가 누락되는 경우 해당 변수의 영향이 오차항에 영향을 끼침

7 선형 회귀분석의 가정

정규성(Normality)

- 오차항이 정규분포를 따름
- 종속변수 Y도 조건부로 정규분포를 따름

$$Y|X \sim N(\beta_0 + \beta_1 x, \sigma^2)$$

정규성 가정 위반의 주요 요인

- 잔차의 극단값(outliers)
- 잔차 분포에 과도한 왜도와, 첨도가 관측되는 경우
- 서로 다른 집단이 섞여 있어 잔차 분포에 다봉분포가 생기는 경우

※ 봉우리가 2개 이상인 분포의 경우 다봉분포(multimodal distribution)라고 함

8 (보충) 정규성의 판단

QQ Plot(Quantile-Quantile Plot)

- 데이터의 분포 모양이 특정 이론분포(예 : 정규분포)를 따르는지 시각적으로 확인하는 그래프
- 오름차순으로 정렬한 데이터와 정규 분포의 이론적 분위수를 기반으로 그래프 구현
- 점들이 대각선에 밀접해 있다면 정규분포에 가깝다고 판단

※ 대각선에서 멀리 떨어져 있는 점(v)이 있는 경우 정규분포와 차이가 난다고 판단

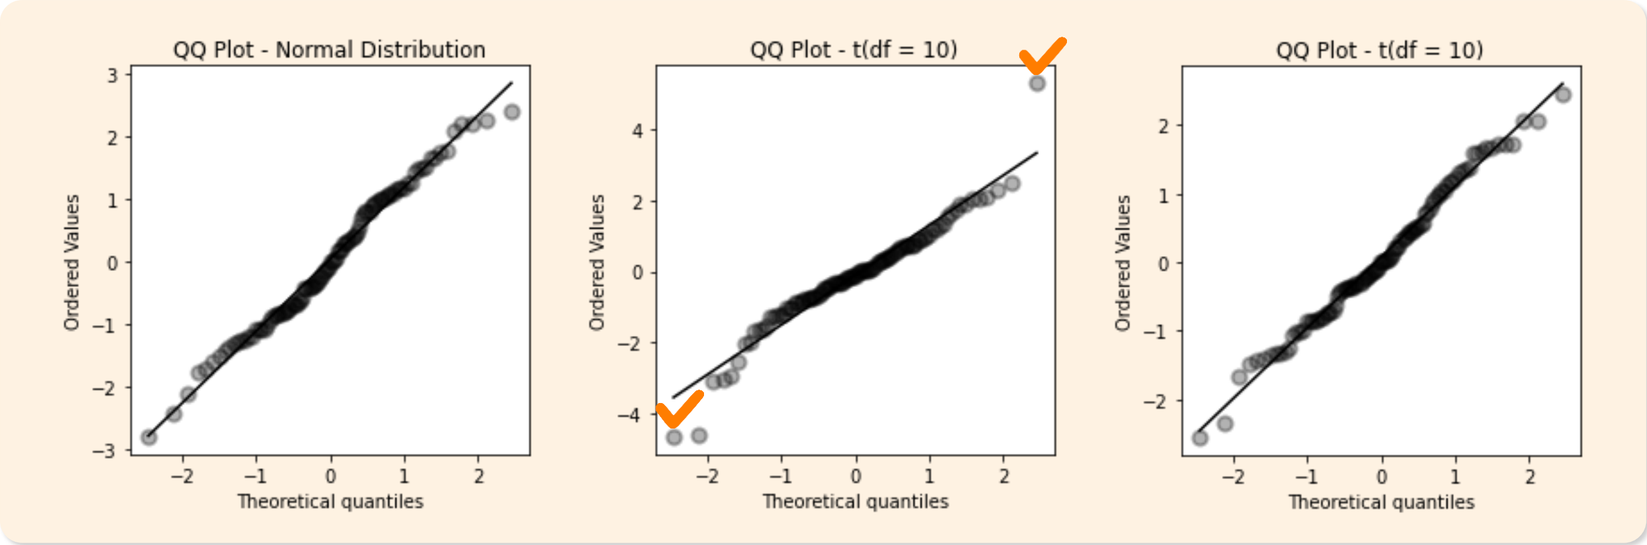

9 문제 풀이

Q1. 다음 중 선형회귀분석의 목적으로 가장 적절하지 않은 것은?

1. 독립변수가 종속변수에 미치는 영향의 방향과 크기를 정량적으로 분석
2. 독립변수의 값이 주어졌을 때 종속변수의 값을 추정
3. 다른 변수들의 영향을 통제한 상태에서 특정 변수의 순수한 효과를 분석
4. 범주형 종속변수에 대한 분류 문제를 해결

9 문제 풀이

Q1. 다음 중 선형회귀분석의 목적으로 가장 적절하지 않은 것은?

1. 독립변수가 종속변수에 미치는 영향의 방향과 크기를 정량적으로 분석
2. 독립변수의 값이 주어졌을 때 종속변수의 값을 추정
3. 다른 변수들의 영향을 통제한 상태에서 특정 변수의 순수한 효과를 분석
4. 범주형 종속변수에 대한 분류 문제를 해결

해설

선형회귀분석은 연속형(수치형) 종속변수를 다루는 기법이다.

9 문제 풀이

Q2. 최소제곱법을 사용하여 단순선형회귀의 회귀계수를 추정하는 방법에 대한 설명으로 올바른 것은?

1. 종속변수와 독립변수의 공분산에 종속변수의 분산을 나눈 값으로 회귀계수를 산출
2. 독립변수와 종속변수의 공분산에 독립변수의 분산을 나눈 값으로 회귀계수를 산출
3. 관측된 데이터와 회귀직선 사이의 차이를 절댓값으로 계산하여 최소화
4. 독립변수의 평균값에 종속변수의 평균값을 더한 후 표본 크기로 나누어 산출

9 문제 풀이

Q2. 최소제곱법을 사용하여 단순선형회귀의 회귀계수를 추정하는 방법에 대한 설명으로 올바른 것은?

1. 종속변수와 독립변수의 공분산에 종속변수의 분산을 나눈 값으로 회귀계수를 산출
2. 독립변수와 종속변수의 공분산에 독립변수의 분산을 나눈 값으로 회귀계수를 산출
3. 관측된 데이터와 회귀직선 사이의 차이를 절댓값으로 계산하여 최소화
4. 독립변수의 평균값에 종속변수의 평균값을 더한 후 표본 크기로 나누어 산출

해설

최소제곱법에서 회귀계수는 독립변수와 종속변수의 공분산을 독립변수의 분산으로 나눈 값으로 산출되며, 이는 잔차제곱합을 최소화하는 원리에 기반한다.

9 문제 풀이

Q3. 단순 선형회귀에서 회귀계수의 분산에 대한 해석으로 틀린 것은?

1. 오차분산(σ^2)이 클수록 회귀계수의 분산이 증가한다.
2. 독립변수의 변동성이 클수록 회귀계수의 분산이 감소한다.
3. 독립변수의 평균값이 클수록 회귀계수의 분산이 증가한다.
4. 표본 크기가 클수록 회귀계수의 분산이 감소한다.

$$var(\hat{\beta}_1) = \frac{\sigma^2}{\sum(x_i - \bar{x})^2}$$

9 문제 풀이

Q3. 단순 선형회귀에서 회귀계수의 분산에 대한 해석으로 틀린 것은?

1. 오차분산(σ^2)이 클수록 회귀계수의 분산이 증가한다.
2. 독립변수의 변동성이 클수록 회귀계수의 분산이 감소한다.
3. 독립변수의 평균값이 클수록 회귀계수의 분산이 증가한다.
4. 표본 크기가 클수록 회귀계수의 분산이 감소한다.

$$var(\hat{\beta}_1) = \frac{\sigma^2}{\sum(x_i - \bar{x})^2}$$

해설

독립변수의 평균값은 β_1의 분산에 직접적인 영향을 주지 않으며,
β_1의 분산은 오차분산과 독립변수의 변동성(편차제곱합)에 의해 결정된다.

9 문제 풀이

Q4. 단순 선형회귀에서 회귀계수의 신뢰구간에 영향을 미치는 요인에 대한 설명으로 틀린 것은?

1. 표본 크기가 클수록 신뢰구간이 좁아진다.
2. 신뢰수준이 높을수록 신뢰구간이 넓어진다.
3. 오차분산이 클수록 신뢰구간이 넓어진다.
4. 독립변수의 변동성이 작을수록 신뢰구간이 좁아진다.

9 문제 풀이

Q4. 단순 선형회귀에서 회귀계수의 신뢰구간에 영향을 미치는 요인에 대한 설명으로 틀린 것은?

1. 표본 크기가 클수록 신뢰구간이 좁아진다.
2. 신뢰수준이 높을수록 신뢰구간이 넓어진다.
3. 오차분산이 클수록 신뢰구간이 넓어진다.
4. 독립변수의 변동성이 작을수록 신뢰구간이 좁아진다.

해설

독립변수의 변동성이 크면 독립변수의 편차제곱합이 커져서 회귀계수의 표준오차가 작아지기 때문에 회귀계수의 신뢰구간이 좁아진다.

9 문제 풀이

Q5. 선형회귀분석의 특징에 대한 설명으로 올바른 것은?

1. 모델이 해석 가능하고 단순하여 예측 뿐만 아니라 설명 목적에도 적합하다.
2. 독립변수의 개수가 표본 크기보다 많아도 회귀계수를 정상적으로 추정할 수 있다.
3. 선형회귀분석은 이상치(outlier)에 강건하여 이상치의 영향을 거의 받지 않는다.
4. 종속변수와 독립변수 간의 관계가 비선형이어도 선형회귀분석을 그대로 적용할 수 있다.

9 문제 풀이

Q5. 선형회귀분석의 특징에 대한 설명으로 올바른 것은?

1. 모델이 해석 가능하고 단순하여 예측 뿐만 아니라 설명 목적에도 적합하다.
2. 독립변수의 개수가 표본 크기보다 많아도 회귀계수를 정상적으로 추정할 수 있다.
3. 선형회귀분석은 이상치(outlier)에 강건하여 이상치의 영향을 거의 받지 않는다.
4. 종속변수와 독립변수 간의 관계가 비선형이어도 선형회귀분석을 그대로 적용할 수 있다.

해설

선형회귀분석은 모델이 해석 가능하고 단순하다는 장점이 있어 예측과 설명 목적 모두에 적합하다. 반면 이상치에 민감하고, 독립변수 개수가 표본 크기보다 많으면 추정이 불가능하다.