Data Science

Level 2

15. 선형 회귀분석 2

1 선형 회귀분석의 해석

단순 선형 회귀모델

- 데이터와 최소제곱법(OLS)을 통하여 확보하는 회귀식은 다음과 같음

$$y = \beta_0 + \beta_1 x_1 + \epsilon \ \rightarrow \ \hat{y} = \beta_0 + \beta_1 x_1$$

절편(Intercept)의 해석

- 절편 β_0 는 독립변수 x가 0일 때 종속변수 y의 예측값을 나타냄

$$\beta_0 = \hat{y} - \beta_1 x_1$$

1 선형 회귀분석의 해석

회귀 계수(Coefficient)의 해석

- 기울기 β_1 은 독립변수 x 가 한 단위 증가할 때 종속변수 y 의 평균적인 변화량
- $\beta_1 > 0$: 양의 관계(독립변수 증가 → 종속변수 증가)
- $\beta_1 < 0$: 음의 관계(독립변수 증가 → 종속변수 감소)
- $\beta_1 = 0$: 관계 없음

$$\beta_1 = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$$

1 선형 회귀분석의 해석

회귀 계수의 해석 예시

- 종속변수가 매출($\hat{y}_{sales}$), 독립변수가 손님 수($x_{customer}$)일 때 산출된 회귀식

$$\hat{y}_{sales} = 4000 + 2500x_{customer}$$

- 손님 수가 1명 증가할 때마다 매출은 2500씩 증가
- 손님 수가 2명일 경우 매출은 9000
- 매출과 손님 수의 관계는 양의 관계

1 선형 회귀분석의 해석

다중 선형 회귀분석 결과 예시

- 분석 결과 레포트에는 회귀 계수, 절편, 결정계수 등 다양한 내용이 포함 됨
- 일반적으로 회귀계수를 뜻하는 "coef" 영역에 회귀계수와 절편이 표기 됨
- $\beta_1 < 0$: 음의 관계(독립변수 증가 → 종속변수 감소)

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	25.6486	2.155	11.903	0.000	21.425	29.872
temp	0.9665	0.301	3.211	0.001	0.377	1.557
atemp	1.7693	0.277	6.388	0.000	1.226	2.312
humidity	-0.8367	0.022	-38.554	0.000	-0.879	-0.794
windspeed	0.0583	0.052	1.119	0.263	-0.044	0.160

$$\hat{y} = 25.6486 + 0.9665x_{temp} + 1.7693x_{atemp} - 0.8367x_{humidity} + 0.0583x_{windspeed}$$

2 결정 계수

결정계수(Coefficient of Determination)의 정의

- 회귀모델이 종속변수의 변동을 얼마나 잘 설명하는지를 나타내는 측도로 보통 R^2로 표시

결정계수의 특징

- 결정계수는 독립변수들이 종속변수의 총 변동 중 몇 퍼센트를 설명하는지를 의미
- 결정계수의 값은 0에서 1 사이이며 값이 클수록 설명력이 높은 것으로 판단
- 결정계수를 보완한 수정된(adjusted) 결정계수가 사용되기도 함
- 단순 선형 회귀분석의 경우 종속변수와 독립변수의 상관계수 제곱과 결정계수가 같음
- 모델의 독립변수가 추가되면 결정계수가 증가하는 경향이 있음

$$R_{k+1}^2 \geq R_k^2$$

2 결정 계수

결정계수의 요소

- 총제곱합(SST, Total Sum of Squares) : 전체 데이터의 변동성(분산)
- 회귀제곱합(SSR, Sum of Squares Regression) : 회귀 모델이 설명한 변동성
- 오차제곱합(SSE, Sum of Squares Error) : 모델이 설명하지 못한 오차

$$SST = \sum_{i=1}^{n} (y_i - \bar{y})^2$$

$$SSR = \sum_{i=1}^{n} (\hat{y}_i - \bar{y})^2$$

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

$$SST = SSR + SSE$$

2 결정 계수

결정계수의 계산(전통적 정의)

- 총 제곱합과 회귀제곱합을 조합하여 산출하며 결정계수는 0이상1이하

$$R^2 = \frac{SSR}{SST} = \frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2}$$

결정계수의 계산(일반적 정의)

- 절편이 없거나 성능이 매우 나쁜 경우 음수가 나오기도 함

$$R^2 = 1 - \frac{SSE}{SST} = \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

2 결정 계수

수정된(Adjusted) 결정 계수

- 자유도를 기반으로 보정된 결정 계수
- 데이터 개수(n)과 독립변수 개수(k)를 기반으로 결정 계수를 보정

  ※ n-k : 잔차 자유도 (residual degrees of freedom), n-1 : 총 자유도 (total degrees of freedom)
- 수정된 결정 계수는 결정 계수보다 반드시 작음
- 값이 음수가 나올 수 있음

$$R^2_{adj} = 1 - \frac{SSE/(n-k)}{SST/(n-1)} \quad (R^2_{adj} < R^2)$$

3 다중공선성

다중공선성(Multicollinearity)의 정의

- 회귀모델에서 두 개 이상의 독립변수 간 높은 상관관계가 존재하는 상태
- 한 독립변수가 다른 독립변수들의 선형결합으로 거의 완벽하게 설명될 수 있는 상태

다중공선성의 특징

- 회귀계수의 표준오차가 크게 증가하여 신뢰구간이 넓어지고 추정이 불안정
- 예측 성능은 크게 문제 없을 수 있으나 회귀 계수 기반 해석이 어려워 짐
- 독립변수들 간에 완전한 선형관계가 존재하면 완전(다중)공선성 이라고 함

3 다중공선성

다중공선성의 진단

- 분산 팽창 인자(VIF, Variance Inflation Factor) : 추정된 회귀 계수의 분산이 증가하는 정도를 나타냄
- 다중공선성의 정도를 수치로 나타내는 대표적인 지표로 분산 팽창 계수 또는 분산 확대 인자 등으로 불림
- VIF값은 각 변수마다 산출할 수 있으며 값이 큰 경우 다중공선성의 문제가 있다고 판단
- VIF는 일반적으로 10을 기준으로 판단하며 3 또는 4를 사용하는 등 주관적인 경계값을 사용
- VIF는 1 이상의 값을 가지며 1의 경우 다중공선성이 전혀 없는 경우를 뜻함

$$VIF_i = \frac{1}{1 - R_i^2}$$

3 다중공선성

다중공선성 문제의 해결

- 다양한 해결 방법 중 문제 원인이 되는 독립변수 제거가 가장 간단한 접근
- VIF값이 지정 임계치 이상인 독립변수를 제거
- 제거 기준은 주관적이며 독립변수 제거 시 2개 이상 일괄 제거 지양
- 문제 독립변수 제거 시 일반적으로 VIF 값들이 일괄 감소

독립변수	VIF
A	1.65
B	11.78
C	11.81
D	4.36

독립변수 C 제거 →

독립변수	VIF
A	1.59
B	2.42
-	-
D	4.33

4 선형 회귀분석의 예측값 산출

예측값 산출

- 회귀식이 산출된 이후 예측값 산출이 가능
- 예측값 산출을 위해 회귀식에 사용된 각 독립변수의 값이 필요
- 학습 데이터를 정규화 한 경우 예측에 사용할 데이터 또한 정규화 필요
- 학습 데이터의 범주형 변수를 별도로 처리한 경우 예측에 사용할 데이터 또한 처리 필요

  ※ Label Encoding, One-Hot Encoding 등

$$\hat{y} = 2 + 3x_A + 5x_B$$

A	B	$\hat{y}_i$
1	1	10
1	2	15
-1	3	14

5 선형 회귀분석의 평가

오차기반 성능평가

- 회귀모델로 MSE, MAE, RMSE, MAPE 등 종속변수 평가지표 사용 가능

$$\mathrm{MSE} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{n}$$

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100$$

$y_i - \hat{y}_i$: $error$ y_i : 실제값 $\hat{y}_i$: 예측값

5 선형 회귀분석의 평가

결정 계수

- 결정 계수가 0.75인 경우 독립변수들이 종속변수 변동의 75%를 설명한다는 의미
- 결정계수가 0 이하인 경우 모델이 단순히 (종속변수)평균을 사용하는 것 이하의 성능을 뜻함
- 결정계수가 클수록 좋으며 이는 영향력이 큰 독립변수가 존재함을 의미

5 선형 회귀분석의 평가

정보량 규준(Information criterion) 개요

- 적합도와 복잡성 간의 균형을 수치로 평가하는 도구로 값이 작을수록 좋음

AIC(Akaike Information Criterion)

- 낮은 AIC값을 가진 모델이 예측력이 적으면서도 덜 복잡하다고 판단

$$AIC = -2\log_e(\hat{L}) + 2p \quad \hat{L} = p(x \mid \hat{\theta}, M) = \frac{SSR}{n}$$

p : 변수(파라미터) 개수
n : 데이터 개수
$\hat{L}$: 우도(likelihood, 모형 적합도)

BIC(Bayesian Information Criterion)

- 표본 개수에 비례한 페널티로 AIC대비 변수 개수를 줄이는데 더 큰 중점을 둠

$$BIC = -2\log_e(\hat{L}) + p\log_e(n)$$

6 선형 회귀분석시 고려사항

결정계수와 독립변수

- 독립변수가 지나치게 많은 경우 결정계수는 높을 수 있으나 예측력이 좋지 않을 수 있음
- 종속변수와 관련이 없는 독립변수도 우연히 높은 결정계수를 만들 수 있음
- 높은 결정계수는 반드시 낮은 오차와 안정성을 보장하지는 않음

6 선형 회귀분석시 고려사항

잔차분석

- 예측값과 잔차를 기반으로 현재 모델 상태를 진단하고 개선 여부를 판단할 수 있음

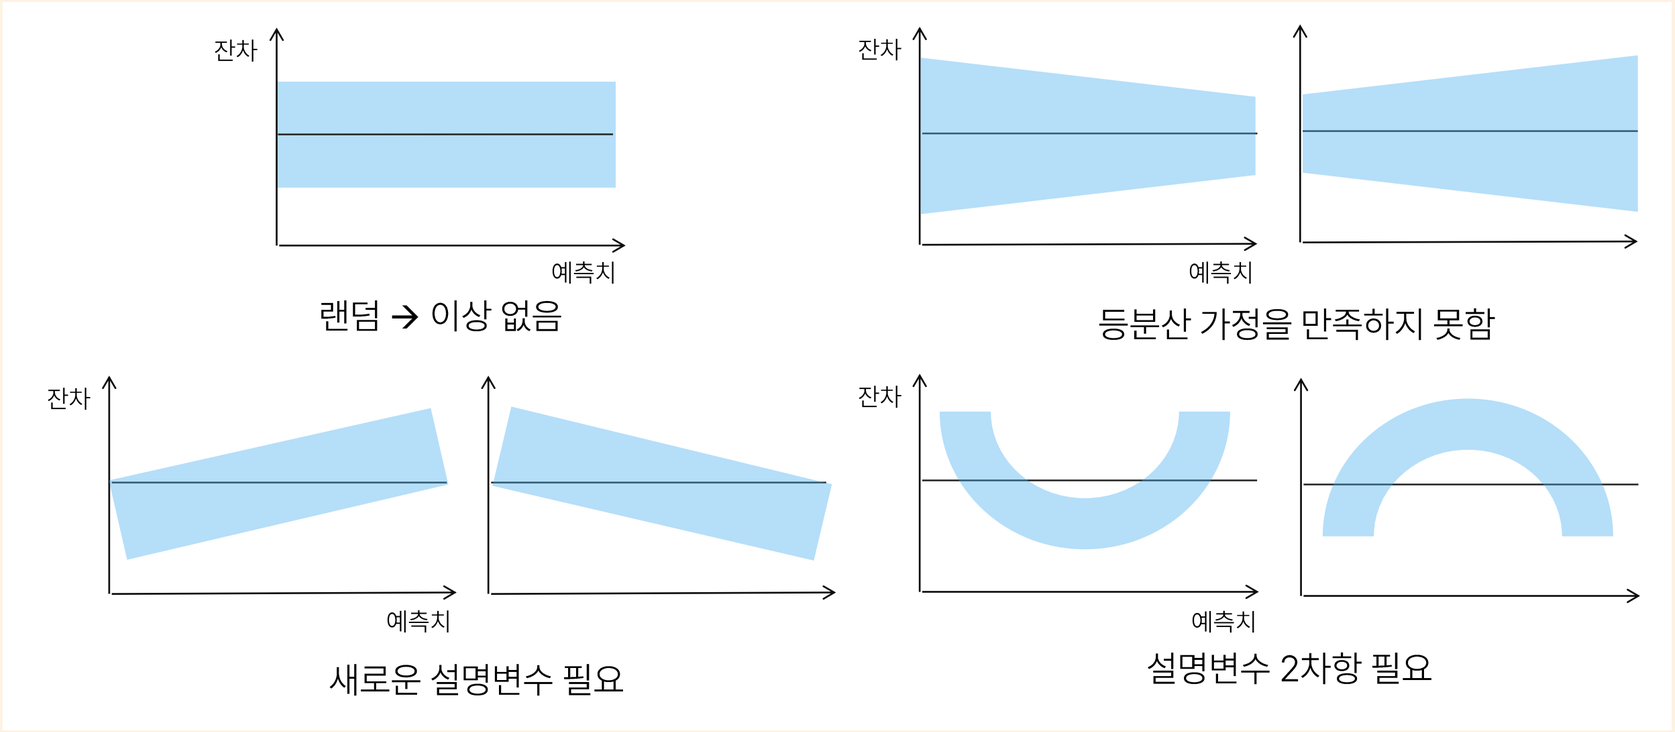

7 문제 풀이

Q1. 다음 중 결정계수에 대한 설명으로 옳지 않은 것은?

1. 결정계수 0.8은 독립변수들이 종속변수 변동의 80%를 설명한다는 의미이다.
2. 결정계수 0은 회귀모델이 종속변수의 평균을 사용하는 것과 동일한 예측 성능을 의미한다.
3. 결정계수 0.3은 예측 성능에 중요한 역할을 하는 독립변수의 부재를 시사한다.
4. 결정계수가 높을수록 항상 좋은 모델이며, 예측 성능도 우수하다.

7 문제 풀이

Q1. 다음 중 결정계수에 대한 설명으로 옳지 않은 것은?

1. 결정계수 0.8은 독립변수들이 종속변수 변동의 80%를 설명한다는 의미이다.
2. 결정계수 0은 회귀모델이 종속변수의 평균을 사용하는 것과 동일한 예측 성능을 의미한다.
3. 결정계수 0.3은 예측 성능에 중요한 역할을 하는 독립변수의 부재를 시사한다.
4. 결정계수가 높을수록 항상 좋은 모델이며, 예측 성능도 우수하다.

해설

과적합이 발생하거나 종속변수와 관련 없는 독립변수도 우연히 높은 결정계수를 만들 수 있으며, 높은 결정계수가 반드시 낮은 오차와 안정성을 보장하지 않는다.

7 문제 풀이

Q2. 분산 팽창 인자(VIF)에 대한 설명으로 옳은 것은?

1. VIF 값이 0.5라면 다중공선성이 심각한 상태이다.
2. VIF는 일반적으로 10을 기준으로 판단하며, 10 이상이면 다중공선성 문제가 있다고 본다.
3. VIF 값이 1보다 작으면 독립변수들 간에 완전한 독립성을 의미한다.
4. 다중공선성이 있어도 예측 성능에는 전혀 영향을 주지 않는다.

7 문제 풀이

Q2. 분산 팽창 인자(VIF)에 대한 설명으로 옳은 것은?

1. VIF 값이 0.5라면 다중공선성이 심각한 상태이다.
2. VIF는 일반적으로 10을 기준으로 판단하며, 10 이상이면 다중공선성 문제가 있다고 본다.
3. VIF 값이 1보다 작으면 독립변수들 간에 완전한 독립성을 의미한다.
4. 다중공선성이 있어도 예측 성능에는 전혀 영향을 주지 않는다.

해설

VIF는 정의상 항상 1 이상의 값을 가지며,
일반적으로 10을 기준으로 다중공선성을 판단한다.

7 문제 풀이

Q3. 수정된 결정계수에 대한 설명으로 옳지 않은 것은?

$$R^2_{adj} = 1 - \frac{SSE/(n-k)}{SST/(n-1)}$$

1. -0.02는 산출될 수 있는 값에 해당한다.
2. 독립변수의 개수가 많을수록 결정계수와의 차이가 커진다.
3. 표본 크기가 매우 클 때는 결정계수와의 차이가 거의 없어진다.
4. 독립변수 개수 증가에 따른 수정된 결정계수는 단조증가 패턴을 보인다.

7 문제 풀이

Q3. 수정된 결정계수에 대한 설명으로 옳지 않은 것은?

$$R^2_{adj} = 1 - \frac{SSE/(n-k)}{SST/(n-1)}$$

1. -0.02는 산출될 수 있는 값에 해당한다.
2. 독립변수의 개수가 많을수록 결정계수와의 차이가 커진다.
3. 표본 크기가 매우 클 때는 결정계수와의 차이가 거의 없어진다.
4. 독립변수 개수 증가에 따른 수정된 결정계수는 단조증가 패턴을 보인다.

해설

결정계수의 경우 독립변수를 추가하는 경우 증가하지 않을 수 있고,
수정된 결정계수의 경우 자유도에 따른 페널티로 오히려 감소할 수 있다.

7 문제 풀이

Q4. 다음 다중선형회귀식이 주어졌을 때, 새로운 관측값 $x_A = 3, x_B = 2, x_C = 1$ 에 대한 예측값($\hat{y}$) 은?

$$\hat{y} = 4 + 2x_A + 5x_B - 3x_C$$

1. 13
2. 15
3. 17
4. 19

7 문제 풀이

Q4. 다음 다중선형회귀식이 주어졌을 때, 새로운 관측값 $x_A = 3, x_B = 2, x_C = 1$ 에 대한 예측값($\hat{y}$) 은?

$$\hat{y} = 4 + 2x_A + 5x_B - 3x_C$$

1. 13
2. 15
3. 17
4. 19

해설

각 독립변수에 3, 2, 1을 대입하여 계산하면 17이 나온다.

7 문제 풀이

Q5. 잔차분석에서 "이상 없음"을 나타내는 패턴은?

1. 예측값이 증가할수록 잔차의 분산이 증가하는 패턴
2. 잔차가 예측값에 대해 랜덤하게 분포하는 패턴
3. 잔차가 예측값에 대해 U자 형태로 분포하는 패턴
4. 잔차가 예측값에 대해 일정한 추세를 보이는 패턴

7 문제 풀이

Q5. 잔차분석에서 "이상 없음"을 나타내는 패턴은?

1. 예측값이 증가할수록 잔차의 분산이 증가하는 패턴
2. 잔차가 예측값에 대해 랜덤하게 분포하는 패턴
3. 잔차가 예측값에 대해 U자 형태로 분포하는 패턴
4. 잔차가 예측값에 대해 일정한 추세를 보이는 패턴

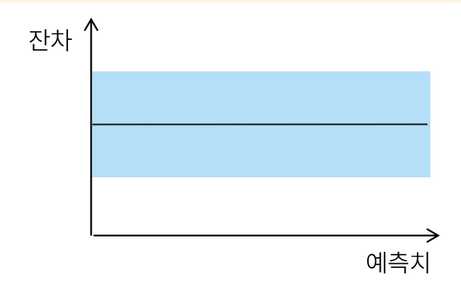

해설

잔차가 예측값에 대해 랜덤하게 분포하는 것이 이상적인 패턴이고 이상 없음을 뜻함.
그리고 해당 패턴은 모델의 가정들이 잘 만족되고 있음을 의미