Data Science

Level 2

16. 이항 로지스틱 회귀분석

1 이항 로지스틱 회귀분석 개요

이항 로지스틱 회귀분석(Binary Logistic Regression)의 정의

- 종속변수가 이항(binary) 결과를 가질 때 독립변수와의 관계를 분석하는 통계적 기법
- 로짓 연결 함수를 사용하여 선형 관계를 확률로 변환하는 일반화 선형모델

관련 용어

- **일반화 선형 모형(GLM)** : 종속 변수와 독립 변수 사이의 관계를 선형적으로 모델링하는 통계적 방법
- **로짓 연결 함수(logit link function)** : 확률 p와 선형예측자(linear predictor) 사이를 연결하는 함수
- **베르누이 시행(bernoulli trial)** : 임의의 결과가 '성공' 또는 '실패'의 두 가지 중 하나인 실험
- **최대 우도 추정법(maximum likelihood estimation)** : 주어진 데이터가 관측될 확률(우도, likelihood)이 가장 크게 되는 파라미터 값을 추정하는 방법

2 이항 로지스틱 회귀분석의 목적과 특징

이항 로지스틱 회귀분석의 목적

- 사건 발생 여부와 같은 이진 결과 변수(정상/고장, 성공/실패 등)을 예측
- 독립변수들이 특정 사건 발생 확률에 미치는 영향을 정량적으로 측정
- 분류(classification) 문제 해결을 위한 예측 모델링

이항 로지스틱 회귀분석의 특징

- 종속변수가 베르누이 분포(단일) 또는 이항 분포(그룹)를 따름
- 종속변수 예측값이 0과 1 사이의 확률로 제한됨
- 독립변수와 성공확률(예측 확률)간 S자 곡선(시그모이드, sigmoid) 형태의 관계로 모델링
- 최대 우도 추정법(maximum likelihood estimation)을 사용하여 모수 추정

3 이항 로지스틱 회귀분석의 쓰임새

분야별 활용

- **의학 및 보건학**: 질병 진단 예측, 치료법 효과성 분석, 위험요인 식별
- **마케팅 및 비즈니스**: 고객 구매 의사결정 예측, 이탈 고객 분석, 캠페인 반응 예측
- **금융**: 신용 평가 및 대출 승인, 부도 위험 예측, 보험 청구 분석
- **공학 및 기술**: 제품 품질 판정, 시스템 고장 예측, 품질관리 분석
- **인사관리**: 채용 결정 지원, 승진 가능성 예측, 직원 만족도 분석
- **교육**: 학습자 성취도 예측, 진로 선택 분석, 교육 프로그램 효과성 평가

4 (보충) 베르누이 시행

베르누이 시행의 정의 및 특징

- 결과가 오직 두 가지 중 하나로 성공(success) 또는 실패(failure)와 같은 이항 결과를 가지는 단일 실험
- 성공 확률이 p, 실패 확률이 q라고 할 때 p + q는 1
- 독립성(independence) : 각 시행은 서로 독립적이며 이전 결과에 영향을 받지 않음
- 이항성(binary) : 결과는 반드시 두 가지 중 하나
- 일정성(constant) : 모든 시행에서 성공 확률 p가 동일함

5 (보충) 로지스틱 함수

로지스틱 함수(Logistic Function)

- 선형예측자를 확률로 변환하는 함수로 시그모이드 함수(sigmoid function)로도 불림

$$p = \frac{1}{1+e^{-\eta}} = \frac{e^{\eta}}{1+e^{\eta}} \qquad \eta = X\beta = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

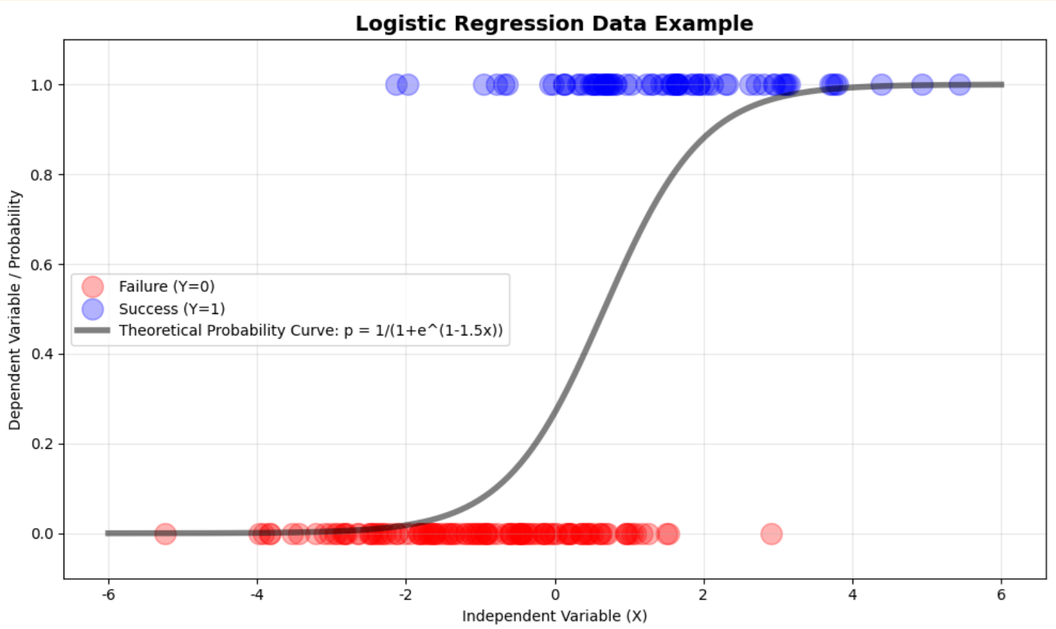

5 (보충) 로지스틱 함수

로지스틱 함수의 특징

- 정의역(독립변수 X) : $(-\infty, +\infty)$
- 치역(성공확률 p) : (0, 1)
- 그래프는 S자 곡선 형태로 나타나며 변곡점은 p가 0.5인 지점
- 변곡점을 중심으로 점대칭
- 임계값(0, 1) 근처에서 상대적으로 확률 p의 변화가 둔화

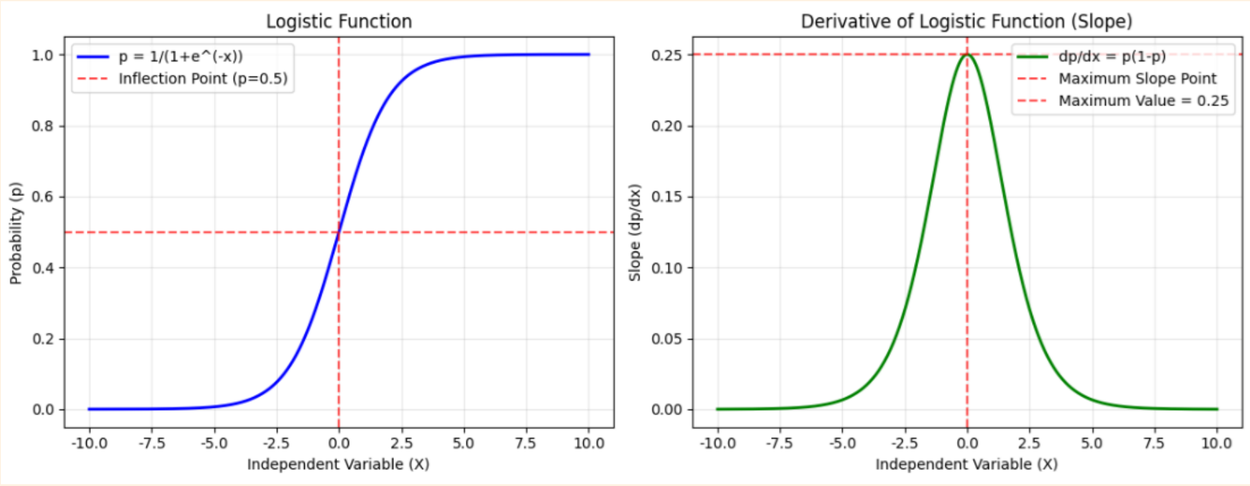

6 (보충) 최대 우도 추정

개념

- 어떤 분포 $f(x;\ \theta)$에서, 파라미터 θ가 미지수, 관측 데이터 $x_1, x_2, \ldots, x_n$가 있을 때, 이 데이터들이 실제로 관측될 확률이 가장 큰 θ를 찾는 것

  ※ 어떤 확률분포로부터 생성된 데이터에 대해, 그 데이터를 가장 잘 설명하는 분포의 파라미터를 찾는 방법

$$L(\theta) = \prod_{i=1}^{n} f(x_i \mid \theta) \qquad \ell(\theta) = \log L(\theta) = \sum_{i=1}^{n} \log f(x_i \mid \theta)$$

$$\hat{\theta}_{MLE} = \underset{\theta}{argmax}\, \ell(\theta)$$

7 이항 로지스틱 회귀분석의 가정

주요 가정

- **독립성(independence)** : 관측치들이 서로 독립적이어야 함
- **선형성(linearity)** : 독립변수와 로짓(logit) 간의 선형관계 가정
- **다중공선성 부재(no multicollinearity)** : 독립변수들 간 높은 상관관계가 없어야 함
- **큰 표본 크기(large sample size)** : 최대 우도 추정법의 정확성을 위해 충분한 표본 필요
- **완전분리 부재(no complete separation)** : 독립변수로 종속변수를 완벽하게 분리할 수 없어야 함

Y	X
0	24
0	53
0	33
0	57
1	68
1	72
1	82

Y	X
0	34
0	52
0	90
0	58
1	25
1	75
1	80

8 이항 로지스틱 회귀분석의 해석

오즈(Odds, 승산)

- 특정 사건이 발생할 확률과 발생하지 않을 확률의 비율
- 성공 확률에 대한 실패 확률의 상대적 크기를 나타내는 지표

$$Odds = \frac{P(\text{성공})}{P(\text{실패})} = \frac{P}{1 - P}$$

오즈의 해석

- Odds = 1 : 성공과 실패 확률이 동일(p = 0.5)
- Odds > 1 : 성공 확률이 실패 확률보다 높음
- Odds < 1 : 성공 확률이 실패 확률보다 낮음

8 이항 로지스틱 회귀분석의 해석

로짓(Logit)

- 성공확률 P를 로그 오즈(log-odds)로 변환하는 함수
- 확률을 선형회귀분석이 가능한 형태로 변환하는 연결함수

$$Logit(P) = \ln(Odds) = \ln\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

8 이항 로지스틱 회귀분석의 해석

회귀계수(β_i)의 해석

- **양의 회귀계수** : 독립변수 증가 시 성공확률 증가
- **음의 회귀계수** : 독립변수 증가 시 성공확률 감소
- **0인 회귀계수** : 해당 독립변수는 성공확률에 영향 없음

8 이항 로지스틱 회귀분석의 해석

오즈비(OR, Odds Ratio)의 해석

- OR = 1 : 해당 변수가 결과에 영향이 없음
- OR > 1 : 해당 변수가 성공 확률을 증가시킴
- OR < 1 : 해당 변수가 성공 확률을 감소시킴

$$
\begin{aligned}
OR &= \frac{odds(x_1,\ldots,x_i+1,\ldots x_n)}{odds(x_1,\ldots,x_i,\ldots x_n)} \\
&= \frac{e^{\beta_1+\beta_1 x_1+\cdots+\beta_i(x_i+1)+\ldots+\beta_n x_n}}{e^{\beta_1+\beta_1 x_1+\cdots+\beta_i x_i+\ldots+\beta_n x_n}} \\
&= e^{\beta_i}
\end{aligned}
$$

9 이항 로지스틱 회귀분석의 예측값 산출

예측확률과 분류값

- 입력된 독립변수 값을 기반으로 확률 값이 산출되며 이를 지정한 경계값을 기준으로 분류
- 경계값(cut-off value)은 문턱값(threshold)라고도 하며 일반적으로 0.5로 지정
- 이진분류에서 경계값이 0.5인 경우 0.5를 초과하는 확률 값은 1, 나머지는 0으로 치환
- 경계값을 조정할 경우 분류 결과가 바뀔 수 있으며 이는 분류 성능과도 직결됨

	경계값: 0.5	경계값: 0.3	경계값: 0.8
p	$\widehat{y_1}$	$\widehat{y_2}$	$\widehat{y_3}$
0.13	0	0	0
0.24	0	0	0
0.48	0	1	0
0.59	1	1	0
0.67	1	1	0
0.75	1	1	0
0.98	1	1	1

10 이항 로지스틱 회귀분석의 평가

성능 평가

- 분류모델로 정확도, 정밀도, 재현율, F1-Score 종속변수 평가지표 사용 가능
- 분류 결과를 기반으로 ROC 곡선 및 AUC 확인 가능

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \times \frac{precision \cdot recall}{precision + recall}$$

※ TP : True Positive, TN : True Negative, FP : False Positive, FN : False Negative

10 이항 로지스틱 회귀분석의 평가

ROC 곡선

- FP 값의 비율(FPR)로 하고 세로축을 TP 값의 비율(TPR)로 하여 시각화 한 그래프
- 분류 모델의 전반적인 성능을 가늠할 수 있음
- 곡선 아래면적을 AUC(area under curve)라고 하며 이 값의 최대값은 1

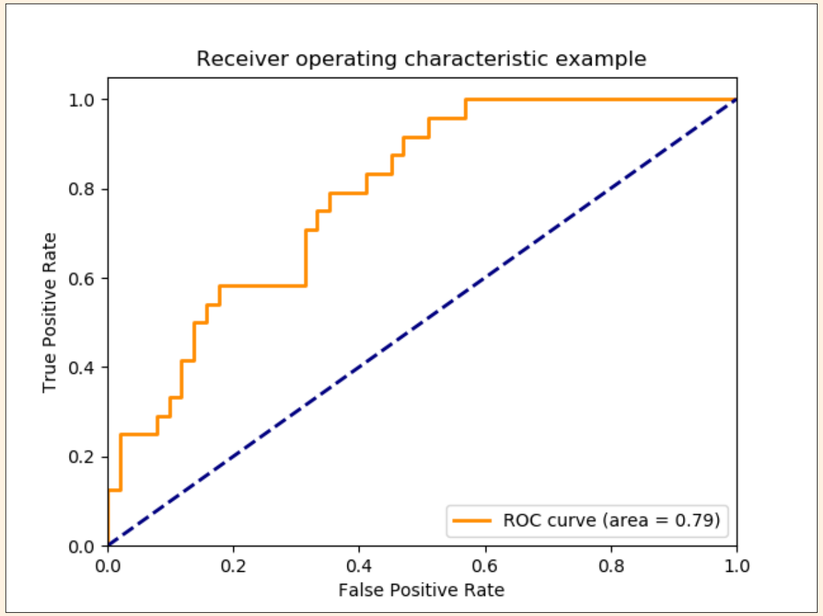

$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

https://scikit-learn.org/stable/auto_examples/model_selection/plot_roc.html

11 이항 로지스틱 회귀분석시 고려사항

모델 가정 위반

- **선형성 위반** : 독립변수와 로짓간 비선형 관계 시 예측력 저하
- **독립성 위반** : 표준오차 편향 및 신뢰구간 부정확
- **다중공선성** : 독립변수 간 강한 상관관계로 회귀계수 해석 어려움

표본 관련

- **최소 표본 크기** : 독립변수 1개당 최소 10~15개의 사건(event, data point) 필요
- **불균형 데이터** : 종속변수의 특정 범주 비율이 매우 작을 경우 예측 성능 저하

  ※ 이상탐지 문제의 경우 종속변수 범주가 불균형인 경우가 많음(99:1 이상)

12 문제 풀이

Q1. 로지스틱 함수와 로짓 함수의 관계에 대한 설명으로 가장 적절한 것은?

1. 로지스틱 함수와 로짓 함수는 동일한 함수이다.
2. 로지스틱 함수는 확률을 선형예측자로 변환하고, 로짓 함수는 선형예측자를 확률로 변환한다.
3. 로지스틱 함수는 선형예측자를 확률로 변환하고, 로짓 함수는 확률을 선형예측자로 변환한다.
4. 두 함수는 서로 독립적이며 관련성이 없다.

12 문제 풀이

Q1. 로지스틱 함수와 로짓 함수의 관계에 대한 설명으로 가장 적절한 것은?

1. 로지스틱 함수와 로짓 함수는 동일한 함수이다.
2. 로지스틱 함수는 확률을 선형예측자로 변환하고, 로짓 함수는 선형예측자를 확률로 변환한다.
3. 로지스틱 함수는 선형예측자를 확률로 변환하고, 로짓 함수는 확률을 선형예측자로 변환한다.
4. 두 함수는 서로 독립적이며 관련성이 없다.

해설

로지스틱 함수는 선형예측자(η, 에타)를 확률 p로 변환하는 함수이고, 로짓 함수는 확률을 선형예측자로 변환하는 함수로, 두 함수는 서로 역함수 관계이다.

12 문제 풀이

Q2. 오즈비(OR)가 0.6일 때의 해석으로 옳은 것은?

1. 해당 변수가 성공 확률을 60% 증가시킨다.
2. 해당 변수가 오즈를 40% 감소시킨다.
3. 해당 변수가 결과에 영향이 없다.
4. 해당 변수가 성공 확률을 40% 감소시킨다.

12 문제 풀이

Q2. 오즈비(OR)가 0.6일 때의 해석으로 옳은 것은?

1. 해당 변수가 성공 확률을 60% 증가시킨다.
2. 해당 변수가 오즈를 40% 감소시킨다.
3. 해당 변수가 결과에 영향이 없다.
4. 해당 변수가 성공 확률을 40% 감소시킨다.

해설

오즈비가 0.6이라는 것은 OR < 1이므로 해당 변수가 성공 확률을 감소시킨다는 의미. 구체적으로 오즈가 0.6배가 되기 때문에 즉, 100%에서 60%로 감소하여 40% 감소한 것으로 해석

12 문제 풀이

Q3. 이항 로지스틱 회귀분석에서 경계값(cut-off value)를 기존 0.5에서 0.8로 증가시켰을 때 예상되는 결과로 옳은 것은?

1. 재현율(recall)은 감소한다.
2. 재현율(recall)은 증가한다.
3. 정밀도(precision)와 재현율(recall) 모두 증가한다.
4. 정밀도(precision)와 재현율(recall) 모두 감소한다.

12 문제 풀이

Q3. 이항 로지스틱 회귀분석에서 경계값(cut-off value)를 기존 0.5에서 0.8로 증가시켰을 때 예상되는 결과로 옳은 것은?

1. 재현율(recall)은 감소한다.
2. 재현율(recall)은 증가한다.
3. 정밀도(precision)와 재현율(recall) 모두 증가한다.
4. 정밀도(precision)와 재현율(recall) 모두 감소한다.

해설

클래스 1로 분류되는 기준이 더 엄격해져서 TP와 FP가 감소
재현율(TP/(TP+FN))은 확실하게 감소하는 것이
맞으나, 정밀도는 경우에 따라 증가 또는 감소한다.

12 문제 풀이

Q4. 이항 로지스틱 회귀분석의 가정으로 옳지 않은 것은?

1. 관측치들이 서로 독립적이어야 한다.
2. 독립변수와 로짓 간의 선형관계가 성립해야 한다.
3. 종속변수가 정규분포를 따라야 한다.
4. 독립변수들 간 높은 상관관계가 없어야 한다.

12 문제 풀이

Q4. 이항 로지스틱 회귀분석의 가정으로 옳지 않은 것은?

1. 관측치들이 서로 독립적이어야 한다.
2. 독립변수와 로짓 간의 선형관계가 성립해야 한다.
3. 종속변수가 정규분포를 따라야 한다.
4. 독립변수들 간 높은 상관관계가 없어야 한다.

해설

이항 로지스틱 회귀분석에서 종속변수는 베르누이분포 또는 이항분포를 따르며, 정규분포를 따를 필요가 없음

12 문제 풀이

Q5. ROC 커브와 AUC에 대한 다음 설명 중 옳은 것을 모두 고른 것은?

ㄱ. ROC 커브의 x축은 거짓양성률(FPR), y축은 참양성률(TPR)이다.
ㄴ. AUC 값이 0.5에 가까울수록 분류 성능이 우수하다.
ㄷ. ROC 커브가 대각선에 가까울수록 랜덤 분류기와 유사한 성능을 의미한다.
ㄹ. 경계값(cut-off value) 증가 시 AUC값 또한 증가한다.

1. ㄱ, ㄴ
2. ㄱ, ㄷ
3. ㄷ, ㄹ
4. ㄱ, ㄴ, ㄷ

12 문제 풀이

Q5. ROC 커브와 AUC에 대한 다음 설명 중 옳은 것을 모두 고른 것은?

ㄱ. ROC 커브의 x축은 거짓양성률(FPR), y축은 참양성률(TPR)이다.
ㄴ. AUC 값이 0.5에 가까울수록 분류 성능이 우수하다.
ㄷ. ROC 커브가 대각선에 가까울수록 랜덤 분류기와 유사한 성능을 의미한다.
ㄹ. 경계값(cut-off value) 증가 시 AUC값 또한 증가한다.

1. ㄱ, ㄴ
2. ㄱ, ㄷ
3. ㄷ, ㄹ
4. ㄱ, ㄴ, ㄷ

해설

AUC 값이 0.5에 가까우면 랜덤 분류기와 유사한 성능으로 틀린 보기이며, AUC값은 경계값에 관계 없이 일정하다.