Data Science

Level 2

17. k-NN

1 k-NN 개요

k-NN(k-Nearest Neighbor)의 정의

- 인스턴스 기반 학습 또는 게으른 학습에 속하는 비모수적 지도학습 알고리즘
- 가장 가까운 k개의 이웃(data point)를 기반으로 회귀 또는 분류 작업을 수행하는 알고리즘

관련 용어

- **인스턴스 기반 학습** : 개별 훈련 사례(instance)를 기반으로 새로운 데이터에 대한 예측을 수행하는 학습 방식
- **게으른 학습(Lazy learning)** : 즉시 학습(Eager learning)이 아닌 별도의 요청(쿼리) 시 학습하는 방식

2 k-NN의 목적과 특징

k-NN의 목적

- **회귀 모델**: 수치형 종속변수를 활용한 회귀 문제 해결
- **분류 모델**: 범주형 종속변수를 활용한 분류 문제 해결

k-NN의 특징

- k는 1 이상의 자연수 작을수록 과적합, 클수록 과소적합 경향이 있음
- 가장 가까운 k개의 이웃을 찾은 후 해당 데이터로 회귀 또는 분류 작업을 실시
- 모델 성능은 k값에 민감함
- 게으른 학습 특성 상 평가 데이터가 인입되기 전에 학습을 하지 않음
- 이웃 데이터 선별 작업에 거리 계산이 필요하여 정규화된 데이터 사용 권장

3 k-NN의 쓰임새

분야별 활용

- **이상치 처리**: k개의 이웃과의 거리를 기반으로 산출한 분포와 임계값으로 이상치 판별 및 처리
- **결측치 처리**: 결측 데이터를 평가 데이터로 하여 결측치 다중 대치
- **금융**: 유사 고객 기반 신용도 평가, 유사 거래 기반 사기거래 판별 등
- **생물 정보학**: 유사 유전자 서열 기반 신규 유전자 기능 예측 등

4 (보충) 인스턴스 기반 학습

인스턴스 기반 학습(Instance-based Learning)의 정의 및 개념

- 개별 학습 사례(instance)를 기반으로 새로운 데이터에 대한 예측을 수행하는 학습 방식
- 학습 데이터의 data point(instance)간 유사성을 기반으로 학습과 예측을 수행

  ※ 구체적 사례(instance) = 데이터 포인트(data point) = 학습 표본(training sample)

인스턴스 기반 학습의 특징

- **메모리 기반 학습(Memory-based Learning)** : 모든 학습 data point를 메모리에 저장
- **지역적 근사(Local Approximation)** : 평가 데이터 주변 k개의 학습 데이터에 의존
- **비모수적 접근(Non-parametric Approach)** : 특정 확률분포 또는 함수 형태에 대한 가정이 없음

5 (보충) 거리 계산

데이터간 거리 계산

- 가장 가까운 k개의 data point를 결정짓기 위한 거리 계산 필요
- 일반적으로 맨하탄 또는 유클리드 거리 계산법 사용

$$d_m(p,q) = \sum_{i=1}^{n} |p_i - q_i|$$

$$d_e(p,q) = \sqrt{\sum_{i=1}^{n} (p_i - q_i)^2}$$

6 k-NN의 예측값 산출

분류 모델

- 1) 학습 데이터 준비
- 2) 평가 데이터를 기준으로 학습 데이터의 독립변수 기준 가장 가까운 k개의 이웃 탐색
- 3) k개의 이웃의 종속변수를 취합하여 최빈 범주 산출

※ 이진 분류의 경우 k가 짝수이면 분류가 올바르게 되지 않아 k 홀수 지정 권장(동점 문제)

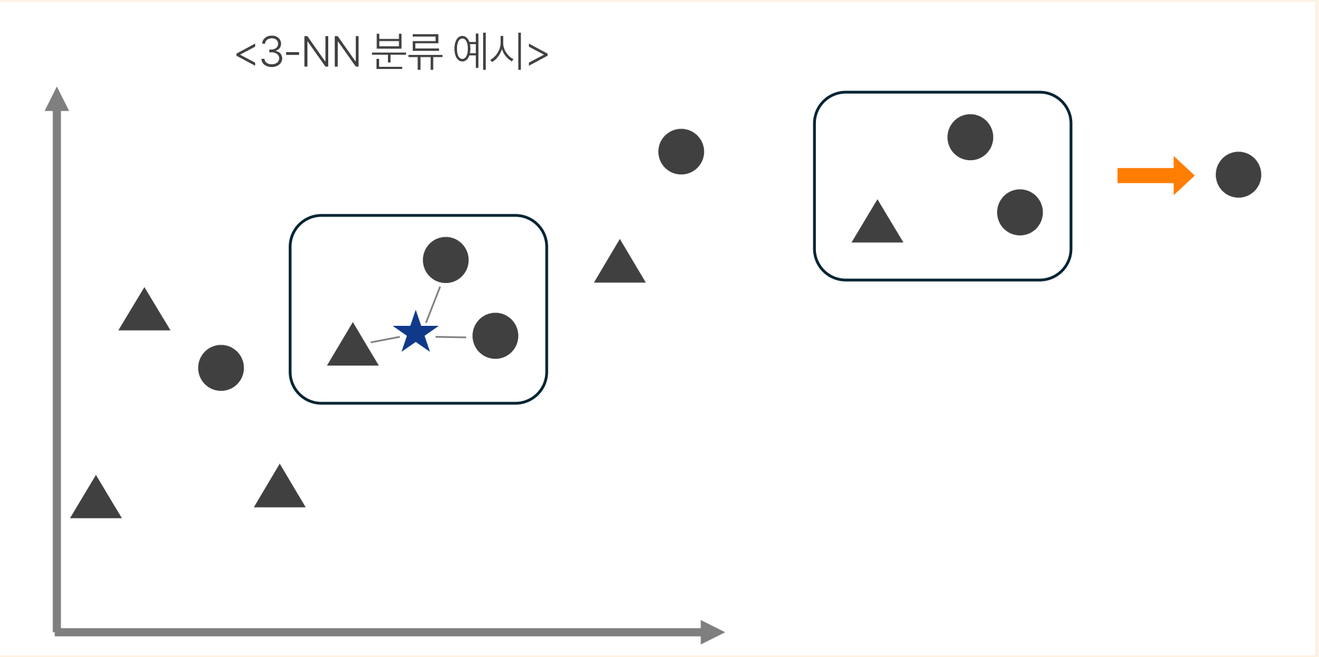

6 k-NN의 예측값 산출

회귀 모델

- 1) 학습 데이터 준비
- 2) 평가 데이터를 기준으로 학습 데이터의 독립변수 기준 가장 가까운 k개의 이웃 탐색
- 3) k개의 이웃의 종속변수를 취합하여 수치를 요약하는 통계량 산출(보통 산술 평균)

※ 가중 평균, 중앙값 또한 사용 가능

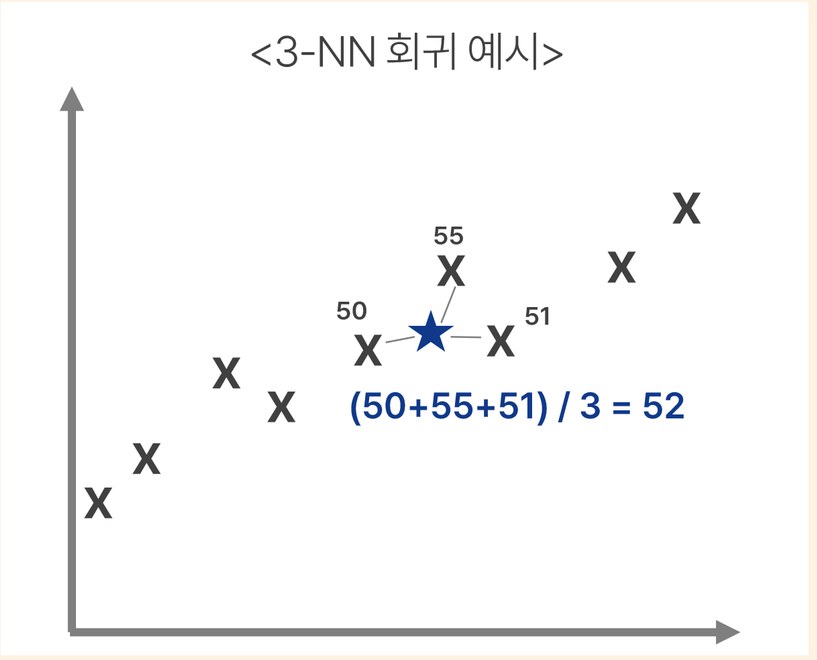

7 k-NN의 평가

성능 평가 – 분류 모델

- 분류모델로 정확도, 정밀도, 재현율, F1-Score 등 종속변수 평가지표 사용 가능

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \times \frac{precision \cdot recall}{precision + recall}$$

※ TP: $True\ Positive$, TN: $True\ Negative$, FP : $False\ Positive$, FN: $False\ Negative$

7 k-NN의 평가

성능 평가 – 회귀 모델

- 회귀모델로 MSE, MAE, RMSE, MAPE 등 종속변수 평가지표 사용 가능

$$\mathrm{MSE} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{n}$$

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100$$

$y_i - \hat{y}_i$: $error$ y_i : 실제값 $\hat{y}_i$: 예측값

8 k-NN 수행 시 고려사항

k값 선정

- k값에 따라 모델의 성능이 크게 바뀌며 상황에 따라 적절한 k값 선정 필요
- 과적합이 우려되는 경우 k값을 증가시키고 과소적합이 우려되는 경우 k값을 감소시킴
- 이진 분류의 경우 k값 홀수 권장

거리 계산 알고리즘의 사용

- 독립변수의 단위 또는 스케일의 영향을 최소화 하기 위해 정규화된 데이터 사용 권장
- Label 인코딩 실시한 범주형 데이터를 독립변수로 사용할 경우 잘못된 계산 가능성 존재

  ※ 범주형 데이터는 원핫 인코딩 권장

9 문제 풀이

Q1. k-NN의 특성에 대한 설명으로 가장 적절하지 않은 것은?

1. k-NN은 인스턴스 기반 학습(instance-based learning)에 속한다.
2. k-NN은 회귀모델과 분류모델이 존재한다.
3. k-NN은 훈련 단계에서 명시적인 모델을 학습한다.
4. k-NN은 비모수적 접근(non-parametric approach)을 사용한다.

9 문제 풀이

Q1. k-NN의 특성에 대한 설명으로 가장 적절하지 않은 것은?

1. k-NN은 인스턴스 기반 학습(instance-based learning)에 속한다.
2. k-NN은 회귀모델과 분류모델이 존재한다.
3. k-NN은 훈련 단계에서 명시적인 모델을 학습한다.
4. k-NN은 비모수적 접근(non-parametric approach)을 사용한다.

해설

k-NN은 훈련 단계에서 명시적인 모델을 학습하지 않으며,
모든 훈련 데이터를 저장하고 예측 시점에서
계산을 수행하는 게으른 학습 방식으로 동작한다.

9 문제 풀이

Q2. k값 선택에 따른 영향에 대한 설명으로 가장 적절한 것은?

1. k값이 클수록 노이즈에 더 민감해진다.
2. k값이 작을수록 과적합(overfitting)이 발생하기 쉽다.
3. k값이 클수록 지역적 패턴을 더 잘 포착한다.
4. k값은 일반적으로 짝수로 설정하는 것이 좋다.

9 문제 풀이

Q2. k값 선택에 따른 영향에 대한 설명으로 가장 적절한 것은?

1. k값이 클수록 노이즈에 더 민감해진다.
2. k값이 작을수록 과적합(overfitting)이 발생하기 쉽다.
3. k값이 클수록 지역적 패턴을 더 잘 포착한다.
4. k값은 일반적으로 짝수로 설정하는 것이 좋다.

해설

k값이 작을수록 소수의 이웃에만 의존하게 되어 노이즈에 민감하고 과적합이 발생하기 쉽다.

9 문제 풀이

Q3. k-NN 회귀에서 예측값을 계산하는 방법으로 보기 어려운 것은?

1. k개 이웃의 종속변수 산술 평균
2. k개 이웃의 종속변수 가중 평균
3. k개 이웃의 종속변수 중앙값
4. k개 이웃의 종속변수 최빈값

9 문제 풀이

Q3. k-NN 회귀에서 예측값을 계산하는 방법으로 보기 어려운 것은?

1. k개 이웃의 종속변수 산술 평균
2. k개 이웃의 종속변수 가중 평균
3. k개 이웃의 종속변수 중앙값
4. k개 이웃의 종속변수 최빈값

해설

연속적인 수치값을 예측해야 하므로 최빈값은
적절하지 않으며, 최빈값은 주로 분류 문제에 사용된다.

9 문제 풀이

Q4. 주변 친구들의 공부 시간과 합격 여부가 다음과 같다고 한다. 만약 공부를 19시간 했다면, 시험은 합격인가 불합격인가?

※ k가 3인 k-NN 분류 모델, 맨하탄 거리 계산법 사용

공부 시간	합격 여부
24	합격
20	합격
15	불합격
12	불합격
30	합격
35	불합격
17	합격

1. 합격
2. 불합격

9 문제 풀이

Q4. 주변 친구들의 공부 시간과 합격 여부가 다음과 같다고 한다. 만약 공부를 19시간 했다면, 시험은 합격인가 불합격인가?

※ k가 3인 k-NN 분류 모델, 맨하탄 거리 계산법 사용

1. 합격
2. 불합격

공부 시간	맨하탄 거리	합격 여부
24	5	합격
20	1	합격
15	4	불합격
12	7	불합격
30	11	합격
35	16	불합격
17	2	합격

해설

공부시간이 19시간인 경우 가장 가까운 3개의 데이터는 (20, 합격), (15, 불합격), (17, 합격)이 되어 최종적으로 "합격"이 최빈값이 된다.

9 문제 풀이

Q5. k-NN에서 데이터 전처리의 중요성에 대한 설명으로 가장 적절한 것은?

1. 범주형 변수는 단순히 1, 2, 3과 같은 숫자로 변환하면 된다.
2. 결측치가 있는 특성은 단순히 평균값으로 대체하면 모든 문제가 해결된다.
3. 정규화와 같은 특성 스케일링은 k-NN 성능에 큰 영향을 미치지 않는다.
4. 특정 독립변수의 값이 큰 경우 거리 계산을 지배할 수 있어 정규화가 필요하다.

9 문제 풀이

Q5. k-NN에서 데이터 전처리의 중요성에 대한 설명으로 가장 적절한 것은?

1. 범주형 변수는 단순히 1, 2, 3과 같은 숫자로 변환하면 된다.
2. 결측치가 있는 특성은 단순히 평균값으로 대체하면 모든 문제가 해결된다.
3. 정규화와 같은 특성 스케일링은 k-NN 성능에 큰 영향을 미치지 않는다.
4. 특정 독립변수의 값이 큰 경우 거리 계산을 지배할 수 있어 정규화가 필요하다.

해설

범주형 데이터는 원핫 인코딩 변환을 권장하고, 결측 대치의 경우 단순 평균 대치를 한다면 전역값을 할당하는 것이 되어 지역적 특성에 민감한 k-NN에 적절하지 않다.
그리고 거리 계산 때문에 정규화를 실시하는 것을 권장한다.