Data Science

Level 2

18. 의사결정 나무

1 의사결정 나무 개요

의사결정 나무(Decision tree)의 정의

- 열성적 학습(eager learning)에 속하는 비모수적 지도학습 알고리즘
- 의사결정 규칙을 나무 구조로 표현하여 분류 또는 회귀 문제를 해결하는 지도학습 알고리즘

관련 용어

- **노드(node)** : 데이터를 담고 있는 상자 또는 주머니
- **링크(link)** : 가지(branch)라고도 하며 노드를 연결하는 선분
- **의사결정 규칙** : 노드의 데이터를 분할하기 위한 if ~ then 형식의 규칙
- **불순도(impurity)** : 노드 내 데이터의 혼잡성 정도를 나타내는 지표

2 의사결정 나무의 목적과 특징

의사결정 나무의 목적

- 새로운 데이터에 대한 분류 또는 회귀 예측 수행
- 데이터 내에 숨겨진 의사결정 규칙과 패턴을 탐지

2 의사결정 나무의 목적과 특징

의사결정 나무의 특징

- 수치형 종속변수는 회귀 나무(Regression tree), 범주형은 분류 나무(Classification tree) 사용
- 의사결정 규칙을 노드와 링크를 조합하여 해석이 용이한 나무 모양의 구조 생성
- 변수 스케일링이나 정규화 불필요
- 데이터 분포에 대한 사전 가정 불필요(비모수적 특성)
- 계단 함수로의 근사로 매끄러운 곡선 관계 표현의 비효율

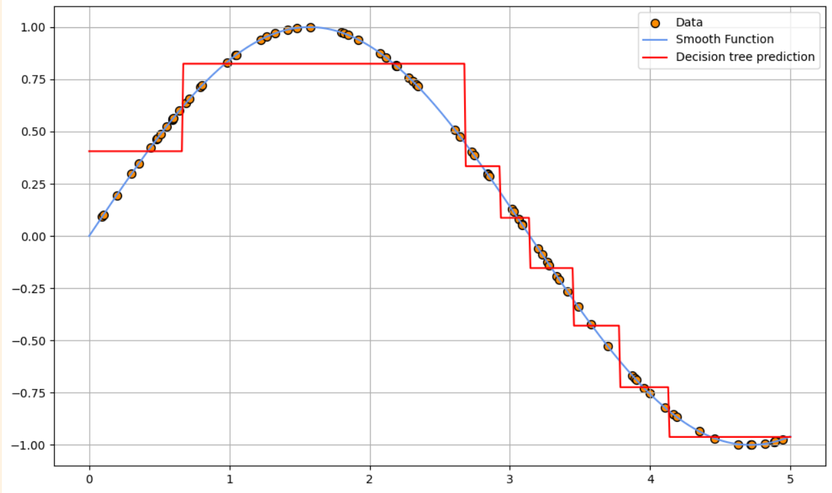

2 의사결정 나무의 목적과 특징

의사결정 나무(모델)의 구조

- 가장 상단의 노드는 뿌리(root) 노드
- 말단(terminal)의 노드는 잎사귀(leaf) 노드
- 상위 노드는 부모(parent) 노드, 하위 노드는 자식(child) 노드
- 첫 번째 자식 노드 위치의 깊이(depth)는 1이며 단계(level)는 2
- 모델의 최대 깊이 값이 클 수록 많은 규칙과 과적합을 수반함

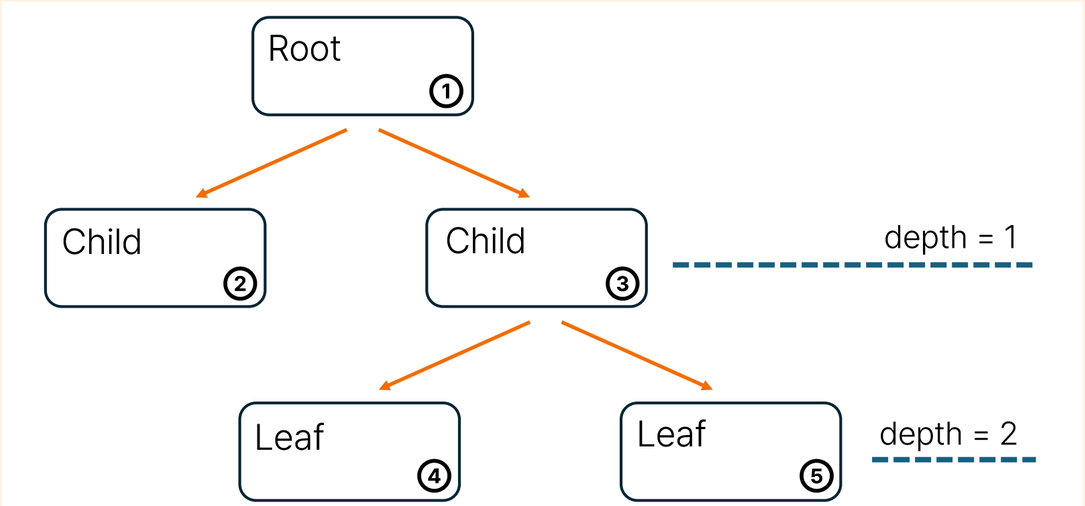

2 의사결정 나무의 목적과 특징

분류 나무(Classification tree)

- 종속변수가 범주형인 모델로 분류 작업을 수행하기 위한 모델
- 이진 분할의 경우 주로 지니 지수를 사용하는 CART(Classification And Regression Trees)알고리즘 사용
- 다중 분할의 경우 정보 획득을 활용하는 C4.5, C5.0 또는 카이제곱 통계량을 사용하는 CHAID 사용
- 말단 노드의 최빈 범주로 최종 분류 결과 결정

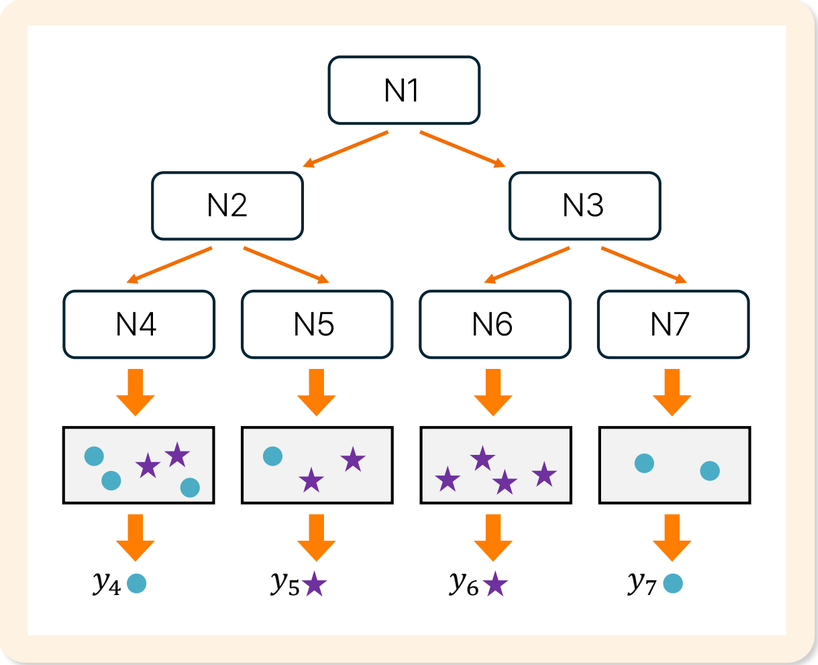

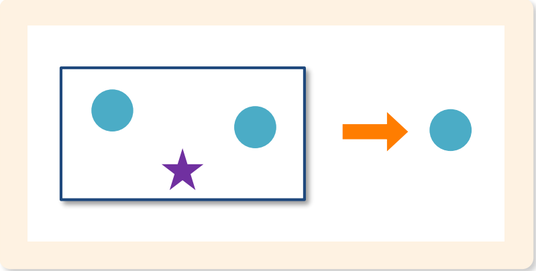

2 의사결정 나무의 목적과 특징

회귀 나무(Regression tree)

- 종속변수가 수치형인 모델로 수치형 데이터 예측을 위한 모델
- 주로 지니 지수를 사용하는 CART(Classification And Regression Trees)알고리즘 사용
- 말단 노드에 할당된 종속변수 값의 산술평균으로 최종 산출값 결정

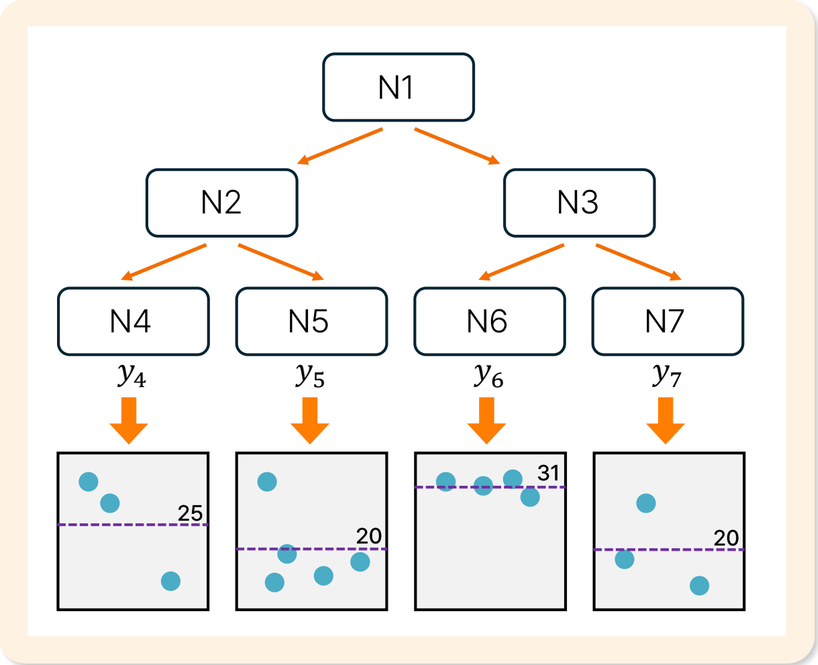

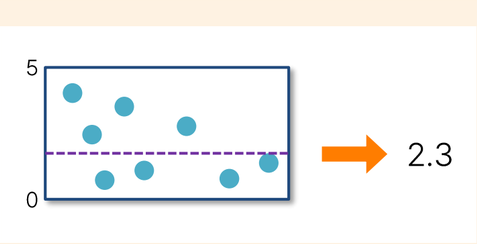

3 의사결정 나무의 쓰임새

분야별 활용

- **제조**: 웨이퍼 품질의 결정에 의사결정 나무 규칙 활용 가능
- **금융**: 신용 대출 거부 시 신용 평가 의사결정 나무 규칙 기반 근거 제시 가능
- **일반**: 암묵지(tacit knowledge)를 명시지(explicit knowledge)로 변환

4 노드의 분할과 나무의 성장

불순도(Impurity)의 평가

- 노드 내 범주가 두 종류 이상인 경우 노드를 분할해야 할 수 있음
- 노드 내 범주의 혼재 정도(데이터의 혼잡성 정도)를 수치화 하기 위해 불순도 개념 차용
- 불순도의 수치화를 위해 엔트로피(entropy) 또는 지니(gini) 사용

  ※ 지니는 Gini Impurity, Gini Index 라고도 함

4 노드의 분할과 나무의 성장

엔트로피의 계산

- 최솟값은 0, 최댓값은 1(이진 분류 기준)이며 값이 클 수록 불순도가 높음을 의미
- 노드에 단일 범주만 존재하는 경우 0, 2개 이상의 범주 구성비가 같은 경우 최대

$$\mathrm{E}(t) = -\sum_{i=1}^{C} p_i \log_2 p_i$$

(C: 분류 범주 개수, p_i: 특정 범주의 구성비)

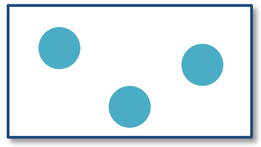

$$-\frac{3}{3}\log_2\frac{3}{3} - \frac{0}{3}\log_2\frac{0}{3} = 0 - 0 = 0$$

$$-\frac{2}{4}\log_2\frac{2}{4} - \frac{2}{4}\log_2\frac{2}{4} = 0.5 + 0.5 = 1$$

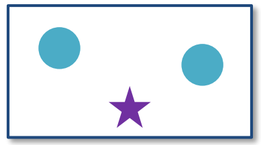

$$-\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3} = 0.38997 + 0.52832 = 0.91829$$

4 노드의 분할과 나무의 성장

지니의 계산

- 최솟값은 0, 최댓값은 0.5(이진 분류 기준)이며 값이 클 수록 불순도가 높음을 의미
- 노드에 단일 범주만 존재하는 경우 0, 2개 이상의 범주 구성비가 같은 경우 최대

$$G(t) = 1 - \sum_{i=1}^{C} p_i^2$$

(C: 분류 범주 개수, p_i: 특정 범주의 구성비)

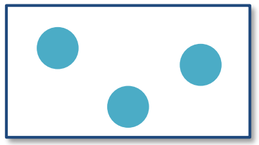

$$1 - \left(\frac{3}{3}\right)^2 - \left(\frac{0}{3}\right)^2 = 1 - 1 - 0 = 0$$

$$1 - \left(\frac{2}{4}\right)^2 - \left(\frac{2}{4}\right)^2 = 1 - 0.25 - 0.25 = 0.5$$

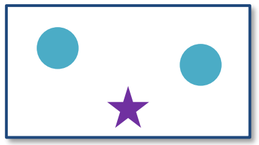

$$1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = 1 - \frac{4}{9} - \frac{1}{9} = \frac{4}{9}$$

4 노드의 분할과 나무의 성장

정보 이득(Information gain)

- 분기 이전 부모 노드의 불순도와 분기 이후 자식 노드의 불순도의 가중합간 차이
- 큰 정보 이득 값은 불순도의 효과적 감소를 뜻하며 분류가 충분히 잘 된 것으로 판단
- 정보이득은 지니 또는 엔트로피로 계산 가능
- 부모 노드의 불순도가 2이고 분기 이후 0.5로 줄었다면 정보 이득은 1.5

$$Information\ Gain = Entropy(N_P) - \sum_{i=1}^{n} w_i \times Entropy(N_{Ci})$$

N_p : 부모 노드
N_{Ci} : i 번째 자식 노드
w_i : i 번째 자식노드의 가중치(노드 크기 비례)

4 노드의 분할과 나무의 성장

정보 이득의 계산

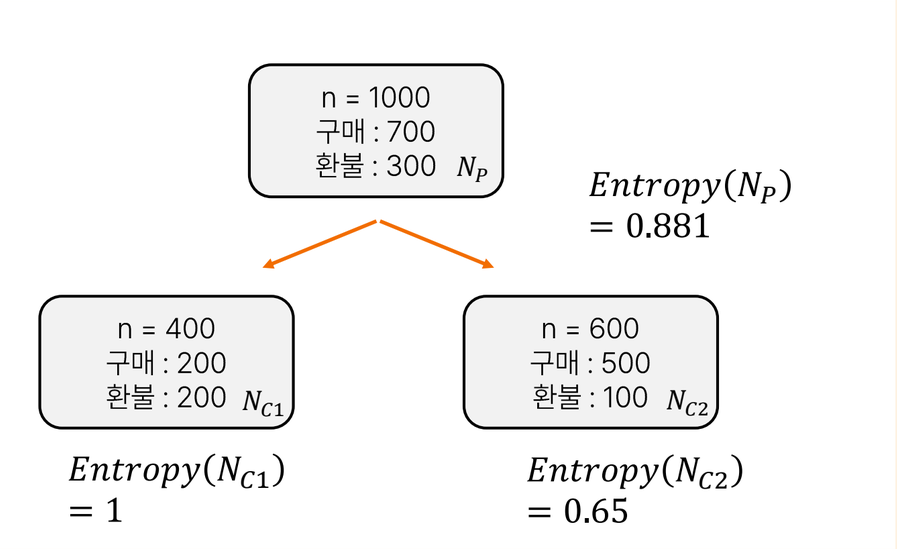

$$※\ \mathrm{E}(t) = -\sum_{i=1}^{c} p_i \log_2 p_i$$

$$IG = Entropy(N_P) - \sum_{i=1}^{n} w_i \times Entropy(N_{Ci})$$

$$= 0.881 - \left(\left(\frac{400}{1000}\right) \times 1 + \left(\frac{600}{1000}\right) \times 0.65\right) = 0.881 - 0.79 = 0.091$$

5 과적합 예방 조치

가지치기(Pruning)

- 학습된 모델을 나무라고 했을 때 해당 나무의 가지를 쳐내어 보다 단순한 모델을 얻는 과정
- 사전 가지치기(pre-pruning) : 모델링 이전에 성장에 제한 값을 설정하여 나무의 완전 성장 제한
- 사후 가지치기(post-pruning) : 모델링 이후에 특정 지표를 기준으로 일부 가지를 쳐내는 방법

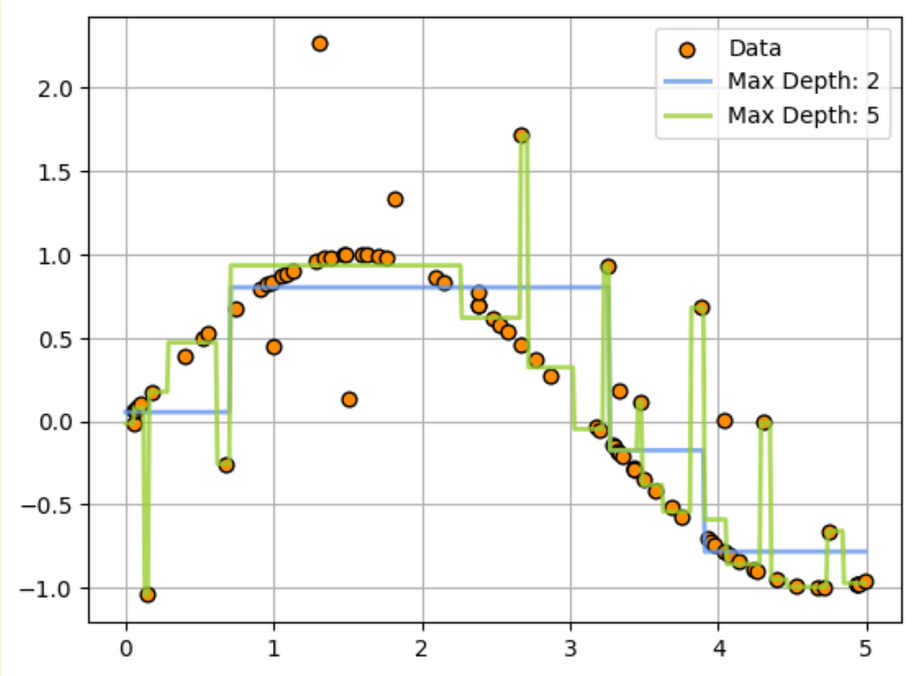

5 과적합 예방 조치

사전 가지치기의 활용

- **최소 표본 수 제한**: 노드 분할을 위한 최소 표본 수, 말단 노드의 최소 표본 수
- **깊이 제한**: 트리의 최대 깊이, 최대 말단 노드 수
- **불순도 임계값**: 노드 분할을 위한 최소 불순도 감소량

6 의사결정 나무의 해석

분류 나무 해석 예시

- 뿌리 노드는 "공부 시간" 독립변수의 값 20을 기준으로 분할되며 20시간 이상인 경우 ★로 분류 됨

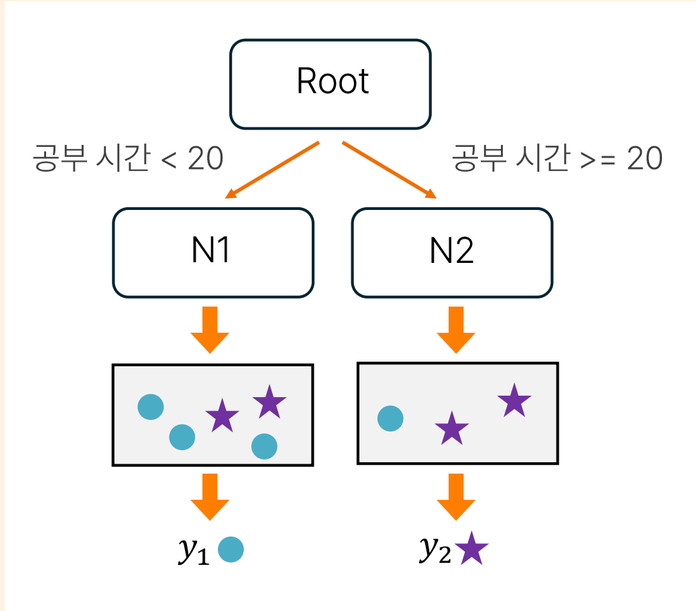

7 의사결정 나무의 예측값 산출

분류 나무

- 뿌리 노드 → 조건 평가 → 경로 선택 → 말단 노드 도달 → 범주 반환

◆ 학습 단계

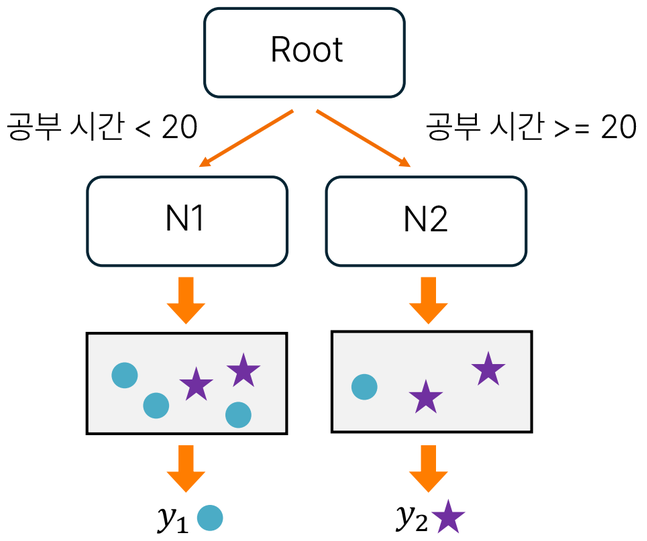

◆ 예측 단계

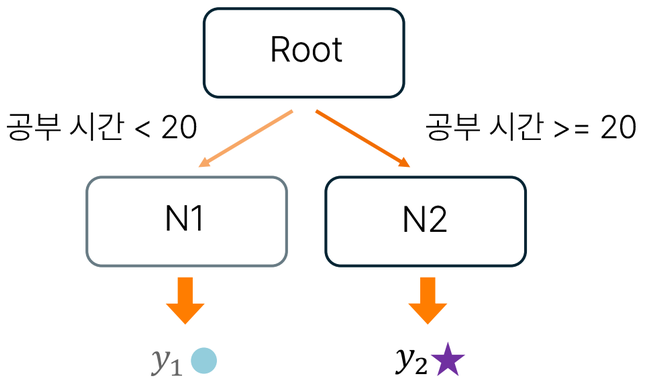

※ 공부 시간이 25시간일 경우 ★로 최종 분류

8 의사결정 나무의 예측값 산출

회귀 나무

- 뿌리 노드 → 조건 평가 → 경로 선택 → 말단 노드 도달 → 평균 반환

◆ 학습 단계

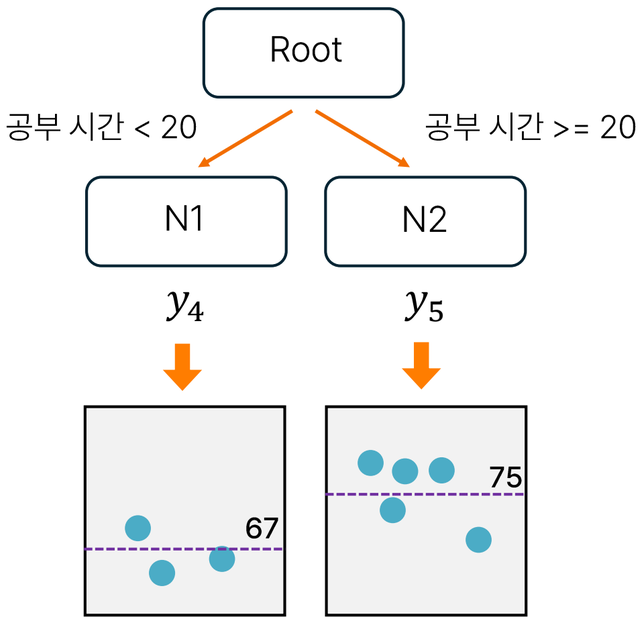

◆ 예측 단계

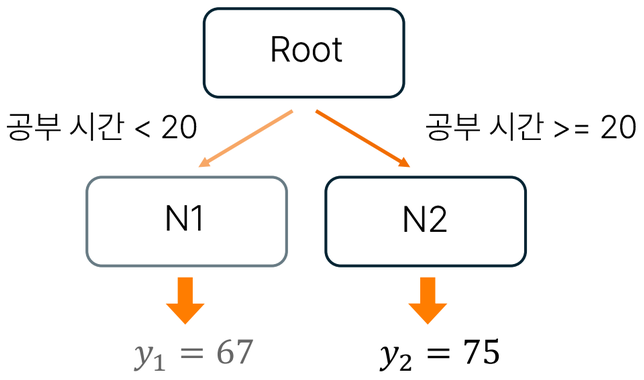

※ 공부 시간이 25시간일 경우 75점으로 예측

9 의사결정 나무의 평가

성능 평가 – 분류 나무

- 분류모델로 정확도, 정밀도, 재현율, F1-score 등 종속변수 평가지표 사용 가능

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \times \frac{precision \cdot recall}{precision + recall}$$

※ TP : True Positive, TN : True Negative, FP : False Positive, FN : False Negative

9 의사결정 나무의 평가

성능 평가 – 회귀 나무

- 회귀모델로 MSE, MAE, RMSE, MAPE 등 종속변수 평가지표 사용 가능

$$\mathrm{MSE} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{n}$$

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100$$

$y_i - \hat{y}_i$: $error$ y_i : 실제값 $\hat{y}_i$: 예측값

10 의사결정 나무 수행 시 고려사항

카디널리티(Cardinality)가 높은 범주형 변수 처리

- 소수 범주를 "기타" 등으로 취합 시 모델 간결화와 해석 용이성 확보 가능
- 각 범주간 관계(계층, 유사)를 고려한 범주 통합

※ 카디널리티 : 중복되지 않는 고유한 값의 개수

11 문제 풀이

Q1. 회귀나무에서 새로운 입력 데이터에 대한 예측값 산출 방법으로 가장 적절한 것은?

1. 말단 노드의 학습 표본의 중앙값(median)
2. 말단 노드의 학습 표본의 최빈값(mode)
3. 말단 노드의 학습 표본의 평균값(mean)
4. 말단 노드에서 가장 가까운 학습 표본의 값

11 문제 풀이

Q1. 회귀나무에서 새로운 입력 데이터에 대한 예측값 산출 방법으로 가장 적절한 것은?

1. 말단 노드의 학습 표본의 중앙값(median)
2. 말단 노드의 학습 표본의 최빈값(mode)
3. 말단 노드의 학습 표본의 평균값(mean)
4. 말단 노드에서 가장 가까운 학습 표본의 값

해설

회귀나무에서는 말단 노드에 도달한 훈련 표본의 평균값을 예측값으로 사용한다. 그리고 최빈값의 경우 범주형 종속변수에 대해 사용하는 통계량이다.

11 문제 풀이

Q2. 다음 설명 중 올바른 것은?

1. 회귀나무는 목표 변수가 연속형이므로 이진 분류만 가능하다.
2. CART는 이진 분할을 사용하고, C4.5는 다중 분할을 사용한다.
3. 범주형 독립변수를 사용하는 회귀나무에서는 다중 분할이 불가능하다.
4. 분할 기준(지니 vs 엔트로피)과 분할 방식(이진 vs 다중)은 항상 연동된다.

11 문제 풀이

Q2. 다음 설명 중 올바른 것은?

1. 회귀나무는 목표 변수가 연속형이므로 이진 분류만 가능하다.
2. CART는 이진 분할을 사용하고, C4.5는 다중 분할을 사용한다.
3. 범주형 독립변수를 사용하는 회귀나무에서는 다중 분할이 불가능하다.
4. 분할 기준(지니 vs 엔트로피)과 분할 방식(이진 vs 다중)은 항상 연동된다.

해설

분할 기준과 분할 방식은 독립적 개념이며 범주형 독립변수로도 다중 분할이 가능하다.

11 문제 풀이

Q3. 의사결정나무에서 과적합이 발생했음을 나타내는 가장 명확한 징후는?

1. 트리의 깊이가 10을 초과하는 경우
2. 훈련 정확도가 95%를 넘는 경우
3. 훈련 데이터 성능과 검증 데이터 성능의 현저한 격차
4. 말단 노드 개수가 전체 표본 수의 10%를 초과하는 경우

11 문제 풀이

Q3. 의사결정나무에서 과적합이 발생했음을 나타내는 가장 명확한 징후는?

1. 트리의 깊이가 10을 초과하는 경우
2. 훈련 정확도가 95%를 넘는 경우
3. 훈련 데이터 성능과 검증 데이터 성능의 현저한 격차
4. 말단 노드 개수가 전체 표본 수의 10%를 초과하는 경우

해설

훈련 정확도는 과적합 여부와 관계없이 높을 수 있으며,
과적합 판단의 핵심은 학습 데이터를 기반으로 한 성능과
학습 데이터가 아닌 나머지 데이터와의 성능의 차이이다.

11 문제 풀이

Q4. 표본 크기가 100, Entropy가 0.3인 노드를 A 속성으로 분할한 경우 그 결과가 다음과 같다. 이때 정보 이득은 얼마인가?

1. 0
2. 0.16
3. 0.15
4. 0.14

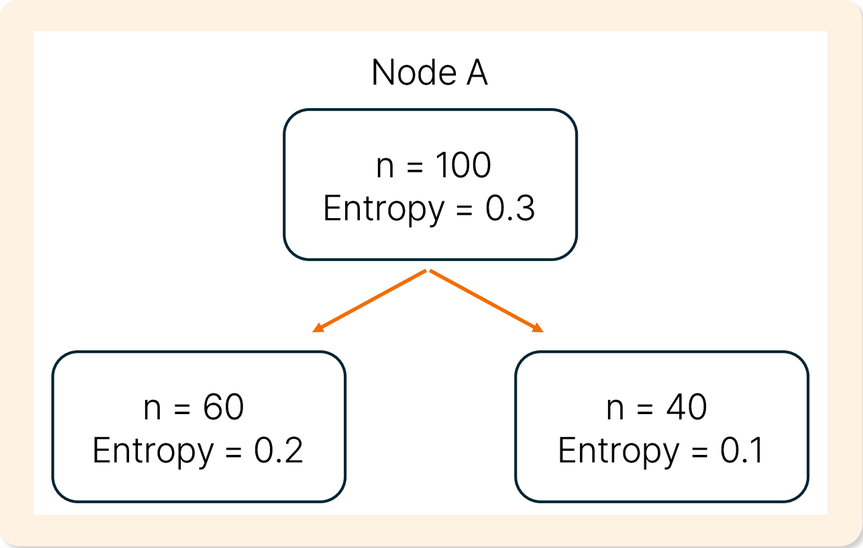

11 문제 풀이

Q4. 표본 크기가 100, Entropy가 0.3인 노드를 A 속성으로 분할한 경우 그 결과가 다음과 같다. 이때 정보 이득은 얼마인가?

1. 0
2. 0.16
3. 0.15
4. 0.14

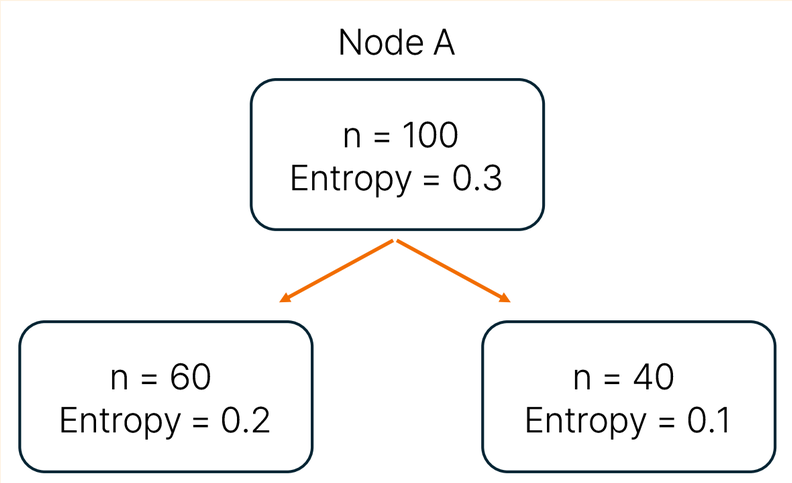

$$IG = 0.3 - \left(\frac{60}{100} \times 0.2 + \frac{40}{100} \times 0.1\right)$$

해설

각 자식노드의 가중치는 부모노드와 자식노드의 표본 수를 기준으로 산정되며 각각 0.6, 0.4가 된다. 그리하여 최종적으로 정보 이득은 0.14가 된다.

11 문제 풀이

Q5. 불균형 이진 분류 문제(양성 5%, 음성 95%)에서 의사결정나무 모델의 성능을 평가할 때 가장 부적절한 지표는?

1. 정확도(accuracy)
2. 정밀도(precision)
3. 재현율(recall)
4. F1-score

11 문제 풀이

Q5. 불균형 이진 분류 문제(양성 5%, 음성 95%)에서 의사결정나무 모델의 성능을 평가할 때 가장 부적절한 지표는?

1. 정확도(accuracy)
2. 정밀도(precision)
3. 재현율(recall)
4. F1-score

해설

정확도의 경우 분자의 값이 TP와 TN의 합이기 때문에
TP가 0과 같이 매우 작더라도 TN의 값이 크다면,
성능이 좋은 모델이라고 오판할 수 있다.