Data Science

Level 2

19. 나이브베이즈

1 나이브베이즈 개요

나이브베이즈(Naïve bayes)의 정의

- 베이즈 정리를 기반으로 한 확률적 분류 알고리즘
- 특성간 조건부 독립성을 가정하여 분류를 수행하는 지도학습 방법 중 하나
  ※ 실제로는 특성간 상관관계가 존재할 수 있지만, 모든 특성이 서로 독립적이라고 가정하여 "Naïve" 라고 함

관련 용어

- **베이즈 정리(bayes' theorem)** : 두 확률 변수의 사전확률과 사후확률 사이의 관계를 나타내는 정리
- **사전 확률(prior probability)** : 관측 데이터 분석 이전에 각 범주가 나타날 확률
- **사후 확률(posterior probability)** : 독립변수 기반 연산 후 각 범주에 속할 확률
- **주변 확률(marginal probability)** : 결합확률에서 관심 없는 변수를 제거(marginalize out)하여 얻는 확률

2 나이브베이즈의 목적과 특징

나이브베이즈 분류기의 유형

- 가우시안 나이브베이즈(gaussian naïve bayes) : 연속형 특성이 각 클래스별로 정규분포를 따른다고 가정
- 다항 나이브베이즈(multinomial naïve bayes) : 텍스트 분류의 단어 빈도와 같은 카운트 데이터에 적합
- 베르누이 나이브베이즈(bernoulli naïve bayes) : 특성의 존재/부재를 나타내는 이진 데이터에 적합

2 나이브베이즈의 목적과 특징

장점과 한계

- 상대적으로 적은 학습 데이터로도 좋은 성능을 보여줌
- 확률적 출력으로 결과 해석 용이
- 실제 데이터에서 특성 간 상관관계가 존재하는 경우가 많으나 이를 독립으로 취급
- 이상치가 확률분포 추정을 왜곡시켜 성능을 저하시킬 수 있음

3 나이브베이즈의 쓰임새

분야별 활용

- **자연어처리**: 스팸 메일 필터링, 감정 분석
- **의료**: 증상 데이터를 기반으로 한 질병 예측
- **금융**: 금융 거래 이상 패턴 분석

4 (보충) 베이즈 정리

베이즈 정리의 구성 요소

- $P(H|E)$, **사후확률** : 사건 E가 관측된 후 사건 H가 참일 확률(최종적으로 구하고자 하는 값)
- $P(E|H)$, **우도** : 가설 H 하에서 증거 E가 관측될 확률
- $P(H)$, **사전 확률** : 증거 E를 관측하기 전 가설 H에 대한 초기 믿음
- $P(E)$, **주변확률** : 증거 E가 관측될 전체 확률

※ 주변확률(marginal probability) : 다른 변수들의 값에 관계없이 특정 변수 하나만의 확률

$$\mathrm{P}(H|E) = \frac{P(H \cap E)}{\mathrm{P}(E)} = \frac{P(H)\,P(E|H)}{\mathrm{P}(E)}$$

5 나이브베이즈 분류기 연산 예시

다항 나이브베이즈 기준 사후확률 계산

- 문서(document)를 특정 클래스(c_i)로 분류하는 경우 사후확률의 계산
- 새로운 뉴스 기사가 발행되었을 때 과학(c_1), 문화(c_2), 경제(c_3) 범주 중 하나에 속할 확률 계산
- $argmax$는 뒤에 오는 (확률)값이 최대가 되도록 하는 범주값을 반환하도록 함

$$P(c_1|docu.) = \frac{P(c_1, docu.)}{P(docu.)} = \frac{P(docu.|c_1)P(c_1)}{P(docu.)}$$

$$C_{MAP} = \underset{c = C}{argmax}\ P(c|docu.)$$

$$= \underset{c = C}{argmax}\ \frac{P(docu.|c)P(c)}{P(d)}$$

	과학	문화	경제
P	0.86	0.23	0.45

※ docu : 문서(document)를 간결하게 표기한 약식 형태

5 나이브베이즈 분류기 연산 예시

다항 나이브베이즈 기준 사후확률 계산(상세)

- 문서의 우도 산출을 위해 문서의 구성 요소인 단어를 기준으로 접근
- 각 단어의 등장 확률은 독립(independent)으로 간주하며 등장 순서 또한 무시

※ 실제로는 문법, 사용 용례 등 다양한 요인으로 서로 관계가 있는 경우가 많음

$$P(docu.|c_k) = \prod_i P(w_i|c_k) = P(w_1|c_k) \times P(w_2|c_k) \times \ \dots \ \times P(w_i|c_k)$$

$$i, k \in \mathbb{N}$$

파이로 읽음.
원주율(π)의 대문자

※ $P(w_1|c_1)$: 과학(c_1) 카테고리에서 초전도체(w_1) 단어가 등장할 확률

6 존재하지 않는 원소에 대한 처리

라플라스 평활화(Laplace smoothing)

- 학습 데이터에 존재하지 않는 원소의 경우 확률이 0이 되기 때문에 이에 대한 조치 필요
- 원소의 등장 횟수에 모두 1을 더하여 부존재 원소에 대한 확률 연산 문제 극복
- 원소 또는 단어의 집합을 V라고 할 때 그 카디널리티(cardinality)는 $|V|$

$$P(w_i|c_i) = \frac{count(w_i, c_i)}{\sum_j count(w_j, c_i)} \rightarrow P(w_i|c_i) = \frac{count(w_i, c_i) + 1}{\sum_j count(w_j, c_i) + |V|}$$

7 나이브베이즈의 예측값 산출

스팸메일 분류 예시를 통한 예측값 산출의 이해

- 텍스트 기반 스팸 메일/정상 메일 분류 예시
- 메일 내용 : 안녕하세요 이번 감사 이벤트 당첨 축하 드립니다.

※ $P(spam)=P(email)=0.5$ 라고 가정

$$P(spam|email) = \frac{P(spam, email)}{P(email)} = \frac{P(email|spam)P(spam)}{P(email)}$$

단어	P(단어|스팸O)	P(단어|스팸X)
축하	0.3	0.05
당첨	0.4	0.01
감사	0.1	0.6
이번	0.05	0.1

※ 기존 이메일(train set)에서 확보한 데이터

$$P(\text{스팸}O|email) = 6 \times 10^{-4} = 0.3 \times 0.4 \times 0.1 \times 0.05$$

$$P(\text{스팸}X|email) = 3 \times 10^{-5} = 0.05 \times 0.01 \times 0.6 \times 0.1$$

$$P(\text{스팸}O|email) > P(\text{스팸}X|email)$$

$$\therefore email \rightarrow spam!$$

8 나이브베이즈 분류기의 평가

성능 평가 – 분류 나무

- 분류모델로 정확도, 정밀도, 재현율, F1-Score 등 종속변수 평가지표 사용 가능

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \times \frac{precision \cdot recall}{precision + recall}$$

※ TP : True Positive, TN : True Negative, FP : False Positive, FN : False Negative

9 나이브베이즈 수행 시 고려사항

데이터 전처리 고려사항

- 확률 분포 추정에 큰 영향을 미치는 이상치/결측치를 적절한 방법으로 처리 필요
- 확률 계산 왜곡 방지를 위한 강한 상관관계를 보이는 독립변수 제거 등 별도 처리 권장

  ※ 연소득, 월소득, 일소득 과 같은 밀접한 변수의 경우 "연소득" 변수만 사용하는 등 별도 처리 권장
- 과신(overconfidence) 문제 : 중복된 정보가 많은 경우 모델이 예측에 대해 지나치게 확신

10 문제 풀이

Q1. 나이브베이즈 분류기에서 조건부 독립성 가정이 위반되었을 때 발생할 수 있는 문제로 가장 적절하지 않은 것은?

1. 상관관계가 높은 특성들이 중복된 정보를 제공하여 확률 계산이 왜곡된다.
2. 모델이 예측에 대해 과도하게 확신하는 과신(overconfidence) 현상이 나타난다.
3. 특성 간 상호작용 효과를 무시하여 실제 데이터 패턴을 제대로 포착하지 못한다.
4. 사전확률 추정 부정확으로 범주별 기본 발생 빈도를 잘못 계산한다.

10 문제 풀이

Q1. 나이브베이즈 분류기에서 조건부 독립성 가정이 위반되었을 때 발생할 수 있는 문제로 가장 적절하지 않은 것은?

1. 상관관계가 높은 특성들이 중복된 정보를 제공하여 확률 계산이 왜곡된다.
2. 모델이 예측에 대해 과도하게 확신하는 과신(overconfidence) 현상이 나타난다.
3. 특성 간 상호작용 효과를 무시하여 실제 데이터 패턴을 제대로 포착하지 못한다.
4. 사전확률 추정 부정확으로 범주별 기본 발생 빈도를 잘못 계산한다.

해설

조건부 독립성 가정 위반은 특성 간 상관관계 문제이며,
사전확률은 각 범주의 발생 빈도로 특성 간 독립성과는 별개의 개념

10 문제 풀이

Q2. 부품 품질 분류를 위해 나이브베이즈를 사용한다고 할 때, 다음 조건에서 불량품으로 분류될 사후확률은?

사전확률 : P(불량) = 0.1, P(정상) = 0.9
온도가 높을 때 : P(온도=높음|불량) = 0.8, P(온도=높음|정상) = 0.2
압력이 높을 때 : P(압력=높음|불량) = 0.7, P(압력=높음|정상) = 0.3
현재 측정값 : 온도=높음, 압력=높음

1. 0.16
2. 0.51
3. 0.30
4. 0.84

10 문제 풀이

Q2. 부품 품질 분류를 위해 나이브베이즈를 사용한다고 할 때, 다음 조건에서 불량품으로 분류될 사후확률은?

사전확률 : P(불량) = 0.1, P(정상) = 0.9
온도가 높을 때 : P(온도=높음|불량) = 0.8, P(온도=높음|정상) = 0.2
압력이 높을 때 : P(압력=높음|불량) = 0.7, P(압력=높음|정상) = 0.3
현재 측정값 : 온도=높음, 압력=높음

1. 0.16
2. 0.51
3. 0.30
4. 0.84

해설

조건은 온도와 압력이 모두 높은 것이고, 사후확률의 분모는
전체 증거 확률로 불량과 정상의 가중 우도를 합해서 구할 수 있다.
즉, 전체 증거 확률 0.11은 0.056과 0.054를 합해서 얻을 수 있다.

10 문제 풀이

Q3. 다음 중 클래스 불균형 문제가 있는 데이터셋에서 나이브베이즈 분류기의 성능을 평가할 때 가장 부적절한 지표는?

1. Accuracy
2. F1-Score
3. AUC-ROC
4. RMSE

10 문제 풀이

Q3. 다음 중 클래스 불균형 문제가 있는 데이터셋에서 나이브베이즈 분류기의 성능을 평가할 때 가장 부적절한 지표는?

1. Accuracy
2. F1-Score
3. AUC-ROC
4. RMSE

해설

1~3번의 보기는 모두 분류모델에 사용하는 평가지표이지만,
RMSE는 회귀모델에 사용하는 오차기반 평가지표이다.

10 문제 풀이

Q4. 제조공정에서 나이브베이즈 분류기를 활용할 때, 다음 특성들 중 조건부 독립성 가정을 가장 심각하게 위반할 것으로 보이는 조합은?

1. 작업자 ID, 작업 시간대, 생산 라인 번호
2. 생산품 지름, 생산품 부피, 생산품 높이
3. 재료 종류, 열처리 온도, 냉각 시간
4. 검사 일자, 검사자, 품질 등급

10 문제 풀이

Q4. 제조공정에서 나이브베이즈 분류기를 활용할 때, 다음 특성들 중 조건부 독립성 가정을 가장 심각하게 위반할 것으로 보이는 조합은?

1. 작업자 ID, 작업 시간대, 생산 라인 번호
2. 생산품 지름, 생산품 부피, 생산품 높이
3. 재료 종류, 열처리 온도, 냉각 시간
4. 검사 일자, 검사자, 품질 등급

해설

생산품 부피는 지름과 높이의 기하학적 관계로 계산될 가능성이 높아
조건부 독립성 가정을 가장 심각하게 위반할 것으로 판단됨

10 문제 풀이

Q5. 베이즈 정리에서 P(H|E) = P(E|H) × P(H) / P(E)에 대한 설명으로 옳은 것은?

1. P(H)는 우도(likelihood)로 가설 H 하에서 증거 E가 관측될 확률이다.
2. P(E|H)는 사전확률(prior probability)로 증거를 보기 전 가설에 대한 믿음이다.
3. P(E)는 주변확률(marginal probability)로 모든 가능한 가설에 대한 가중평균이다.
4. P(H|E)는 사후확률이 0.5가 되도록 보장한다.

10 문제 풀이

Q5. 베이즈 정리에서 P(H|E) = P(E|H) × P(H) / P(E)에 대한 설명으로 옳은 것은?

1. P(H)는 우도(likelihood)로 가설 H 하에서 증거 E가 관측될 확률이다.
2. P(E|H)는 사전확률(prior probability)로 증거를 보기 전 가설에 대한 믿음이다.
3. P(E)는 주변확률(marginal probability)로 모든 가능한 가설에 대한 가중평균이다.
4. P(H|E)는 사후확률이 0.5가 되도록 보장한다.

해설

P(E)는 주변확률(marginal probability)로 모든 가능한 가설을 고려했을 때 증거 E가 관측될 전체 확률이다. 그리고 확률의 합이 1이 되도록 하는 정규화 상수라고도 한다.