Data Science

Level 2

20. k-Means 군집분석

1 k-Means 군집분석 개요

k-Means 군집분석의 정의

- 비지도 학습(unsupervised learning)에 속하는 분할 기반 군집분석 알고리즘
- 데이터를 k개의 군집(cluster)으로 분할하여 각 데이터 포인트를 가장 가까운 중심점(centroid)에 할당하는 기법

관련 용어

- **군집분석(cluster analysis)**
  : 라벨이 없는 데이터에서 유사한 특성을 가진 데이터들을 그룹으로 묶는 비지도 학습 방법
- **중심점(centroid)**
  : 각 군집의 중심에 위치하는 점으로, 해당 군집에 속한 모든 데이터 포인트들의 평균 좌표
- **분할 기반 클러스터링(partitioning-based clustering)**
  : 전체 데이터를 사전에 정의된 k개의 군집으로 분할하는 클러스터링 방법

2 k-Means 군집분석의 목적과 특징

k-Means 군집분석의 목적

- 데이터에 숨겨진 구조와 패턴을 발견하여 데이터의 본질적 특성 파악
- 데이터를 유사한 특성별로 그룹화하여 도메인 지식 기반 해석 및 응용(품질 세분화 등)
- 후속 분석을 위한 데이터 그룹화 및 정리

k-Means 군집분석의 특징

- 모델링 전 군집 개수(k) 지정 필요
- 중심점 계산에 산술평균을 사용하므로 이상치(outlier)에 민감
- 최초의 중심점 초기값은 임의의 위치
- 반복 연산을 통한 최적화

3 k-Means 군집분석의 쓰임새

분야별 활용

- **제조업 및 품질관리** : 불량품 분류, 예측 정비 등
- **마케팅 및 고객 분석** : 고객 세분화, 시장 세분화, 추천 시스템 등
- **교통 및 물류** : 교통 패턴 분석, 배송 최적화 등
- **에너지 및 환경** : 에너지 소비 패턴, 환경 모니터링 등

4 k-Means 군집분석의 동작

알고리즘 동작 절차

- **1) 초기화**: 임의의 k개의 중심점 위치 선정
- **2) 할당**: 중심점과 각 데이터 포인트간 거리를 계산하고 가장 가까운 중심점을 가진 군집에 할당
- **3) 업데이트**: 각 군집에 할당된 데이터 포인트의 평균으로 새로운 중심점 좌표 계산
- **4) 수렴 확인**: 중심점의 변화가 임계값 이하 또는 최대 반복 횟수에 도달 시 종료

※ 종료 실패 시 "할당" 단계로 되돌아 가서 반복

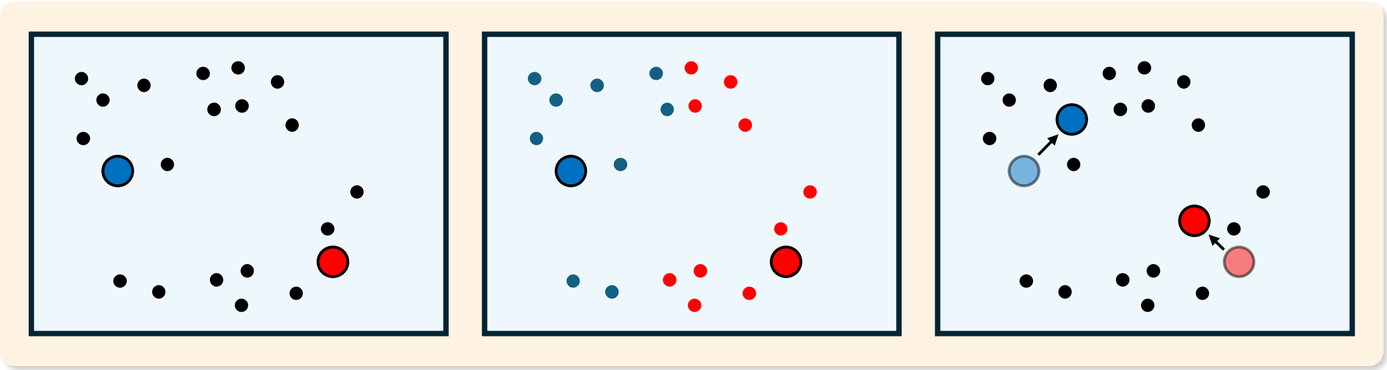

5 k-Means 군집분석의 해석

중심점 좌표 기반 해석

- 각 중심점의 좌표값을 기반으로 그 특성 파악
- 특정 군집의 중심점의 좌표값과 다른 군집의 좌표값을 상대 비교하여 특성 파악
- 중심점 좌표의 해석을 통해 각 군집을 설명하는 명칭 또는 해설 부여 권장

군집	두께오차	표면조도	평탄도	결정성	오염도
1	-0.2	1.2	0.8	0.997	1.8
2	0.2	2.8	1.9	0.989	4.2
3	-2.9	6.4	4.7	0.962	12.8

군집1 : 프리미엄 품질군

군집2 : 표준 품질군

군집3 : 불량/개선 필요군

5 k-Means 군집분석의 해석

군집 타당성 지표(Clustering validity index)

- 최적의 군집 개수 선정과 서로 다른 군집화 방법의 성능 비교를 위해 사용되는 객관적 평가 기준
- 군집 내부의 응집도(intra-cluster cohesion)와 군집간 분리도(inter-cluster separation)를 중요시 함
- 관련 하여 실루엣 분석(silhouette analysis)과 Dunn Index가 있음

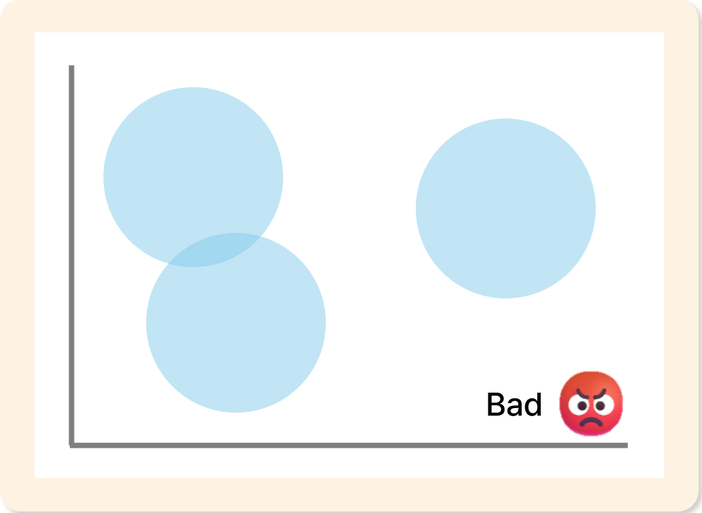

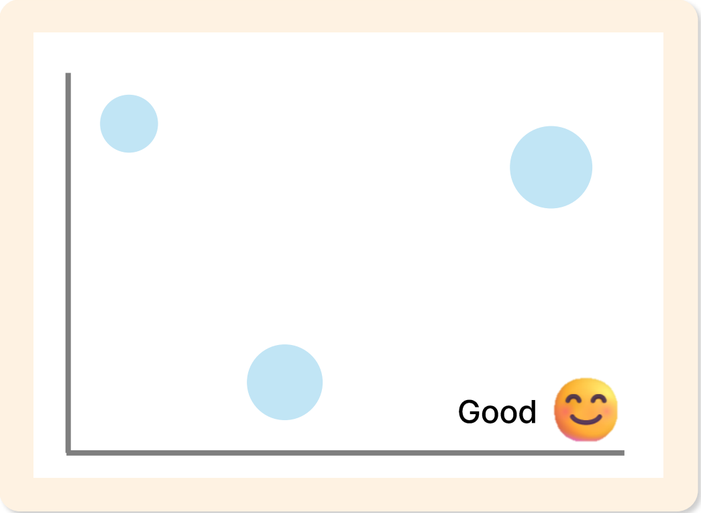

5 k-Means 군집분석의 해석

군집 타당성 지표 – 실루엣 점수(Silhouette score)

- 실루엣 분석(silhouette analysis)에서 계산하는 점수로 클수록 좋음
- 자신의 군집의 특정원소와 각 원소 간의 거리 평균과 타 군집 원소 간의 거리 평균을 기반으로 산출
- 실루엣 계수는 데이터 포인트별로 산출되며 실루엣 점수는 모든 계수의 산술 평균 값
- 실루엣 계수와 점수는 -1에서 1사이의 값을 가짐

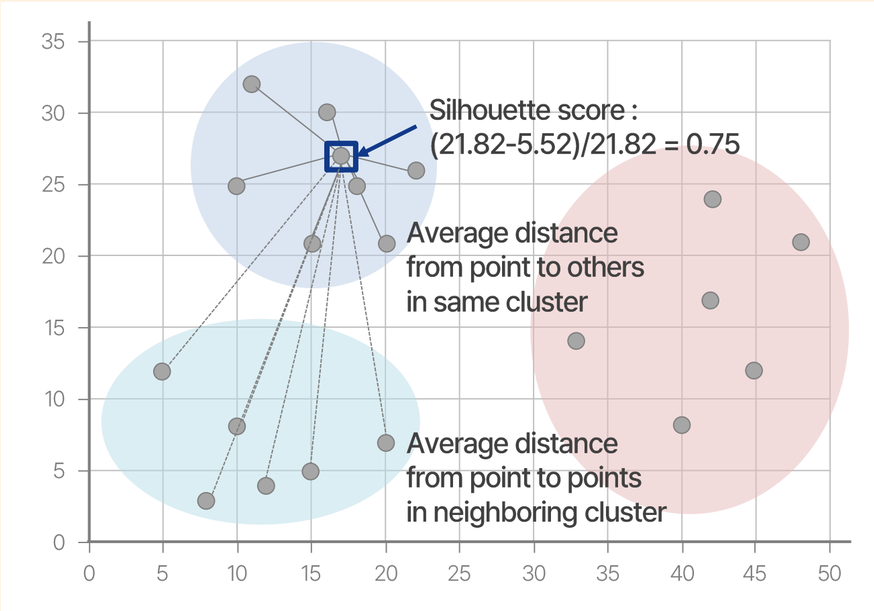

$$s(i) = \frac{b(i) - a(i)}{\max(a(i),\ b(i))}$$

$a(i)$: i번째 개체와 같은 군집에 속한 요소간 거리 평균

$b(i)$: i번째 개체와 다른 군집에 속한 요소간 거리 최소

5 k-Means 군집분석의 해석

군집 타당성 지표 - Dunn Index

- 군집 간 거리의 최소값을 분자, 군집 내 요소 간 거리의 최대값을 분모로 하는 지표
- 값이 클수록 좋으며 최소값은 0이며, 최대값은 무한대

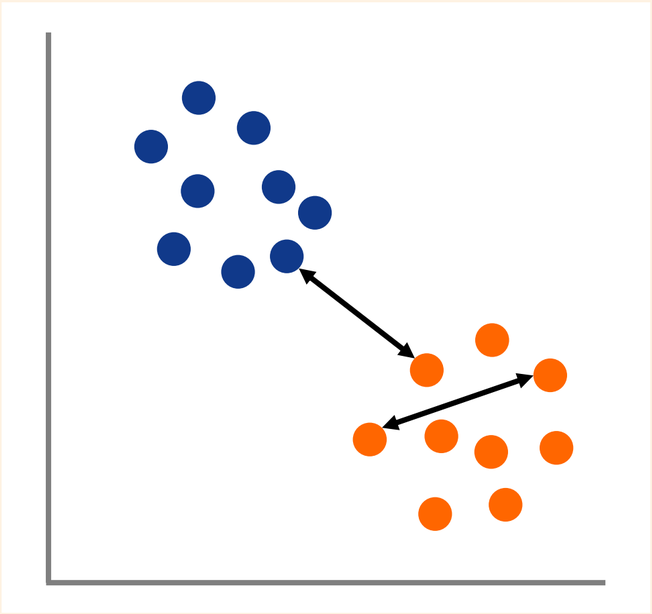

$$I(C) = \frac{\min\limits_{i \neq j}\{d_c(C_i, C_j)\}}{\max\limits_{1 \leq l \leq k}\{\Delta(C_l)\}}$$

6 k-Means 군집분석시 고려사항

데이터 전처리

- **특성 스케일링** : 거리계산 과정이 포함되어 있어 특성 정규화 권장
- **범주형 변수 처리** : 연산 특성으로 인해 Label 인코딩 대신 원핫 인코딩 권장

파라미터 설정과 해석

- 두 개 이상의 군집의 해석이 유사한 경우 군집 개수를 줄이는 것을 권장
- 군집 타당성 지표는 수학적인 해석이며 최종 해석은 도메인 지식 적극 활용 권장

7 문제 풀이

Q1. k-Means 군집분석을 실시함에 있어 데이터가 19개, 군집 개수는 3개, 반복 연산은 총 5회를 실시한다고 할 경우 수행하는 총 수치연산 횟수는 총 몇 번인가?

1. 30
2. 300
3. 3000
4. 30000

7 문제 풀이

Q1. k-Means 군집분석을 실시함에 있어 데이터가 19개, 군집 개수는 3개, 반복 연산은 총 5회를 실시한다고 할 경우 수행하는 총 수치연산 횟수는 총 몇 번인가?

1. 30
2. 300
3. 3000
4. 30000

해설

각 중심점과 각 데이터간 거리계산(n x k)
거리계산 결과를 기반으로 평균을 활용한 중심점 위치 재계산(k)
앞의 과정을 반복 → (n x k + k) x iter.

7 문제 풀이

Q2. k-Means 알고리즘의 중심점 계산에 대한 설명으로 가장 적절한 것은?

1. 각 군집에서 가장 빈번하게 나타나는 데이터 포인트를 중심점으로 선택한다.
2. 각 군집에 속한 모든 데이터 포인트들의 특성별 평균값으로 계산한다.
3. 각 군집에서 다른 모든 점들과의 거리 합이 최소인 점을 중심점으로 선택한다.
4. 각 군집의 경계에서 가장 가까운 점들의 중점을 중심점으로 계산한다.

7 문제 풀이

Q2. k-Means 알고리즘의 중심점 계산에 대한 설명으로 가장 적절한 것은?

1. 각 군집에서 가장 빈번하게 나타나는 데이터 포인트를 중심점으로 선택한다.
2. 각 군집에 속한 모든 데이터 포인트들의 특성별 평균값으로 계산한다.
3. 각 군집에서 다른 모든 점들과의 거리 합이 최소인 점을 중심점으로 선택한다.
4. 각 군집의 경계에서 가장 가까운 점들의 중점을 중심점으로 계산한다.

해설

k-Means에서 중심점(centroid)은 각 군집에 속한 모든 데이터 포인트들의 특성별 평균값으로 계산된다.

7 문제 풀이

Q3. 제조공정에서 k-Means를 활용한 불량품 분류 시 고려사항으로 가장 부적절한 것은?

1. 측정 변수들의 단위가 다르므로 표준화 또는 정규화를 실시해야 한다.
2. 측정 오류나 장비 이상으로 인한 이상치를 사전에 탐지하여 처리해야 한다.
3. 공정 조건과 품질 지표 간의 강한 상관관계가 있는 변수들을 모두 포함해야 한다.
4. 최적 k값 선정을 위해 실루엣 분석을 활용해야 한다.

7 문제 풀이

Q3. 제조공정에서 k-Means를 활용한 불량품 분류 시 고려사항으로 가장 부적절한 것은?

1. 측정 변수들의 단위가 다르므로 표준화 또는 정규화를 실시해야 한다.
2. 측정 오류나 장비 이상으로 인한 이상치를 사전에 탐지하여 처리해야 한다.
3. 공정 조건과 품질 지표 간의 강한 상관관계가 있는 변수들을 모두 포함해야 한다.
4. 최적 k값 선정을 위해 실루엣 분석을 활용해야 한다.

해설

강한 상관관계를 보이는 변수들을 모두 포함하면 중복된 정보로 인해 특정 측면이 과도하게 강조될 수 있음

7 문제 풀이

Q4. 실루엣 점수에 대한 설명으로 가장 적절한 것은?

1. 1에 가까울수록 해당 데이터 포인트가 잘못된 군집에 할당되었음을 의미한다.
2. 값은 항상 0과 1 사이의 값을 가지며 음수가 될 수 없다.
3. -1에 가까울수록 해당 데이터 포인트가 완벽하게 군집에 할당되었음을 의미한다.
4. 실루엣 계수를 산술평균 하여 산출하는 값이다.

Q4. 실루엣 점수에 대한 설명으로 가장 적절한 것은?

1. 1에 가까울수록 해당 데이터 포인트가 잘못된 군집에 할당되었음을 의미한다.
2. 값은 항상 0과 1 사이의 값을 가지며 음수가 될 수 없다.
3. -1에 가까울수록 해당 데이터 포인트가 완벽하게 군집에 할당되었음을 의미한다.
4. 실루엣 계수를 산술평균 하여 산출하는 값이다.

해설

실루엣 점수는 실루엣 계수를 산술평균 하여 얻는 값이다.

7 문제 풀이

Q5. k-Means 알고리즘의 한계점으로 가장 적절하지 않은 것은?

1. 구형(spherical) 형태가 아닌 복잡한 모양의 군집을 제대로 탐지하기 어렵다.
2. 초기 중심점의 위치에 따라 최종 결과가 달라질 수 있다.
3. 군집 개수 k를 사전에 결정해야 하는 제약이 있다.
4. 범주형 변수와 연속형 변수를 동시에 처리할 수 없다.

7 문제 풀이

Q5. k-Means 알고리즘의 한계점으로 가장 적절하지 않은 것은?

1. 구형(spherical) 형태가 아닌 복잡한 모양의 군집을 제대로 탐지하기 어렵다.
2. 초기 중심점의 위치에 따라 최종 결과가 달라질 수 있다.
3. 군집 개수 k를 사전에 결정해야 하는 제약이 있다.
4. 범주형 변수와 연속형 변수를 동시에 처리할 수 없다.

해설

적절한 전처리(원핫 인코딩, 정규화 등)를 통해
범주형 변수와 연속형 변수를 동시에 처리할 수 있다.