Data Science

Level 2

21. 특성공학

1 특성공학 개요

특성공학(Feature Engineering)의 정의

- 원시 데이터로부터 머신러닝 알고리즘에 적합한 특성(feature)을 생성, 선택, 변환하는 과정

특성공학의 갈래

- Feature Creation
  : 기존 특성들을 조합하여 새로운 특성을 생성하는 과정
- Feature Selection
  : 유용한 특성을 선별하는 과정
- Feature Transformation
  : 특성의 스케일이나 분포를 조정하는 과정

2 특성공학의 목적과 특징

특성공학의 목적

- 모델이 학습할 수 있는 의미 있는 패턴 제공으로 모델의 성능 향상 기대
- 기존 변수 병합 또는 제거로 보다 간결하고 해석이 용이한 모델 확보
- 도메인 지식을 활용하여 비즈니스적으로 의미 있고 해석 가능한 특성 생성

특성공학의 특징

- **계층적 접근**: 원시 데이터 → 기본 특성 → 고차 특성
- **반복적 개선**: 점진적 특성 추가 및 검증
- **도메인 의존성**: 문제 영역에 특화된 지식 활용

3 Feature Creation

Feature Interaction

- 상호작용 효과를 포착하기 위하여 두 개 이상의 특성을 결합하여 신규 변수 생성
  - **곱셈의 활용**: 가격 × 할인율 = 할인금액
  - **비율의 활용**: 수익/매출 = 수익율

Pattern Mining

- 특정 변수에서 특정 패턴을 추출하여 신규 변수 생성
  - **최빈값 활용**: 고객이 방문한 지점 변수를 기반으로 "주 방문 지점" 변수 생성
  - **최솟값 활용**: 배송 시간 변수를 기반으로 "최소 배송 시간" 변수 생성
  - **최댓값 활용**: 생산 시간 변수를 기반으로 "최대 생산 시간" 변수 생성

4 Feature Selection

특성 선택의 다양한 접근

- Filter Methods : 특성과 타겟 변수 간의 통계적 관계를 바탕으로 특성을 평가하여 특성 선별
- Embedded Methods : 의사결정나무와 같이 모델 내부 알고리즘으로 인해 특성이 자동 선별
- Wrapper Methods : 모델의 성능을 직접 평가하여 최적의 특성 부분집합을 찾는 방법

4 Feature Selection

독립변수의 중요도 확인

- 지도학습 모델의 경우 독립변수의 중요도를 평가하여 상대적으로 덜 중요한 변수를 제거할 수 있음
- 대표적으로 Drop Column Importance와 Permutation Importance가 있으며 모델에 관계없이 사용 가능
- 의사결정나무 등 일부 지도학습 기법은 자체적으로 독립변수의 중요도를 판단하는 지표가 있음

4 Feature Selection

Drop Column Importance

- 특정 변수를 제외 후 평가지표 변화량을 기준으로 중요도 산출
- 동작 원리 및 결과 해석이 쉽고 명료
- 특정 독립변수를 제외 후 학습 및 평가를 실시하기에 변수 중요도 평가를 위한 연산량이 많은 편

Model	독립변수				RMSE	변화량	중요도
	A	B	C	D			
FM	O	O	O	O	13.232	-	-
RM1		O	O	O	21.342	8.11	0.427
RM2	O		O	O	14.345	1.113	0.059
RM3	O	O		O	16.657	3.425	0.180
RM4	O	O	O		19.569	6.337	0.334

※ FM(Full Model) : 모든 독립변수가 들어간 모델, RM(Reduced Model) : FM에서 일부 독립변수가 제거된 모델

https://datadoctorblog.com/2023/09/14/Py-ML-Evaluation-Model-Drop-Column-Importance/

4 Feature Selection

Permutation Importance

- 평가 데이터의 특정 변수를 임의로 섞을 때 평가지표 변화량을 기준으로 중요도 산출
- 특정 독립변수의 데이터를 임의로 섞는다면 데이터 포인트간 관계가 끊어진다고 가정
- 랜덤으로 데이터가 섞이지만 우연히 섞기 전과 데이터가 일치하거나 거의 비슷할 수 있음

	나이	경력	실적
0	52	24	45
1	27	1	0
2	34	6	12

→

	나이	경력	실적
0	52	1	45
1	27	24	0
2	34	6	12

https://datadoctorblog.com/2023/09/10/Py-ML-Evaluation-Model-Permutation-Importance/

5 Feature Transformation

변수 스케일링

- **수치형 데이터**: 정규화, 지수 변환, 로그 변환 등
- **범주형 데이터**: 라벨 인코딩, 원핫 인코딩 등

6 문제 풀이

Q1. Drop Column Importance를 이용하여 특성 중요도를 평가할 때, 다음 중 가장 적절한 설명은?

1. 각 특성을 하나씩 제거한 후 모델 성능의 변화를 측정하여 중요도를 계산한다.
2. 각 특성의 값을 무작위로 섞은 후 모델 성능의 변화를 측정하여 중요도를 계산한다.
3. 모델 학습 과정에서 자동으로 계산되는 내재적 중요도를 사용한다.
4. 특성과 타겟 변수 간의 상관계수를 기반으로 중요도를 계산한다.

6 문제 풀이

Q1. Drop Column Importance를 이용하여 특성 중요도를 평가할 때, 다음 중 가장 적절한 설명은?

1. 각 특성을 하나씩 제거한 후 모델 성능의 변화를 측정하여 중요도를 계산한다.
2. 각 특성의 값을 무작위로 섞은 후 모델 성능의 변화를 측정하여 중요도를 계산한다.
3. 모델 학습 과정에서 자동으로 계산되는 내재적 중요도를 사용한다.
4. 특성과 타겟 변수 간의 상관계수를 기반으로 중요도를 계산한다.

해설

Drop Column Importance는 각 특성을 데이터셋에서 완전히 제거(drop)한 후 모델을 재학습시켜 성능 변화를 측정하는 방법. 특성이 중요할수록 제거했을 때 성능 저하가 크게 나타남

6 문제 풀이

Q2. Permutation Importance의 특징으로 가장 적절하지 않은 것은?

1. 이미 학습된 모델을 사용하여 계산할 수 있어 계산 효율적이다.
2. 특성 간의 상호작용을 고려하여 중요도를 계산한다.
3. 특성의 값을 무작위로 섞어서 모델 성능 변화를 측정한다.
4. 모델에 독립적(model-agnostic)이어서 다양한 지도학습 모델에 적용 가능하다.

6 문제 풀이

Q2. Permutation Importance의 특징으로 가장 적절하지 않은 것은?

1. 이미 학습된 모델을 사용하여 계산할 수 있어 계산 효율적이다.
2. 특성 간의 상호작용을 고려하여 중요도를 계산한다.
3. 특성의 값을 무작위로 섞어서 모델 성능 변화를 측정한다.
4. 모델에 독립적(model-agnostic)이어서 다양한 지도학습 모델에 적용 가능하다.

해설

Permutation Importance는 각 특성을 개별적으로 섞어 중요도를 측정하므로, 특성 간의 상호작용을 고려하지 않음

6 문제 풀이

Q3. 전자상거래 데이터에서 고객의 구매 패턴을 예측하기 위해 새로운 특성을 생성할 때, 다음 중 가장 부적절한 특성은?

1. 평균 구매 간격 (일 단위)
2. 구매 금액의 계절별 변동 계수
3. 고객 ID값을 이용한 수치형 특성
4. 주말 대비 평일 구매 비율

6 문제 풀이

Q3. 전자상거래 데이터에서 고객의 구매 패턴을 예측하기 위해 새로운 특성을 생성할 때, 다음 중 가장 부적절한 특성은?

1. 평균 구매 간격 (일 단위)
2. 구매 금액의 계절별 변동 계수
3. 고객 ID값을 이용한 수치형 특성
4. 주말 대비 평일 구매 비율

해설

고객 ID값은 단순히 식별자를 수치화한 것으로, 구매 패턴과는 전혀 관련이 없는 노이즈 특성이라고 할 수 있다.

6 문제 풀이

Q4. Feature Engineering 시 가장 우선적으로 고려해야 할 원칙은?

1. 가능한 한 많은 수의 특성을 생성하여 모델이 선택하도록 한다.
2. 복잡한 수학적 변환을 통해 비선형 관계를 모두 선형화한다.
3. 도메인 지식을 바탕으로 비즈니스 의미가 있는 특성을 우선 생성한다.
4. 모든 특성을 동일한 스케일로 변환하여 수치적 안정성을 확보한다.

6 문제 풀이

Q4. Feature Engineering 시 가장 우선적으로 고려해야 할 원칙은?

1. 가능한 한 많은 수의 특성을 생성하여 모델이 선택하도록 한다.
2. 복잡한 수학적 변환을 통해 비선형 관계를 모두 선형화한다.
3. 도메인 지식을 바탕으로 비즈니스 의미가 있는 특성을 우선 생성한다.
4. 모든 특성을 동일한 스케일로 변환하여 수치적 안정성을 확보한다.

해설

Feature Engineering의 가장 핵심적인 원칙은 도메인 지식을 활용하여 비즈니스적으로 의미있고 해석 가능한 특성을 생성하는 것

6 문제 풀이

Q5. 계층적 접근에서 고차 특성(High-order Features)에 대한 설명으로 가장 적절하지 않은 것은?

1. 여러 기본 특성들의 조합이나 상호작용을 통해 생성된다.
2. 원시 데이터에서 직접 관찰할 수 없는 잠재적 패턴을 표현한다.
3. 도메인 전문 지식이 가장 많이 활용되는 단계이다.
4. 모델의 해석가능성을 높이기 위해 단순한 형태로 유지해야 한다.

6 문제 풀이

Q5. 계층적 접근에서 고차 특성(High-order Features)에 대한 설명으로 가장 적절하지 않은 것은?

1. 여러 기본 특성들의 조합이나 상호작용을 통해 생성된다.
2. 원시 데이터에서 직접 관찰할 수 없는 잠재적 패턴을 표현한다.
3. 도메인 전문 지식이 가장 많이 활용되는 단계이다.
4. 모델의 해석가능성을 높이기 위해 단순한 형태로 유지해야 한다.

해설

고차 특성은 오히려 복잡한 상호작용과 비선형 관계를 표현하기 때문에 해석가능성이 낮아지는 것이 일반적이며 단순한 형태는 고차 특성과 반대되는 개념의 특징임