Data Science

# Level 2

## 22. 앙상블 모델링

# 1 앙상블 모델링 개요

## 앙상블 모델링(Ensemble Modeling)의 정의

- 다수의 기본/약한 학습기를 조합하여 단일 모델 대비 성능이 좋은 모델을 생성하는 기법
- 단일/다수 알고리즘을 결합하여 예측/분류의 정확성과 안정성을 향상시키는 기법

## 관련 용어

- **기본 학습기(base learner)**
  : 앙상블을 구성하는 개별 예측 모델로, 일반적으로 단순하고 해석 가능한 알고리즘을 사용
- **약한 학습기(weak learner)**
  : 무작위 추측보다는 조금 더 나은 성능을 보이는 학습기로, 일반적으로 50% 이상의 정확도를 가짐
- **강한 학습기(strong learner)**
  : 높은 정확도를 가진 학습기로, 앙상블 모델링의 최종 목표
- **다양성(diversity)**
  : 구성 모델들 간의 예측 차이를 뜻하며 정확성과의 균형이 중요

# 2 앙상블 모델링의 목적과 특징

## 앙상블 모델링의 목적

- 개별 모델의 편향(bias)과 분산(variance)을 효과적으로 감소시켜 전체적인 예측 오차/오분류 감소
- 예측 불확실성의 정량화

## 앙상블 모델링의 특징

- 편향과 분산을 동시에 고려하여 최적화
- 모델의 복잡성을 제어하여 과적합 방지
- 불안정성을 완화시켜 신규 데이터에 대한 일반화 성능 향상

# 3 앙상블 모델링의 유형

## 데이터 및 알고리즘의 개수에 따른 구분

- **단일** 데이터 세트 + **단일** 알고리즘으로 구성된 다수의 모델
- **단일** 데이터 세트 + **다중** 알고리즘으로 구성된 다수의 모델
- **다중** 데이터 세트 + **단일** 알고리즘으로 구성된 다수의 모델
- **다중** 데이터 세트 + **다중** 알고리즘으로 구성된 다수의 모델

# 3 앙상블 모델링의 유형

## 데이터 및 알고리즘의 개수에 따른 구분(예시)

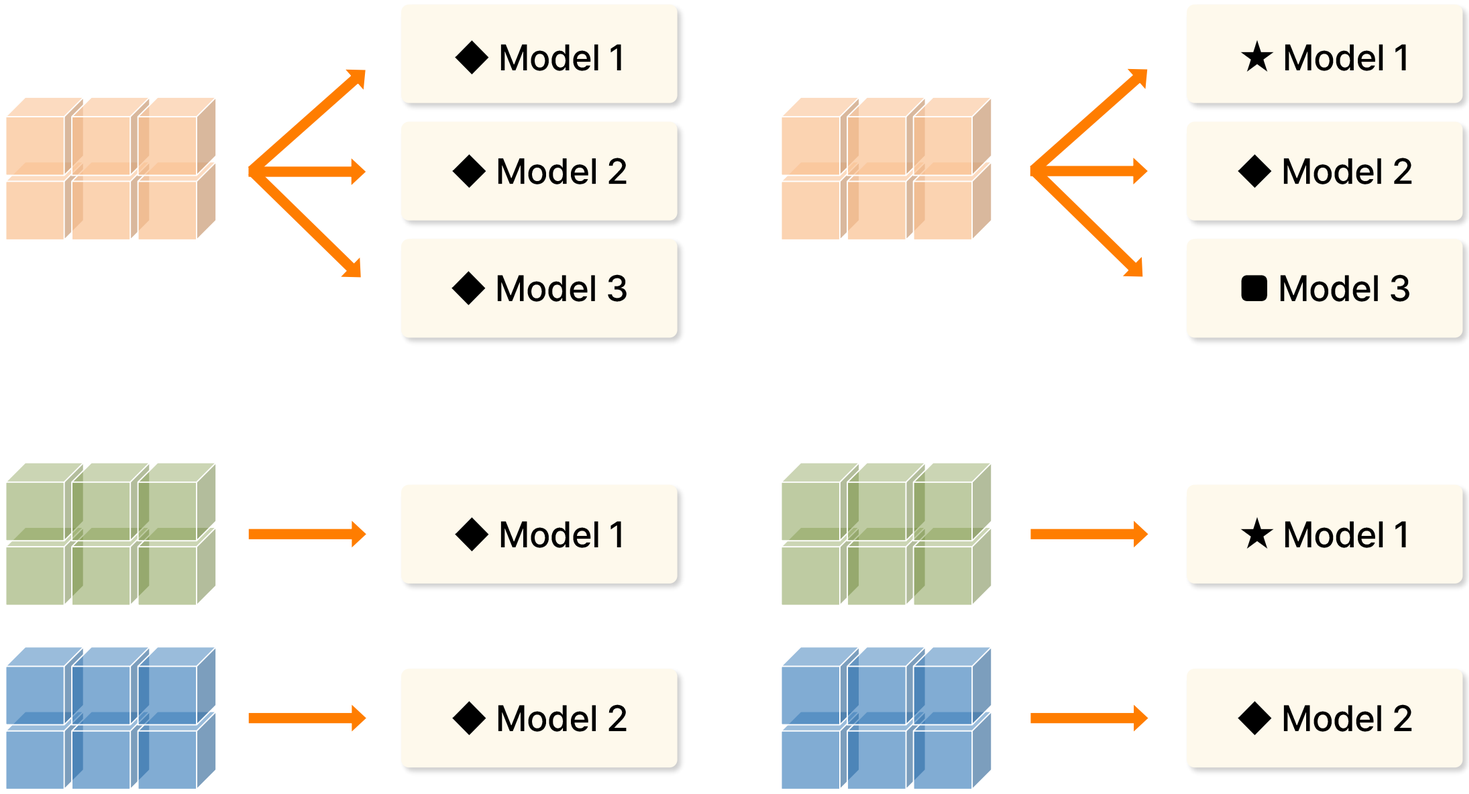

# 4 부트스트랩

## 부트스트랩(Bootstrap)

- 원본 데이터셋에서 복원추출을 통해 원본과 동일한 크기의 새로운 데이터셋을 생성하는 통계적 기법
- 특성(특히 종속변수)이 불균형인 경우(imbalanced) 이를 맞춰주기 위해 사용될 수 있음
- 부트스트랩으로 추출되지 않은 데이터를 OOB(Out Of Bag) 표본이라고 함
- 부트스트랩의 부스팅은 주로 편향을 감소시키는데 기여

# 4 부트스트랩

## OOB(Out Of Bag)

- 부트스트랩 표본 크기가 n일 때 한 번의 표본 추출에서 어떤 표본 하나가 추출되지 않을 확률은 (n-1)/n
- 데이터가 충분히 클 때 OOB 표본의 비율은 약 36.8% 임

$$\lim_{n\to\infty}\left(1-\frac{1}{n}\right)^{n} = e^{-1} \approx 0.368$$

# 5 배깅

## 배깅(Bagging, Bootstrap Aggregating)

- 부트스트랩으로 생성한 훈련 데이터셋으로 모델들을 학습하고 그 예측을 집계하여 최종 예측을 수행
- 분산 감소가 주 목적이며, 높은 분산을 가진 기본 학습기의 예측을 평균하여 더 안정적인 예측을 만들어냄
- 결괏값의 취합에 있어 회귀모델의 경우 산술평균을, 분류모델의 경우 투표(voting)을 활용

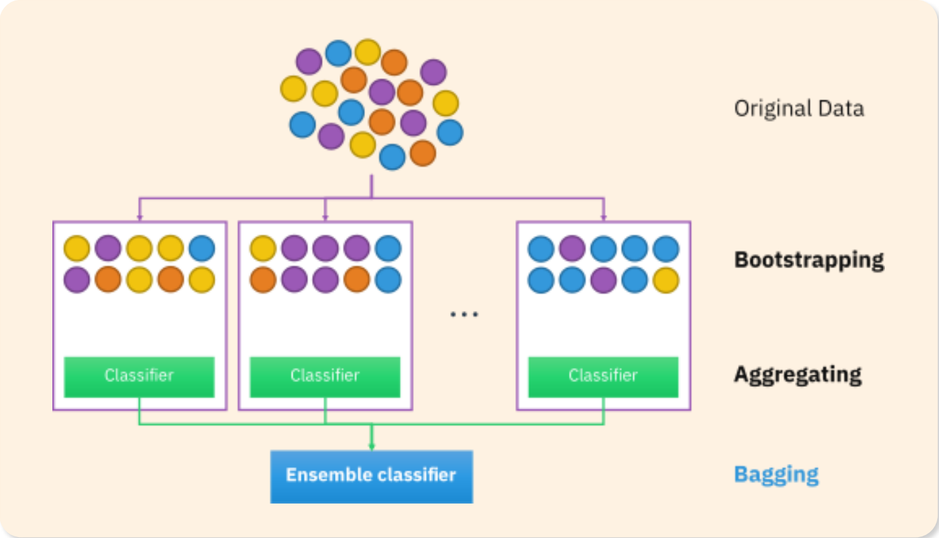


https://zetawiki.com/wiki/배깅

## 투표(Voting)

- 분류모델 앙상블에서 서로 다른 모델의 예측치를 취합하여 하나의 결과로 결정하는 방법
- 최빈값을 기준으로 하는 Hard Voting, 확률이 가장 높은 값을 기준으로 하는 Soft Voting 중 선택

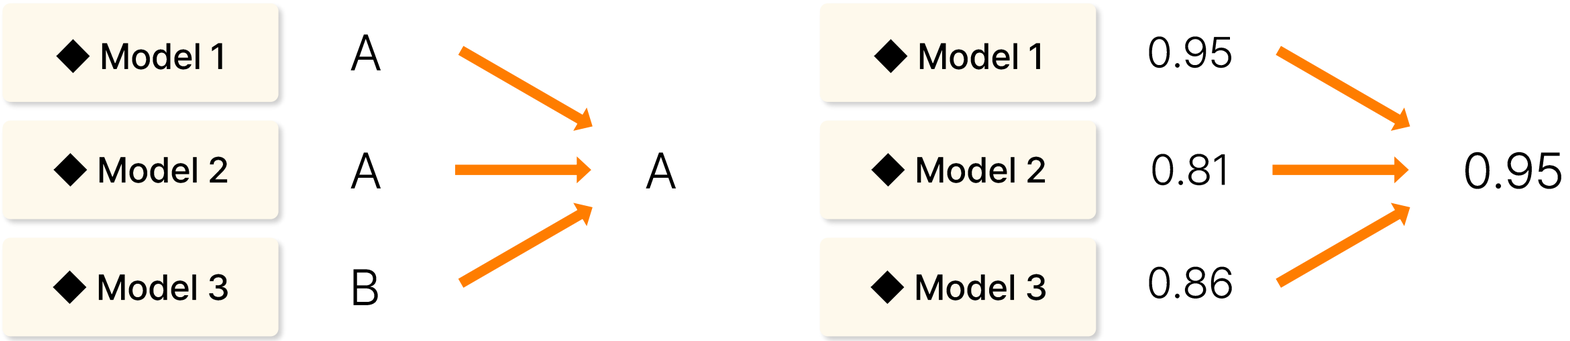

# 6 앙상블 모델링 시 고려사항

## 구성 모델의 결정과 그 비중

- 성능 향상과 계산 비용 간의 균형을 위한 적절한 모델 수 선정
- 도메인 데이터를 기반으로 맥락에 맞는 모델을 조합하며 필요 시 가중치 설정
- 서로 다른 학습 원리를 가진 모델 조합 권장(의사결정나무 + 로지스틱 회귀 등)
- 기본 모델들 간의 예측 상관관계를 낮춰 다양성 극대화

# 7 문제 풀이

## Q1. 5개의 분류 모델이 다음과 같이 예측했을 때, Hard Voting의 최종 예측 결과는?

1. A
2. B
3. C
4. 오류 발생

Model 1 : A
Model 2 : B
Model 3 : A
Model 4 : C
Model 5 : A

# 7 문제 풀이

## Q1. 5개의 분류 모델이 다음과 같이 예측했을 때, Hard Voting의 최종 예측 결과는?

1. A
2. B
3. C
4. 오류 발생

Model 1 : A
Model 2 : B
Model 3 : A
Model 4 : C
Model 5 : A

## 해설

Hard Voting은 최빈값을 기준으로 결정됨으로 A/B/C 중에 A가 Model 1, 3, 5에서 나왔기 때문에 최종으로는 "A"가 정답

# 7 문제 풀이

## Q2. 3개의 분류 모델이 다음과 같은 확률로 예측했을 때, Hard Voting의 최종 예측 결과는?

**모델 1** : P(A)=0.8, P(B)=0.1, P(C)=0.1
**모델 2** : P(A)=0.3, P(B)=0.4, P(C)=0.3
**모델 3** : P(A)=0.4, P(B)=0.3, P(C)=0.3

1. A
2. B
3. C
4. 동점으로 인한 문제 발생

# 7 문제 풀이

## Q2. 3개의 분류 모델이 다음과 같은 확률로 예측했을 때, Hard Voting의 최종 예측 결과는?

모델 1 : P(A)=0.8, P(B)=0.1, P(C)=0.1
모델 2 : P(A)=0.3, P(B)=0.4, P(C)=0.3
모델 3 : P(A)=0.4, P(B)=0.3, P(C)=0.3

1. A
2. B
3. C
4. 동점으로 인한 문제 발생

## 해설

모델 1이 A(0.8), 모델 2가 B(0.4), 모델 3이 A(0.4)로
최종적으로 A라고 할 수 있음

# 7 문제 풀이

## Q3. 앙상블 모델링에서 기본 모델들 간의 강한 상관관계가 있을 경우 어떤 문제가 예상되는가?

1. 계산 비용이 기하급수적으로 증가한다.
2. 모델의 해석가능성이 크게 떨어진다.
3. 다양성이 부족하여 앙상블 효과가 감소한다.
4. 메모리 사용량이 과도하게 증가한다.

# 7 문제 풀이

## Q3. 앙상블 모델링에서 기본 모델들 간의 강한 상관관계가 있을 경우 어떤 문제가 예상되는가?

1. 계산 비용이 기하급수적으로 증가한다.
2. 모델의 해석가능성이 크게 떨어진다.
3. 다양성이 부족하여 앙상블 효과가 감소한다.
4. 메모리 사용량이 과도하게 증가한다.

## 해설

기본 모델들이 유사한 오류를 만들면 앙상블의 "서로 다른 관점의 조합"
효과가 줄어들어 성능 향상이 제한될 수 있음

# 7 문제 풀이

## Q4. 배깅(Bagging)과 부스팅(Boosting)이 편향-분산 트레이드오프에 미치는 영향으로 올바른 것은?

1. 배깅 : 편향 감소, 부스팅 : 분산 감소
2. 배깅 : 분산 감소, 부스팅 : 편향 감소
3. 배깅 : 편향과 분산 모두 감소, 부스팅 : 변화 없음
4. 배깅 : 변화 없음, 부스팅 : 편향과 분산 모두 증가

# 7 문제 풀이

## Q4. 배깅(Bagging)과 부스팅(Boosting)이 편향-분산 트레이드오프에 미치는 영향으로 올바른 것은?

1. 배깅 : 편향 감소, 부스팅 : 분산 감소
2. 배깅 : 분산 감소, 부스팅 : 편향 감소
3. 배깅 : 편향과 분산 모두 감소, 부스팅 : 변화 없음
4. 배깅 : 변화 없음, 부스팅 : 편향과 분산 모두 증가

### 해설

배깅은 여러 모델의 평균화를 통해 분산을 감소시키고,
부스팅은 순차적 학습을 통해 편향을 감소시킴

# 7 문제 풀이

## Q5. 원본 데이터셋에서 부트스트랩을 수행할 때, 특정 데이터 포인트가 부트스트랩 표본에 포함되지 않을 확률은 약 얼마인가?

※ 부트스트랩 표본이 충분히 크다고 가정

1. 약 26.4%
2. 약 36.8%
3. 약 50.0%
4. 약 63.2%

# 7 문제 풀이

## Q5. 원본 데이터셋에서 부트스트랩을 수행할 때, 특정 데이터 포인트가 부트스트랩 표본에 포함되지 않을 확률은 약 얼마인가?

※ 부트스트랩 표본이 충분히 크다고 가정

1. 약 26.4%
2. 약 36.8%
3. 약 50.0%
4. 약 63.2%

## 해설

$(1-1/n)^n \approx 1/e \approx 0.368$로, 약 36.8%의 데이터가 각 부트스트랩 표본에서 제외