Data Science

Level 2

23. 랜덤포레스트

1 랜덤포레스트 개요

랜덤포레스트(Random Forest)의 정의

- 앙상블 학습(ensemble learning) 방법 중 하나로, 다수의 의사결정나무를 결합하여 예측 성능을 향상시키는 지도학습 알고리즘

관련 용어

- **앙상블 학습(ensemble learning)**
  : 여러 개의 약한 학습기(weak learner)를 결합하여 강한 학습기(strong learner)를 만드는 기법
- **배깅(bagging)**
  : 부트스트랩 샘플링을 통해 생성된 여러 데이터셋으로 모델을 학습하고 결과를 집계하는 방법
- **특성 부분집합 선택(feature subset selection)**
  : 랜덤포레스트는 개별 의사결정나무 모델에 사용되는 특성이 랜덤하게 사용됨

  ※ Random Feature Subset

2 랜덤포레스트의 목적과 특징

랜덤포레스트의 목적

- 앙상블 모델링을 통한 단일 의사결정나무의 한계를 극복과 예측 성능 향상

랜덤포레스트의 특징

- 배깅(bagging)과 무작위로 선택된 특성으로 학습하는 앙상블 방법
- 여러 개의 의사결정나무를 병렬로 학습시켜 결과를 집계
- 분류 문제에서는 다수결 투표, 회귀 문제에서는 평균값으로 최종 예측
- 의사결정나무 모델 대비 성능이 좋으나 해석이 어려움
- 각 특성이 불순도 감소에 기여하는 정도를 활용한 특성 중요도 확인 가능

2 랜덤포레스트의 목적과 특징

모델 의사결정나무 수량 증가 시 특징

- 나무 개수에 비례한 연산시간의 선형적 증가
- 예측 속도 감소 및 메모리 요구량 증가
- 급격한 성능 향상을 보여주다 일정 개수 이상에서 예측 성능이 수렴
- 예측 결과의 안정성 향상 및 과적합 방지 효과 증대

3 랜덤포레스트의 쓰임새

분야별 활용

- **제조:** 다변수 공정 조건 최적화
- **유통:** 수요 예측 및 재고 최적화
- **금융:** 다양한 지표 조합을 통한 알고리즘 트레이딩

4 (보충) 의사결정나무

의사결정 나무(모델)의 구조

- 가장 상단의 노드는 뿌리(root) 노드
- 말단(terminal)의 노드는 잎사귀(leaf) 노드
- 상위 노드는 부모(parent) 노드, 하위 노드는 자식(child) 노드
- 첫 번째 자식 노드 위치의 깊이(depth)는 1이며 단계(level)는 2
- 모델의 최대 깊이 값이 클 수록 많은 규칙과 과적합을 수반함

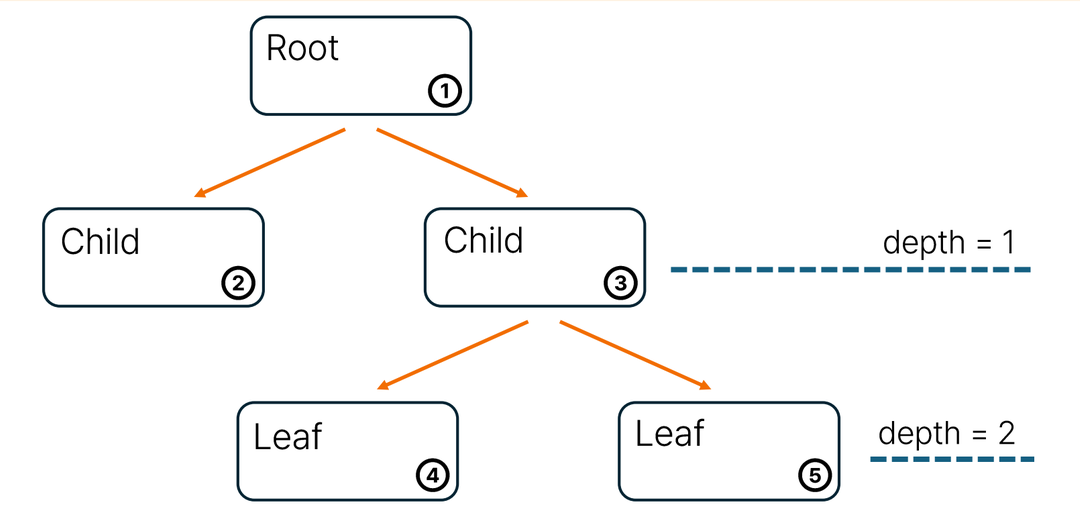

5 (보충) 앙상블 모델링

앙상블 모델링(Ensemble Modeling)의 정의

- 다수의 기본/약한 학습기를 조합하여 단일 모델 대비 성능이 좋은 모델을 생성하는 기법
- 단일/다수 알고리즘을 결합하여 예측/분류의 정확성과 안정성을 향상시키는 기법

5 (보충) 앙상블 모델링

데이터 및 알고리즘의 개수에 따른 구분(예시)

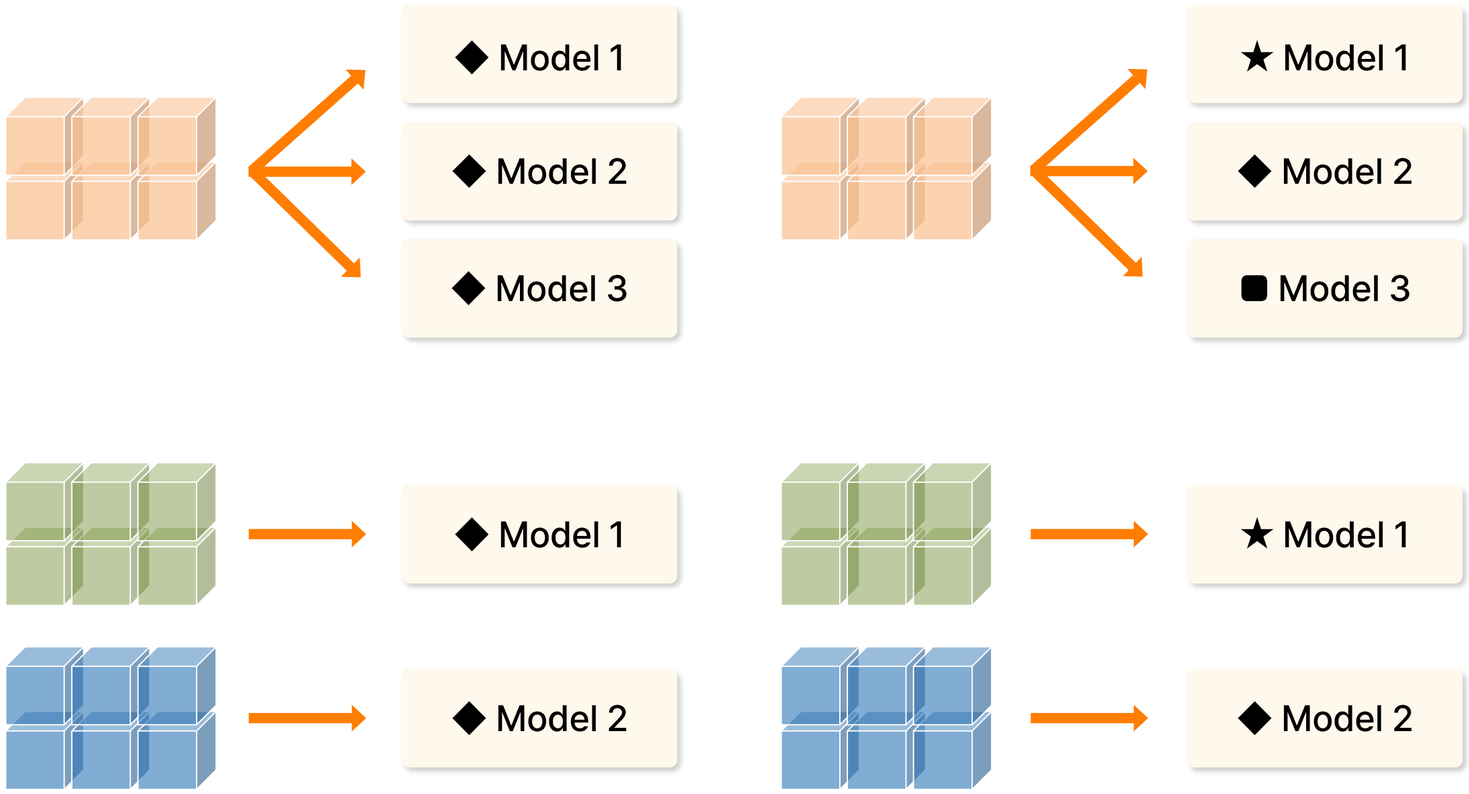

5 (보충) 앙상블 모델링

배깅(Bagging, Bootstrap Aggregating)

- 부트스트랩으로 생성한 훈련 데이터셋으로 모델들을 학습하고 그 예측을 집계하여 최종 예측을 수행
- 분산 감소가 주 목적이며, 높은 분산을 가진 기본 학습기의 예측을 평균하여 더 안정적인 예측을 만들어냄
- 결괏값의 취합에 있어 회귀모델의 경우 산술평균을, 분류모델의 경우 투표(voting)을 활용

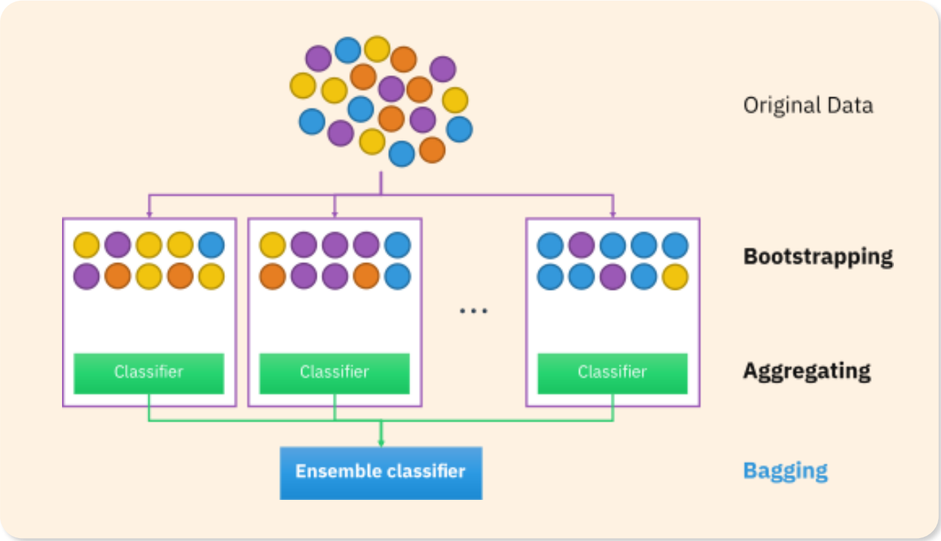

https://zetawiki.com/wiki/배깅

6 랜덤포레스트의 해석

MDI(Mean Decrease in Impurity)

- 랜덤포레스트에서의 특성 중요도(MDI)는 각 특성이 불순도 감소에 기여하는 정도로 계산
- 모델 학습 과정에서 자동으로 산출되어 별도의 재학습이나 데이터 조작 없이 얻을 수 있음
- 학습 데이터 기반으로 산출이 되며 정규화를 통해 각 특성의 중요도 합은 1
- 높은 카디널리티를 가진 특성의 경우 중요도가 과도하게 크게 산출될 수 있음

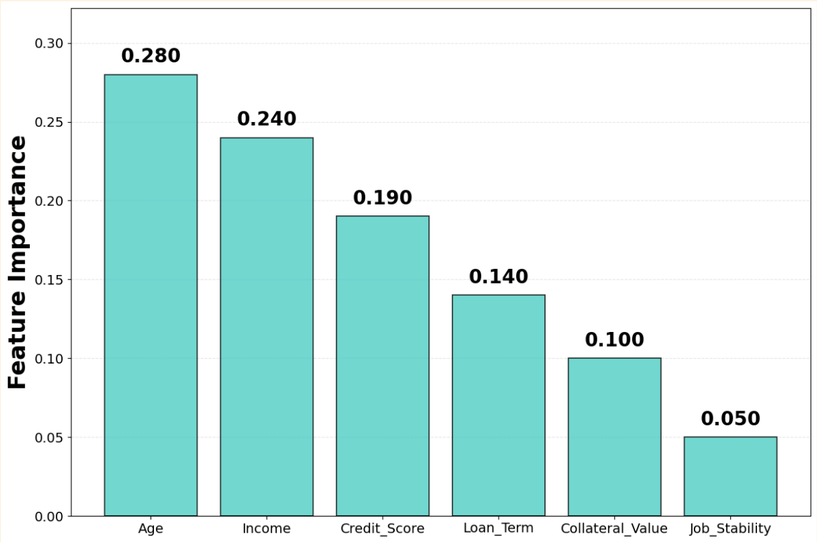

7 랜덤포레스트의 예측값 산출

학습 과정

- 1) 원본 데이터에서 복원추출로 n개의 부트스트랩 표본 생성
- 2) 각 나무(기본 학습기)에서 전체 특성 중 일부 특성만 무작위 선택
- 3) 각 부트스트랩 표본과 선택한 일부 특성으로 나무 학습
- 4) m개의 나무로 랜덤포레스트 구성

7 랜덤포레스트의 예측값 산출

예측 과정

- **개별 예측**: 각 나무가 새로운 데이터에 대해 예측 수행
- **결과 집계**:
  - **분류**: 다수결 투표로 최종 클래스 결정
  - **회귀**: 모든 나무의 예측값 평균으로 최종 값 결정

8 랜덤포레스트의 평가

성능 평가 – 분류 모델

- 분류모델로 정확도, 정밀도, 재현율, F1-Score 등 종속변수 평가지표 사용 가능

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$\text{F1 score} = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 \times \frac{precision \cdot recall}{precision + recall}$$

※ TP: True Positive, TN: True Negative, FP : False Positive, FN: False Negative

8 랜덤포레스트의 평가

성능 평가 – 회귀 모델

- 회귀모델로 MSE, MAE, RMSE, MAPE 등 종속변수 평가지표 사용 가능

$$\mathrm{MSE} = \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}} = \sqrt{\frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{n}}$$

$$\mathrm{MAE} = \frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{n}$$

$$\mathrm{MAPE} = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100$$

$y_i - \hat{y}_i$: $error$ y_i : 실제값 $\hat{y}_i$: 예측값

9 랜덤포레스트 수행 시 고려사항

과적합 방지를 위한 조치

- 너무 많은 나무는 과적합 위험 증가
- 최대 깊이(max depth) 조절로 사전 가지치기 검토

10 문제 풀이

Q1. 랜덤포레스트의 기본 원리에 대한 설명으로 가장 적절한 것은?

1. 모든 나무가 동일한 데이터와 특성을 사용하여 학습한다.
2. 순차적으로 이전 모델의 오류를 보정하는 부스팅 방법을 사용한다.
3. 단일 의사결정나무를 깊게 성장시켜 복잡한 패턴을 학습한다.
4. 부트스트랩 샘플링과 특성 랜덤 선택을 통해 다양한 나무들을 생성한다.

10 문제 풀이

Q1. 랜덤포레스트의 기본 원리에 대한 설명으로 가장 적절한 것은?

1. 모든 나무가 동일한 데이터와 특성을 사용하여 학습한다.
2. 순차적으로 이전 모델의 오류를 보정하는 부스팅 방법을 사용한다.
3. 단일 의사결정나무를 깊게 성장시켜 복잡한 패턴을 학습한다.
4. 부트스트랩 샘플링과 특성 랜덤 선택을 통해 다양한 나무들을 생성한다.

해설

랜덤포레스트는 배깅(Bagging) 기반의 앙상블 방법으로, 각 나무가 부트스트랩 샘플링된 데이터와 무작위로 선택된 특성 부분집합을 사용하여 학습

10 문제 풀이

Q2. 다음 수식에서 B는 나무의 개수, $h_b(x)$는 b번째 나무의 예측값일 때 랜덤포레스트 회귀 예측값을 나타내는 것은?

1. 가중평균을 통한 예측값 계산
2. 모든 나무의 예측값에 대한 산술평균 계산
3. 모든 나무의 예측값 중 최댓값 선택
4. 모든 나무의 예측값 중 중간값 선택

$$\hat{y} = \frac{1}{B}\sum_{b=1}^{B} h_b(x)$$

10 문제 풀이

Q2. 다음 수식에서 B는 나무의 개수, $h_b(x)$는 b번째 나무의 예측값일 때 랜덤포레스트 회귀 예측값을 나타내는 것은?

1. 가중평균을 통한 예측값 계산
2. 모든 나무의 예측값에 대한 산술평균 계산
3. 모든 나무의 예측값 중 최댓값 선택
4. 모든 나무의 예측값 중 중간값 선택

$$\hat{y} = \frac{1}{B}\sum_{b=1}^{B} h_b(x)$$

해설

랜덤포레스트의 회귀 예측은 모든 나무의 예측값에 대한 산술평균으로 계산

10 문제 풀이

Q3. MDI(Mean Decrease in Impurity) 특성중요도에 대한 설명으로 올바르지 않은 것은?

1. 모델 학습과 동시에 계산되어 추가 연산 비용이 없다.
2. 모든 특성의 중요도 합이 1이 되도록 정규화 된다.
3. 중요도 산출과 카디널리티는 관련이 없다.
4. 각 특성이 불순도 감소에 기여하는 평균적 정도를 측정한다.

10 문제 풀이

Q3. MDI(Mean Decrease in Impurity) 특성중요도에 대한 설명으로 올바르지 않은 것은?

1. 모델 학습과 동시에 계산되어 추가 연산 비용이 없다.
2. 모든 특성의 중요도 합이 1이 되도록 정규화 된다.
3. 중요도 산출과 카디널리티는 관련이 없다.
4. 각 특성이 불순도 감소에 기여하는 평균적 정도를 측정한다.

해설

MDI는 높은 카디널리티(고유값이 많은 특성)에 편향되는 대표적인 한계가 있음.
고유값이 많을수록 더 많은 분할 기회를 가져 우연히 불순도를 감소시킬 가능성이 높아져 과대평가될 수 있음

10 문제 풀이

Q4. 다음 중 랜덤포레스트의 장점으로 올바르지 않은 것은?

1. 개별 의사결정나무보다 과적합 방지 효과가 크다.
2. 특성 스케일링이나 정규화가 불필요하다.
3. 각 나무를 독립적으로 학습하여 병렬 처리가 가능하다.
4. 단일 의사결정나무보다 모델 해석이 더 용이하다.

10 문제 풀이

Q4. 다음 중 랜덤포레스트의 장점으로 올바르지 않은 것은?

1. 개별 의사결정나무보다 과적합 방지 효과가 크다.
2. 특성 스케일링이나 정규화가 불필요하다.
3. 각 나무를 독립적으로 학습하여 병렬 처리가 가능하다.
4. 단일 의사결정나무보다 모델 해석이 더 용이하다.

해설

랜덤포레스트는 개별 의사결정나무 모델을 취합한 것으로 개별 의사결정나무 모델은 if-then 규칙으로 명확하고 간결한 해석이 가능한 반면, 랜덤포레스트의 경우 상세 규칙 해석이 어렵다.

10 문제 풀이

Q5. 랜덤포레스트에서 사용하는 의사결정나무의 숫자에 따른 영향으로 올바른 것은?

1. 나무의 개수가 증가할수록 이상치나 노이즈의 영향이 평균화되어 완화된다.
2. 나무의 개수가 증가할수록 항상 과적합이 발생한다.
3. 나무의 개수와 모델 성능은 반비례 관계이다.
4. 나무의 개수가 증가하면 특성중요도가 불안정해진다.

10 문제 풀이

Q5. 랜덤포레스트에서 사용하는 의사결정나무의 숫자에 따른 영향으로 올바른 것은?

1. 나무의 개수가 증가할수록 이상치나 노이즈의 영향이 평균화되어 완화된다.
2. 나무의 개수가 증가할수록 항상 과적합이 발생한다.
3. 나무의 개수와 모델 성능은 반비례 관계이다.
4. 나무의 개수가 증가하면 특성중요도가 불안정해진다.

해설

랜덤포레스트에서 나무의 개수가 증가할수록 이상치나 노이즈의 영향이 평균화되어 완화되는데 이는 안정성의 증가를 뜻한다.