Data Science

Level 2

24. 종합문제 1

문제 풀이

Q1. 다음 중 수치형 데이터에 대한 설명으로 가장 적절한 것은?

1. 변환된 범주형 데이터와 동일하게 사칙연산에 주의해야 한다.
2. 하위 개념에 이산형 데이터가 존재한다.
3. 연속형 데이터와 순서형 데이터로 구분된다.
4. 명목척도와 순서척도만을 포함한다.

문제 풀이

Q1. 다음 중 수치형 데이터에 대한 설명으로 가장 적절한 것은?

1. 변환된 범주형 데이터와 동일하게 사칙연산에 주의해야 한다.
2. 하위 개념에 이산형 데이터가 존재한다.
3. 연속형 데이터와 순서형 데이터로 구분된다.
4. 명목척도와 순서척도만을 포함한다.

해설

수치형 데이터는 연속형 데이터와 이산형 데이터로 구분되며,
범주형 데이터는 명목형 데이터와 순서형 데이터로 구분된다.

문제 풀이

Q2. 층화표본추출에 대한 설명으로 가장 적절한 것은?

1. 모집단을 동질적인 층으로 나눈 후 각 층에서 무작위로 표본을 추출한다.
2. 첫 번째 표본을 무작위로 선택한 후 일정한 간격으로 표본을 추출한다.
3. 모집단의 모든 구성원에게 동일한 선택 확률을 부여하여 추출한다.
4. 지리적으로 인접한 집단을 하나의 단위로 하여 무작위로 선택한다.

문제 풀이

Q2. 층화표본추출에 대한 설명으로 가장 적절한 것은?

1. 모집단을 동질적인 층으로 나눈 후 각 층에서 무작위로 표본을 추출한다.
2. 첫 번째 표본을 무작위로 선택한 후 일정한 간격으로 표본을 추출한다.
3. 모집단의 모든 구성원에게 동일한 선택 확률을 부여하여 추출한다.
4. 지리적으로 인접한 집단을 하나의 단위로 하여 무작위로 선택한다.

해설

층화표본추출은 각 계층별 표본추출을 하여 특정 계층이 누락되지 않도록 하는 확률적 표본추출 방법이며 일반적으로 각 계층별 n개의 표본 또는 m%의 비율로 표본을 추출한다.

문제 풀이

Q3. 조화평균에 대한 표현으로 적절한 것은?

1. 관측값들의 합에 그 개수를 나눈 값
2. 각 관측값에 가중치를 적용하여 그 개수를 나눈 값
3. 각 관측값의 제곱합을 구한 다음 해당 값에 제곱근을 취한 값
4. 관측값들의 역수의 산술평균에 역수를 취한 값

문제 풀이

Q3. 조화평균에 대한 표현으로 적절한 것은?

1. 관측값들의 합에 그 개수를 나눈 값
2. 각 관측값에 가중치를 적용하여 그 개수를 나눈 값
3. 각 관측값의 제곱합을 구한 다음 해당 값에 제곱근을 취한 값
4. 관측값들의 역수의 산술평균에 역수를 취한 값

해설

조화평균에 대한 설명에 있어 핵심이 되는 단어는 "역수"이며,
나머지 보기는 다른 종류의 평균에 대한 내용이다.

문제 풀이

Q4. 독립 사건의 정의로 가장 적절한 것은?

1. 두 사건의 합집합 확률이 각 사건 확률의 합과 같다.
2. 두 사건의 교집합 확률이 각 사건 확률의 곱과 같다.
3. 두 사건의 조건부 확률이 서로 같다.
4. 두 사건의 합집합 확률이 전사건에서 교집합을 뺀 확률과 같다.

문제 풀이

Q4. 독립 사건의 정의로 가장 적절한 것은?

1. 두 사건의 합집합 확률이 각 사건 확률의 합과 같다.
2. 두 사건의 교집합 확률이 각 사건 확률의 곱과 같다.
3. 두 사건의 조건부 확률이 서로 같다.
4. 두 사건의 합집합 확률이 전사건에서 교집합을 뺀 확률과 같다.

해설

두 사건이 독립인 경우 교집합(동시에 일어날 확률)은 조건부 확률이 아닌 각 사건 확률의 곱과 같다.

문제 풀이

Q5. 이항분포의 확률질량함수에 대한 설명으로 올바른 것은?

1. 단위구간당 평균발생률의 지수함수와 팩토리얼의 비로 표현된다.
2. 구간의 길이에 대한 역수로 일정한 확률밀도를 갖는다.
3. 이항계수와 성공확률의 거듭제곱 및 실패확률의 거듭제곱의 곱으로 표현된다.
4. 성공확률과 기하급수적 감소하는 실패확률의 곱으로 표현된다.

문제 풀이

Q5. 이항분포의 확률질량함수에 대한 설명으로 올바른 것은?

1. 단위구간당 평균발생률의 지수함수와 팩토리얼의 비로 표현된다.
2. 구간의 길이에 대한 역수로 일정한 확률밀도를 갖는다.
3. 이항계수와 성공확률의 거듭제곱 및 실패확률의 거듭제곱의 곱으로 표현된다.
4. 성공확률과 기하급수적 감소하는 실패확률의 곱으로 표현된다.

해설

이항분포 확률질량함수의 수식은 다음과 같으며 3번이 정답이다.

$$P(X = k) = \frac{n!}{k!(n-k)!} p^k (1-p)^{1-k}$$

문제 풀이

Q6. 연속확률변수의 확률밀도함수 f(x)에 대한 설명으로 틀린 것은?

1. 모든 x에 대해 $f(x) \geq 0$ 이다.
2. 전체 구간에 대한 적분값은 1이다.
3. f(x) 자체가 확률을 의미한다.
4. 곡선 아래의 면적이 확률을 의미한다.

문제 풀이

Q6. 연속확률변수의 확률밀도함수 f(x)에 대한 설명으로 틀린 것은?

1. 모든 x에 대해 $f(x) \geq 0$ 이다.
2. 전체 구간에 대한 적분값은 1이다.
3. f(x) 자체가 확률을 의미한다.
4. 곡선 아래의 면적이 확률을 의미한다.

해설

연속분포에서 확률밀도함수의 값은 확률이 아니라 확률밀도를 나타내며,
확률은 구간의 적분으로 구할 수 있다. 그리고 전체 구간에 대한 적분값은 1이다.

문제 풀이

Q7. 표준정규분포 N(0,1)에 대한 설명으로 가장 적절한 것은?

1. 평균이 1이고 분산이 0인 정규분포이다.
2. 평균이 0이고 표준편차가 1인 정규분포이다.
3. 모든 값이 0과 1 사이에 위치하는 분포이다.
4. 이산확률분포의 한 종류이다.

문제 풀이

Q7. 표준정규분포 N(0,1)에 대한 설명으로 가장 적절한 것은?

1. 평균이 1이고 분산이 0인 정규분포이다.
2. 평균이 0이고 표준편차가 1인 정규분포이다.
3. 모든 값이 0과 1 사이에 위치하는 분포이다.
4. 이산확률분포의 한 종류이다.

해설

정규분포 중에서 평균이 0이고 표준편차가 1인 정규분포인 분포는 표준정규분포 라고 지칭하며 N(0, 1)로 표기하기도 한다.

문제 풀이

Q8. 중심극한정리에서 표본크기가 충분히 큰 경우 표본의 평균과 관련 있는 분포는?

1. 이항분포
2. 포아송분포
3. 균등분포
4. 정규분포

문제 풀이

Q8. 중심극한정리에서 표본크기가 충분히 큰 경우 표본의 평균과 관련 있는 분포는?

1. 이항분포
2. 포아송분포
3. 균등분포
4. 정규분포

해설

모집단에서 추출하는 표본의 크기가 커질수록 모집단의 분포에 관계없이 표본 집단의 표본 평균이 이루는 분포는 정규분포에 가까워진다.

문제 풀이

Q9. 점추정량의 바람직한 성질이 아닌 것은?

1. 복잡성(complexity)
2. 일치성(consistency)
3. 효율성(efficiency)
4. 불편성(unbiasedness)

문제 풀이

Q9. 점추정량의 바람직한 성질이 아닌 것은?

1. 복잡성(complexity)
2. 일치성(consistency)
3. 효율성(efficiency)
4. 불편성(unbiasedness)

해설

좋은 점 추정량의 조건 및 성질로 불편성, 일치성, 유효성, 충분성이 있으며
복잡성은 관련 없는 내용이다.

문제 풀이

Q10. 전체 데이터를 4개 구간으로 나누는 사분위수에서, 제 2 사분위수(Q_2)와 같은 의미를 가지는 것은?

1. 제 25 백분위수
2. 중위수(median)
3. 제 75 백분위수
4. 최빈값(mode)

문제 풀이

Q10. 전체 데이터를 4개 구간으로 나누는 사분위수에서, 제 2 사분위수(Q_2)와 같은 의미를 가지는 것은?

1. 제 25 백분위수
2. 중위수(median)
3. 제 75 백분위수
4. 최빈값(mode)

해설

제 2 사분위수는 중위수 및 제 50 백분위수와 같다.

문제 풀이

Q11. 다음 중 잔차(residual)에 대한 내용 중 틀린 것은?

1. 단순선형회귀분석에서 실제값과 추정한 회귀직선에 의한 값의 차이다.
2. 잔차는 항상 양수이다.
3. 잔차의 평균은 항상 0이다.
4. 잔차는 모델의 등분산성이 만족되는지 확인하는데 사용된다.

문제 풀이

Q11. 다음 중 잔차(residual)에 대한 내용 중 틀린 것은?

1. 단순선형회귀분석에서 실제값과 추정한 회귀직선에 의한 값의 차이다.
2. 잔차는 항상 양수이다.
3. 잔차의 평균은 항상 0이다.
4. 잔차는 모델의 등분산성이 만족되는지 확인하는데 사용된다.

해설

잔차는 음수가 있을 수 있으며,
최소제곱법에 의해 잔차의 평균은 항상 0이 된다.

문제 풀이

Q12. 피어슨 상관계수의 성질로 틀린 것은?

1. 상관계수 1.5는 존재할 수 없다.
2. 상관계수가 1이면 완전한 양의 선형관계를 의미한다.
3. 상관계수가 0이면 두 변수 간에 아무런 관계가 없다.
4. 상관계수가 마이너스 1이면 완전한 음의 선형관계를 의미한다.

문제 풀이

Q12. 피어슨 상관계수의 성질로 틀린 것은?

1. 상관계수 1.5는 존재할 수 없다.
2. 상관계수가 1이면 완전한 양의 선형관계를 의미한다.
3. 상관계수가 0이면 두 변수 간에 아무런 관계가 없다.
4. 상관계수가 마이너스 1이면 완전한 음의 선형관계를 의미한다.

해설

상관분석은 두 변수간 선형 관계를 알아보는 분석이다. 그러나 두 변수간의 관계는 선형 관계 뿐만 아니라 비선형 관계도 존재한다.

문제 풀이

Q13. 의사결정나무에 대한 설명으로 가장 적절한 것은?

1. 열성적 학습에 속하는 비모수적 지도학습 알고리즘이다.
2. 변수 스케일링이나 정규화가 반드시 필요하다.
3. 데이터 분포에 대한 엄격한 사전가정이 요구된다.
4. 매끄러운 곡선관계 표현에 매우 효율적이다.

문제 풀이

Q13. 의사결정나무에 대한 설명으로 가장 적절한 것은?

1. 열성적 학습에 속하는 비모수적 지도학습 알고리즘이다.
2. 변수 스케일링이나 정규화가 반드시 필요하다.
3. 데이터 분포에 대한 엄격한 사전가정이 요구된다.
4. 매끄러운 곡선관계 표현에 매우 효율적이다.

해설

의사결정나무는 의사결정 규칙의 특성상 회귀모델 예측의 경우 곡선의 표현이 아닌 계단형으로 나타난다. 그리고 학습 과정의 특성상 사전 가정의 필요 없는 비모수적 성격을 띄는 알고리즘이다.

문제 풀이

Q14. 나이브 베이즈 분류기에 대한 내용으로 가장 적절한 것은?

1. 모든 특성변수들이 서로 강한 상관관계를 갖는다.
2. 모든 특성변수들이 주어진 클래스에 대해 조건부 독립이다.
3. 연속형 독립변수만 처리할 수 있다.
4. 이진 분류 문제에만 적용 가능하다.

문제 풀이

Q14. 나이브 베이즈 분류기에 대한 내용으로 가장 적절한 것은?

1. 모든 특성변수들이 서로 강한 상관관계를 갖는다.
2. 모든 특성변수들이 주어진 클래스에 대해 조건부 독립이다.
3. 연속형 독립변수만 처리할 수 있다.
4. 이진 분류 문제에만 적용 가능하다.

해설

모든 독립변수는 주어진 범주에 대해 조건부 독립이다.
독립변수의 경우 연속형 뿐만 아니라 범주형도 처리가 가능하다.
단, 범주형의 경우 One-Hot 인코딩 같은 추가 처리가 필요하다.

문제 풀이

Q15. 어제 생산 공정에서는 근무시간(8시간)동안 총 16건의 생산품 결함이 보고되었다고 한다. 일반적으로 근무시간 동안 8건의 결함이 보고된다고 할 때 어제의 일이 일어날 확률은 얼마인가?

1. 약 10%
2. 약 19%
3. 약 18%
4. 약 27%

문제 풀이

Q15. 어제 생산 공정에서는 근무시간(8시간)동안 총 16건의 생산품 결함이 보고되었다고 한다. 일반적으로 근무시간 동안 8건의 결함이 보고된다고 할 때 어제의 일이 일어날 확률은 얼마인가?

1. 약 10%
2. 약 19%
3. 약 18%
4. 약 27%

$$P(X = k) = \frac{e^{-\lambda}\lambda^{k}}{k!}$$

해설

8시간 동안 총 16건의 결함은 1시간 평균 2건을 의미하고,
일반적으로 근무시간(8시간)동안 8건은 1시간 평균 1건을 의미한다.
상기 내용을 기반으로 계산하면 확률이 약 0.18로 약 18%라고 할 수 있다.

문제 풀이

Q16. k-Means 알고리즘의 중심점 계산 설명으로 가장 적절한 것은?

1. 각 군집에서 가장 빈번하게 나타나는 데이터포인트를 중심점으로 선택한다.
2. 각 군집에 속한 모든 데이터 포인트들의 좌표 평균값으로 계산한다.
3. 각 군집에서 다른 모든 점들과의 거리합이 최소인 점을 중심점으로 선택한다.
4. 각 군집의 경계에서 가장 가까운 점들의 중점을 중심점으로 계산한다.

문제 풀이

Q16. k-Means 알고리즘의 중심점 계산 설명으로 가장 적절한 것은?

1. 각 군집에서 가장 빈번하게 나타나는 데이터포인트를 중심점으로 선택한다.
2. 각 군집에 속한 모든 데이터 포인트들의 좌표 평균값으로 계산한다.
3. 각 군집에서 다른 모든 점들과의 거리합이 최소인 점을 중심점으로 선택한다.
4. 각 군집의 경계에서 가장 가까운 점들의 중점을 중심점으로 계산한다.

해설

군집별 중심점의 계산에 있어 중심점과 각 데이터 포인트간 거리 계산 후 특정 중심점과 가장 가까운 데이터 포인트들을 기준으로 해당 데이터 포인트의 좌표 평균값으로 해당 군집의 중심점 좌표를 계산한다.

문제 풀이

Q17. 랜덤포레스트(Random Forest)의 특징으로 가장 적절한 것은?

1. 선형 모델들만을 앙상블로 결합할 수 있다.
2. 부스팅(boosting) 기반의 순차적 학습을 수행한다.
3. 단일 의사결정나무보다 과적합 위험이 높다.
4. 배깅(bagging)과 특성 무작위 선택을 결합한 앙상블 기법이다.

문제 풀이

Q17. 랜덤포레스트(Random Forest)의 특징으로 가장 적절한 것은?

1. 선형 모델들만을 앙상블로 결합할 수 있다.
2. 부스팅(boosting) 기반의 순차적 학습을 수행한다.
3. 단일 의사결정나무보다 과적합 위험이 높다.
4. 배깅(bagging)과 특성 무작위 선택을 결합한 앙상블 기법이다.

해설

배깅의 부트스트랩 표본추출과 각 의사결정 나무 모델에 사용되는 특성(독립변수)에는 무작위(random)성이 반영된다.

문제 풀이

Q18. 군집분석의 평가지표 중 하나인 실루엣 점수에 대한 설명으로 가장 적절한 것은?

1. 1에 가까울수록 해당 데이터포인트가 잘못된 군집에 할당되었음을 의미한다.
2. 군집별로 하나씩 산출되는 값이다.
3. -1에 가까울수록 해당 데이터포인트가 완벽하게 군집에 할당되었음을 의미한다.
4. 실루엣 계수를 평균하여 산출하는 값이다.

문제 풀이

Q18. 군집분석의 평가지표 중 하나인 실루엣 점수에 대한 설명으로 가장 적절한 것은?

1. 1에 가까울수록 해당 데이터포인트가 잘못된 군집에 할당되었음을 의미한다.
2. 군집별로 하나씩 산출되는 값이다.
3. -1에 가까울수록 해당 데이터포인트가 완벽하게 군집에 할당되었음을 의미한다.
4. 실루엣 계수를 평균하여 산출하는 값이다.

해설

실루엣 계수는 엄밀하게 말하면 각 데이터 포인트에 대해서 산출되는 값이고 해당 값들을 평균 내어 산출하는 값이 실루엣 점수이다.

문제 풀이

Q19. 로지스틱 회귀분석에서 독립변수 X의 회귀계수가 0.693일 때, 이 변수의 오즈비(OR)는 얼마인가?

1. 1
2. 1.5
3. 2
4. 2.5

문제 풀이

Q19. 로지스틱 회귀분석에서 독립변수 X의 회귀계수가 0.693일 때, 이 변수의 오즈비(OR)는 얼마인가?

1. 1
2. 1.5
3. 2
4. 2.5

$$OR = \frac{odds(x_1,\ldots,x_i+1,\ldots x_n)}{odds(x_1,\ldots,x_i,\ldots x_n)}$$
$$= \frac{e^{\beta_1+\beta_1 x_1+\cdots+\beta_i(x_i+1)+\ldots+\beta_n x_n}}{e^{\beta_1+\beta_1 x_1+\cdots+\beta_i x_i+\ldots+\beta_n x_n}}$$
$$= e^{\beta_i}$$

해설

오즈비는 밑이 e(오일러 수)이고 지수부에 해당 독립변수의 회귀계수를 놓고 계산하는 값이다. 회귀 계수가 0.693일 때 오즈비는 약 1.9997로 반올림 하면 2라고 할 수 있다.

문제 풀이

Q20. 연속확률변수 X의 누적분포함수 F(x)의 성질로 틀린 것은?

1. 최솟값과 최댓값이 각각 0과 1이다.
2. F(x)는 단조증가 함수이다.
3. F(x)의 도함수가 확률밀도함수이다.
4. 구간 확률은 F(b) + F(a)로 계산된다.

문제 풀이

Q20. 연속확률변수 X의 누적분포함수 F(x)의 성질로 틀린 것은?

1. 최솟값과 최댓값이 각각 0과 1이다.
2. F(x)는 단조증가 함수이다.
3. F(x)의 도함수가 확률밀도함수이다.
4. 구간 확률은 F(b) + F(a)로 계산된다.

해설

확률밀도함수와 확률누적함수의 관계는 미분/적분 관계이며,
누적분포함수의 경우 구간 확률은 F(b) - F(a)로 계산된다.